MDPI

Article

Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares

Yeray Antón Juárez[1], Carlos Foo Sidro[1], Ángel Queral Castell[1]

[1] Máster en Ciencia de Datos Universitat de València; yeanjua@alumni.uv.es
* Correspondence: yeanjua@alumni.uv.es

Abstract: El proyecto trata de un análisis exploratorio de datos médicos con el objetivo de encontrar patrones entre datos del historial de un paciente y la aparición de enfermedades cardiovasculares, con el objetivo de poder llegar a predecir en un futuro si otros pacientes son susceptibles a desarrollar cardiopatías.

Keywords: Análisis Exploratorio de Datos; RMarkdown; Tidyverse; Enfermedades Cardiovasculares; Medicina.

1. Introducción

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel global. Según la Organización Mundial de la Salud (OMS), estas patologías son responsables de aproximadamente un 32% de todas las muertes en el mundo. Por tanto, lograr identificar de forma precoz a los pacientes susceptibles de padecerlas puede salvar multitud de vidas, especialmente considerando que el diagnóstico de estas enfermedades suele producirse en fases avanzadas.

El objetivo principal de este estudio es analizar los datos procedentes de la encuesta epidemiológica anual del *Centers for Disease Control and Prevention* (CDC), procesados y disponibles en Kaggle, para establecer relaciones entre diversas variables explicativas y la aparición de cardiopatías. El conjunto de datos está compuesto por 40 variables, incluyendo datos demográficos, hábitos de vida y la presencia de otras patologías secundarias, junto con una variable objetivo binaria que indica la presencia de enfermedad cardíaca. Al disponer de una muestra amplia de aproximadamente 246.000 observaciones, se cuenta con una base sólida para trabajar sobre los datos de forma robusta.

El presente análisis se articula en torno a la pregunta de si existe una relación directa entre los hábitos de vida, las características sociodemográficas y la presencia de patologías previas u otras variables con el riesgo de padecer enfermedades cardiovasculares.

El análisis exploratorio de datos (EDA) consistirá en un primer preprocesamiento y limpieza de los datos (tratamiento de valores perdidos y tipado de variables), seguido de un análisis mediante la visualización de relaciones entre variables con gráficos estadísticosAdemás, buscará identificar cuáles de estas variables muestran una mayor asociación con las cardiopatías, cómo interactúan entre sí y qué patrones o perfiles de pacientes presentan una mayor vulnerabilidad.

2. Métodos y Materiales

2.1. Descripción del Conjunto de Datos y Procedencia

El conjunto de datos analizado procede del Behavioral Risk Factor Surveillance System (BRFSS) correspondiente al año 2022, un sistema de encuestas telefónicas coordinado por los Centros para el Control y la Prevención de Enfermedades de los Estados Unidos. Esta base de datos recopila información anual de ciudadanos adultos no institucionalizados sobre hábitos de riesgo para la salud, condiciones médicas crónicas y uso de servicios preventivos.

Citation: Antón, Y.; Foo, C.; Queral, A. Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

El conjunto cuenta inicialmente con 445.132 observaciones y 40 variables que recogen mediciones biométricas continuas, variables sociodemográficas y antecedentes clínicos.

2.2. Diccionario de Variables

Las 40 variables del estudio se estructuran en seis dimensiones clínicas: **1) Sociodemográficas:** `Estado`, `Sexo`, `GrupoEdad` (13 tramos quinquenales) y `RazaEtnia`. **2) Antropométricas y salud física:** `AlturaMetros`, `PesoKilogramos`, `IMC` y percepción de salud (`SaludGeneral`, `DiasMalaSaludFisica`, `DiasMalaSaludMental`). **3) Hábitos de vida:** `HorasSueno`, `ActividadFisica`, `EstadoFumador`, `UsoCigarrilloElectronico` y `ConsumidorAlcohol`. **4) Patologías y comorbilidades:** `InfartoMiocardio`, `AnginaPecho`, `Ictus`, `Diabetes`, `Asma`, `EPOC`, `EnfermedadRenal`, `Artritis`, `CancerPiel` y `TrastornoDepresivo`. **5) Limitaciones funcionales:** `DientesExtraidos` y dificultades en la vida diaria (`DificultadAuditiva`, `Visual`, `Concentracion`, `Caminar`, `VestirseBanarse`, `TareasDiarias`). **6) Prevención y vacunas:** `UltimoChequeoMedico`, `TomografiaTorax`, `PruebaVIH`, `VacunaGripeUltimoAno`, `VacunaNeumococo`, `VacunaTetanos10Anos`, `ConductaAltoRiesgo` y `CovidPositivo`. Como variable objetivo derivada se define `EnfermedadCard` (diagnóstico positivo en infarto o angina).

2.3. Ingesta y Tipado de Variables

La importación se realiza de forma reproducible a partir del archivo comprimido mediante la librería readr. Posteriormente, se convierten las variables cualitativas a factores nominales y ordinales, y se define la variable objetivo EnfermedadCardiaca (definida como presencia de infarto de miocardio HadHeartAttack o angina de pecho HadAngina).

```
# Carga reproducible
heart_raw <- read_csv("data/heart_2022_with_nans.csv.gz")

# Renombrado de variables a español
heart_data <- heart_raw %>%
  rename(
    Estado = State, Sexo = Sex, SaludGeneral = GeneralHealth,
    DiasMalaSaludFisica = PhysicalHealthDays, DiasMalaSaludMental = MentalHealthDays,
    UltimoChequeoMedico = LastCheckupTime, ActividadFisica = PhysicalActivities,
    HorasSueno = SleepHours, DientesExtraidos = RemovedTeeth,
    InfartoMiocardio = HadHeartAttack, AnginaPecho = HadAngina, Ictus = HadStroke,
    Asma = HadAsthma, CancerPiel = HadSkinCancer, EPOC = HadCOPD,
    TrastornoDepresivo = HadDepressiveDisorder, EnfermedadRenal = HadKidneyDisease,
    Artritis = HadArthritis, Diabetes = HadDiabetes, DificultadAuditiva = DeafOrHardOfHearing,
    DificultadVisual = BlindOrVisionDifficulty, DificultadConcentracion = DifficultyConcentrating,
    DificultadCaminar = DifficultyWalking, DificultadVestirseBanarse = DifficultyDressingBathing,
    DificultadTareasDiarias = DifficultyErrands, EstadoFumador = SmokerStatus,
    UsoCigarrilloElectronico = ECigaretteUsage, TomografiaTorax = ChestScan,
    RazaEtnia = RaceEthnicityCategory, GrupoEdad = AgeCategory, AlturaMetros = HeightInMeters,
    PesoKilogramos = WeightInKilograms, IMC = BMI, ConsumidorAlcohol = AlcoholDrinkers,
    PruebaVIH = HIVTesting, VacunaGripeUltimoAno = FluVaxLast12, VacunaNeumococo = PneumoVaxEver,
    VacunaTetanos10Anos = TetanusLast10Tdap, ConductaAltoRiesgo = HighRiskLastYear, CovidPositivo = CovidPos
  )

# Tipado de variables y creación de HeartDisease
heart_data <- heart_data %>%
  mutate(
    EnfermedadCardiaca = factor(if_else(InfartoMiocardio == "Yes" | AnginaPecho == "Yes", "Yes", "No"), levels = c("
    Diabetes = factor(case_when(
      Diabetes %in% c("Yes", "No, pre-diabetes or borderline diabetes") ~ "Yes",
      Diabetes %in% c("No", "Yes, but only during pregnancy (female)") ~ "No",
      TRUE ~ NA_character_
    ), levels = c("No", "Yes")),
    SaludGeneral = factor(SaludGeneral, levels = c("Poor", "Fair", "Good", "Very good", "Excellent"), ordered = TRUE
    GrupoEdad = factor(GrupoEdad, levels = c(
      "Age 18 to 24", "Age 25 to 29", "Age 30 to 34", "Age 35 to 39", "Age 40 to 44", "Age 45 to 49",
      "Age 50 to 54", "Age 55 to 59", "Age 60 to 64", "Age 65 to 69", "Age 70 to 74", "Age 75 to 79", "Age 80 or old
    ), ordered = TRUE),
    DientesExtraidos = factor(DientesExtraidos, levels = c("None of them", "1 to 5", "6 or more, but not all", "All
    EstadoFumador = factor(EstadoFumador, levels = c(
      "Never smoked", "Former smoker", "Current smoker - now smokes some days", "Current smoker - now smokes every d
    ), ordered = TRUE),
    UsoCigarrilloElectronico = factor(UsoCigarrilloElectronico, levels = c(
      "Never used e-cigarettes in my entire life", "Not at all (right now)", "Use them some days", "Use them every d
    ), ordered = TRUE),
    UltimoChequeoMedico = factor(UltimoChequeoMedico, levels = c(
      "Within past year (anytime less than 12 months ago)", "Within past 2 years (1 year but less than 2 years ago)"
```

```
      "Within past 5 years (2 years but less than 5 years ago)", "5 or more years ago"
    ), ordered = TRUE),
    CovidPositivo = factor(case_when(CovidPositivo == "No" ~ "No", str_detect(CovidPositivo, "positive|Yes") ~ "Yes"
    VacunaTetanos10Anos = factor(case_when(str_detect(VacunaTetanos10Anos, "^No") ~ "No", str_detect(VacunaTetanos10
    TotalEnfermedades = rowSums(across(c(Ictus, Diabetes, Asma, EPOC, EnfermedadRenal, Artritis, CancerPiel, Trastor
    across(where(is.character), as.factor)
  )

# Resumen del dataset
tabla_resumen <- tibble(
  Métrica = c("Total Observaciones", "Variables Totales", "Casos Cardiopatía (Yes)", "Casos Sin Cardiopatía (No)", "
  Valor = c(as.character(nrow(heart_data)), as.character(ncol(heart_data)), sum(heart_data$EnfermedadCardiaca == "Ye
            sum(heart_data$EnfermedadCardiaca == "No", na.rm = TRUE), paste(round(mean(heart_data$EnfermedadCardiaca
)

kable(tabla_resumen, caption = "Dimensiones iniciales y prevalencia de cardiopatías.")
```

Table 1. Dimensiones iniciales y prevalencia de cardiopatías.

Métrica	Valor
Total Observaciones	445132
Variables Totales	42
Casos Cardiopatía (Yes)	39751
Casos Sin Cardiopatía (No)	400360
Prevalencia Cardiopatía (%)	9.03 %

2.4. Detección y Corrección de Inconsistencias

Siguiendo con el análisis exploratorio se analiza la presencia de valores especiales, valores numéricos imposibles para las variables y la consistencia entre el índice de masa corporal, el peso y la altura.

```
# Comprobación de especiales, valores no positivos y consistencia de IMC
infinitos <- sapply(heart_data %>% select(where(is.numeric)), function(x) sum(is.infinite(x)))
menores_cero <- sapply(heart_data %>% select(where(is.numeric)), function(x) sum(x < 0, na.rm = TRUE))
inconsistencias_bmi <- sum(abs(heart_data$IMC - (heart_data$PesoKilogramos / heart_data$AlturaMetros^2)) > 1.5, na.r

# Corrección de inconsistencias biológicas imposibles a NA
heart_data <- heart_data %>%
  mutate(
    HorasSueno = if_else(HorasSueno <= 2 | HorasSueno >= 20, NA_real_, HorasSueno),
    AlturaMetros = if_else(AlturaMetros < 1.0, NA_real_, AlturaMetros)
  )
```

Tras la verificación, se comprobó la ausencia de valores infinitos y de valores negativos imposibles en las variables numéricas (constatando que únicamente `DiasMalaSaludFisica` y `DiasMalaSaludMental` presentan valores 0 válidos). Asimismo, no se detectaron discrepancias entre el IMC y el cociente peso/altura fuera del margen de tolerancia de 1.5 kg/m^2 atribuible al redondeo de unidades imperiales. Se sustituyeron por `NA` los valores biológicamente anómalos: horas de sueño ≤ 2 o ≥ 20 y estaturas de adultos inferiores a 1 metro.

2.5. Valores Perdidos y Observaciones Completas

A continuación se cuantifica el volumen de valores perdidos presentes en las variables y se evalúa la proporción de casos completos.

```
# Cálculo de NAs por columna
nas_columna <- colSums(is.na(heart_data))
pct_nas <- round((nas_columna / nrow(heart_data)) * 100, 2)

# Tabla maquetada con las 5 variables de mayor volumen de NAs
tabla_nas <- tibble(
  Variable = names(nas_columna),
  Num_NAs = nas_columna,
  Porcentaje = paste(pct_nas, " %")
) %>%
  filter(Num_NAs > 0) %>%
```

```
  arrange(desc(Num_NAs))

kable(head(tabla_nas, 5), caption = "Variables con mayor proporción de valores perdidos.")
```

Table 2. Variables con mayor proporción de valores perdidos.

Variable	Num_NAs	Porcentaje
VacunaTetanos10Anos	82516	18.54 %
VacunaNeumococo	77040	17.31 %
PruebaVIH	66127	14.86 %
TomografiaTorax	56046	12.59 %
CovidPositivo	50764	11.4 %

El análisis de casos completos revela que 277.447 observaciones (el 62.33% del total) carecen de valores perdidos en la totalidad de sus campos. Descartar las filas incompletas mediante un filtrado global supondría desechar casi un 38% de la muestra (asociado a preguntas optativas de inmunización o chequeos). Por tanto, se conservan las observaciones para el análisis general y se aplican procedimientos de imputación en las variables clave.

2.6. Detección Univariante de Outliers y Comparativa de Métodos

A continuación se aplican y comparan cuatro métodos de detección de outliers sobre el IMC (Índice de Masa Corporal): regla 3 sigma, identificador Hampel, regla del boxplot y percentiles (5% y 95%).

Para cada método se evalúa tanto el número de anomalías detectadas como los umbrales que definen los valores típicos para decidir como tratar a los valores extremos.

```
# Definición de reglas univariantes
reglasigma     <- function(x) abs(x - mean(x, na.rm = TRUE)) > 3 * sd(x, na.rm = TRUE)
reglahampel    <- function(x) abs(x - median(x, na.rm = TRUE)) > 3 * (1.4826 * median(abs(x - median(x, na.rm = TRUE
reglaboxplot   <- function(x) { q <- quantile(x, c(0.25, 0.75), na.rm = TRUE); x < q[1] - 1.5 * diff(q) | x > q[2] +
reglapercentil <- function(x) { p <- quantile(x, c(0.05, 0.95), na.rm = TRUE); x < p[1] | x > p[2] }

# Clasificación de outliers sobre IMC
heart_outliers <- heart_data %>%
  mutate(IMC_Sigma = reglasigma(IMC), IMC_Hampel = reglahampel(IMC),
         IMC_Boxplot = reglaboxplot(IMC), IMC_Percentil = reglapercentil(IMC))

# Umbrales y comparativa de métodos
m_imc <- mean(heart_data$IMC, na.rm = TRUE); s_imc <- sd(heart_data$IMC, na.rm = TRUE)
med_imc <- median(heart_data$IMC, na.rm = TRUE); mad_imc <- 1.4826 * median(abs(heart_data$IMC - med_imc), na.rm = T
q_imc <- quantile(heart_data$IMC, c(0.25, 0.75), na.rm = TRUE); p_imc <- quantile(heart_data$IMC, c(0.05, 0.95), na.

tabla_outliers <- tibble(
  Método = c("Regla 3 Sigma", "Identificador Hampel", "Regla Boxplot", "Percentiles (5% - 95%)"),
  Outliers_Detectados = c(sum(heart_outliers$IMC_Sigma, na.rm = TRUE), sum(heart_outliers$IMC_Hampel, na.rm = TRUE),
                          sum(heart_outliers$IMC_Boxplot, na.rm = TRUE), sum(heart_outliers$IMC_Percentil, na.rm = TR
  Porcentaje = paste(round(c(mean(heart_outliers$IMC_Sigma, na.rm = TRUE), mean(heart_outliers$IMC_Hampel, na.rm = T
                             mean(heart_outliers$IMC_Boxplot, na.rm = TRUE), mean(heart_outliers$IMC_Percentil, na.r
  Umbral_Inferior = round(c(m_imc - 3 * s_imc, med_imc - 3 * mad_imc, q_imc[1] - 1.5 * diff(q_imc), p_imc[1]), 2),
  Umbral_Superior = round(c(m_imc + 3 * s_imc, med_imc + 3 * mad_imc, q_imc[2] + 1.5 * diff(q_imc), p_imc[2]), 2)
)
kable(tabla_outliers, caption = "Comparativa de métodos de detección de outliers y umbrales en IMC.")
```

Table 3. Comparativa de métodos de detección de outliers y umbrales en IMC.

Método	Outliers_Detectados	Porcentaje	Umbral_Inferior	Umbral_Superior
Regla 3 Sigma	5071	1.28 %	8.87	48.19
Identificador Hampel	10657	2.69 %	10.85	44.03
Regla Boxplot	12339	3.11 %	12.70	43.18
Percentiles (5% - 95%)	38840	9.8 %	20.12	40.69

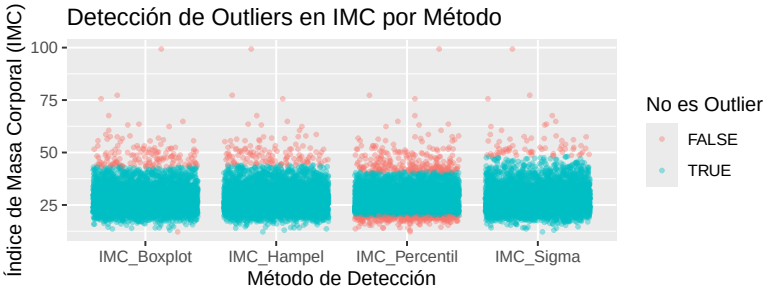


Figure 1. Detección de outliers en IMC según cada método implementado

La regla 3 Sigma es poco agresiva: fija el umbral superior en 48.21, detectando solo un 1.28% de outliers debido a que la propia desviación típica se expande por la presencia de casos extremos. **El identificador Hampel es más agresivo:** al basarse en el MADM, sitúa el umbral superior en 44.03, identificando un 2.69% de anomalías. **La regla del Boxplot:** con un umbral superior de 43.33 y detectando un 3.11% de valores fuera de los bigotes. Esto pasa porque justo la variable IMC no es simétrica si no con una cola a la derecha. **Percentiles:** corta de forma fija el 10% de la muestra, con independencia de la distribución.

Tratamiento de los outliers identificados: Estos valores de IMC no representan errores de medición o transcripción (ya fueron filtrados antes), sino observaciones biológicamente reales correspondientes a pacientes con obesidad mórbida (grado III). Por tanto, no se eliminan del conjunto de datos, sino que se conservan para ser analizados mediante procedimientos y estadísticos en los siguientes bloques.

2.7. Representación Gráfica de Outliers por Método

Se representan gráficamente los valores de IMC frente a los métodos de detección empleados, mostrando los datos catalogados como típicos y los catalogados como outliers en distinto color.

Para evitar problemas de saturación visual en el gráfico debido al volumen de más de 400.000 observaciones, se utiliza una muestra aleatoria representativa de 5.000 observaciones con set.seed(123) y se aplica dispersión aleatoria con transparencia.

```r
# Preparación de datos
set.seed(123)

df_plot_outliers <- heart_outliers %>%
  select(IMC, starts_with("IMC_")) %>%
  filter(!is.na(IMC)) %>%
  slice_sample(n = 5000) %>%
  pivot_longer(
    cols = starts_with("IMC_"),
    names_to = "Metodo",
    values_to = "Es_Outlier"
  )

# Gráfico de puntos con jitter
ggplot(df_plot_outliers, aes(x = Metodo, y = IMC, color = !Es_Outlier)) +
  geom_point(position = "jitter", alpha = 0.4, size = 0.8) +
  labs(
    title = "Detección de Outliers en IMC por Método",
    x = "Método de Detección",
    y = "Índice de Masa Corporal (IMC)",
    color = "No es Outlier"
  )
```

El gráfico refleja de manera visual la sensibilidad de cada método.

Continuidad de los datos: Se observa que los valores superiores no son puntos aislados ni errores tipográficos, sino una nube continua que se extiende hasta valores extremos, confirmando que se trata de individuos con obesidad severa real que deben conservarse en la muestra.

- **Comparativa de cortes:** La regla 3 Sigma deja una franja alta de puntos clasificados como normales (debido a la varianza inflada), mientras que la regla del Boxplot y el identificador Hampel capturan de forma equilibrada la masa de valores atípicos.

2.8. Imputación de Variables Numéricas

Para garantizar la integridad de los análisis cuantitativos posteriores sin introducir sesgos artificiales, se aplica una imputación según la naturaleza de cada variable:

Variables AlturaMetros, PesoKilogramos, IMC: Hombres y mujeres siguen distribuciones distintas. Imputamos los valores perdidos directamente por la media según el Sexo del paciente.

Variables de descanso y salud percibida (`HorasSueno`**,** `DiasMalaSaludFisica`**,** `DiasMalaSalud` Al concentrarse en valores típicos (7 horas de sueño y 0 días de enfermedad), se imputan mediante su mediana.

```
# Imputación por Sexo (antropometría) y por Mediana (descanso y salud percibida)
heart_data <- heart_data %>%
  group_by(Sexo) %>%
  mutate(
    AlturaMetros   = coalesce(AlturaMetros, mean(AlturaMetros, na.rm = TRUE)),
    PesoKilogramos = coalesce(PesoKilogramos, mean(PesoKilogramos, na.rm = TRUE)),
    IMC            = coalesce(IMC, mean(IMC, na.rm = TRUE))
  ) %>%
  ungroup() %>%
  mutate(across(c(HorasSueno, DiasMalaSaludFisica, DiasMalaSaludMental), ~ coalesce(.x, median(.x, na.rm = TRUE)))) %>%
  drop_na()
```

Tras el proceso de imputación de las variables cuantitativas y el filtrado de observaciones completas en los registros categóricos restantes, el conjunto de datos final cuenta con 267.281 observaciones y cero valores perdidos en la totalidad de sus 40 variables, quedando perfectamente acondicionado para los análisis univariante, bivariante y multivariante.

3. Resultados

En este apartado vamos a estudiar los datos como hemos mencionado en la sección anterior, dividiéndolo en dos subsecciones dependiendo de la naturaleza del análisis.

3.1. Análisis Univariante

El análisis univariante va a consistir en analizar la distribución de algunas de las variables, representando factores. binarias y numéricas. También podemos ver algunos estadísticos representativos de las variables numéricas.

```
skewness <- function(x) {
  x <- x[!is.na(x)]
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^3 / s^3) / n}
kurtosis <- function(x) {
  x <- x[!is.na(x)]
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^4 / s^4) / n - 3}
madm <- function(x) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)}
# Hago de nuevo la tabla por todas las imputaciones hechas
estadisticos_num <- heart_data %>%select(where(is.numeric)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>%
  group_by(Variable) %>%summarise(
    Media = round(mean(Valor, na.rm = TRUE), 2),SD   = round(sd(Valor, na.rm = TRUE), 2),
    Mediana = round(median(Valor, na.rm = TRUE), 2),
    MADM = round(madm(Valor), 2),IQR = round(IQR(Valor, na.rm = TRUE), 2),
    Sesgo = round(skewness(Valor), 2),Curtosis = round(kurtosis(Valor), 2))
```

En esta tabla podemos ver la diferencia que hay entre medidas como la media, mediana o MADM. En variables como IMC las medidas no son muy distantes entre sí, pero la curtosis y el sesgo ya nos arrojan pistas sobre la forma de su distribución, parecida a una normal

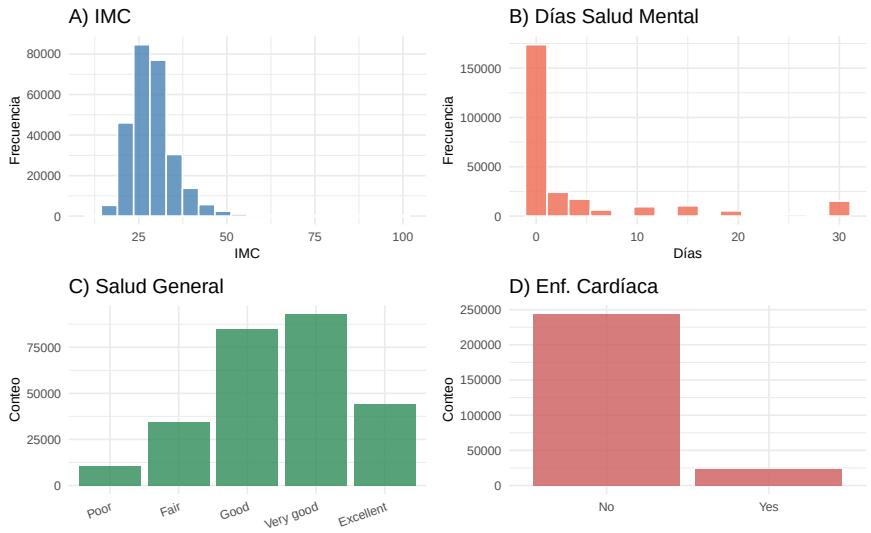


Figure 2. Distribuciones univariantes de las variables principales del estudio.

pero con colas más grandes y asimétricas. También es resaltable lo que distan en otras variables como el número de dias con mala salud, que al tener distribuciones algo más exóticas sí que se consigue una gran diferencia entre medidas como la media y la mediana.

Con esto, ya podemos pasar con las gráficas y comentarlas.

```
p1 <- ggplot(heart_data, aes(x = IMC)) +
  geom_histogram(bins = 20, fill = "steelblue", color = "white", alpha = 0.8) +
  theme_minimal() +
  theme(axis.text = element_text(size = 8), axis.title = element_text(size = 9)) +labs(title = "A) IMC", x = "IMC",

p2 <- ggplot(heart_data, aes(x = DiasMalaSaludMental)) +
  geom_histogram(bins = 15, fill = "coral2", color = "white", alpha = 0.8) +
  theme_minimal() +
  theme(axis.text = element_text(size = 8), axis.title = element_text(size = 9)) +labs(title = "B) Días Salud Mental

p3 <- ggplot(heart_data, aes(x = SaludGeneral)) +
  geom_bar(fill = "seagreen", alpha = 0.8) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 20, hjust = 1, size = 8),
        axis.text.y = element_text(size = 8), axis.title = element_text(size = 9)) +labs(title = "C) Salud General",

p4 <- ggplot(heart_data, aes(x = EnfermedadCardiaca)) +
  geom_bar(fill = "indianred", alpha = 0.8) +
  theme_minimal() +
  theme(axis.text = element_text(size = 8), axis.title = element_text(size = 9)) +labs(title = "D) Enf. Cardíaca", x

(p1 + p2) / (p3 + p4)
```

A partir de estas gráficas podemos sacar varias conclusiones. En las variables numéricas ya habíamos comentado como los estadísticos de la tabla podían darnos información sobre la variable. En el dataset hay diferentes distribuciones continuas, pero a pesar de los múltiples parecidos solo la altura es susceptible a tener una distribución normal.

Por otra parte, tanto los factores ordenados como los no ordenados nos dan menos información que las variables numéricas, pero aun así podemos ver en sus gráficas cuales son los valores predominantes. En el caso representado podemos ver que 'Very Good' es la respuesta más popular, pero podríamos ver que grupos de edad están más representados, o que porcentaje de la muestra fuma o es exfumador, entre otras cosas, si representamos las variables adecuadas.

Por último en las variables binarias podemos ver el porcentaje de respuestas positivas hay en cada variable. En el caso de la variable target vemos como es aproximadamente un 9%. Esto puede ser importante considerarlo a la hora de construir modelos con este dataset o incluso al llevar un análisis exploratorio bivariante, como veremos más adelante. Si representaramos otras variables podríamos ver que otras están desbañanceadas (Dia-

betes, ConductaRiesgo, DificultadCaminar, etc.) y cuales están más o menos balanceadas (ConsumidorAlcohol, VacunaGripe, etc.).

3.2. Análisis Bivariante

Para el análisis bivariante lo vamos a estructurar en dos partes. La primera estudiaremos con tests si las variables explicativas tienen relación entre sí, mientras que en la segunda veremos si la tienen con la variable objetivo.

3.2.1. Redundancia y Multicolinealidad entre Variables Explicativas

Vamos a seleccionar distintos grupos susceptibles a tener redundancia. Para factores, vamos a utilizar la V de Cramer, Wilcoxon cuando sea una variable numérica con una binaria y Kruskal-Wallis cuando sea una numérica con un factor, que son los casos que vamos a estudiar. A estos dos últimos casos vamos a añadirle un test de Spearman para terminar de concretar la relación entre las variables.

El primer grupo de variables que vamos a estudiar es del subgrupo de variables que representan dificultades, podemos pensar que las mismas dificultades motoras pueden llegar a traducirse a dificultad al andar, a vestirse o bañarse, y a hacer tareas en general.

```
cat(sprintf("V de Cramér (Caminar vs. Vestirse/Bañarse): %.4f\n", assocstats(table(heart_data$DificultadCaminar, hea
```

```
## V de Cramér (Caminar vs. Vestirse/Bañarse): 0.3816
```

```
cat(sprintf("V de Cramér (Caminar vs. Tareas Diarias): %.4f\n", assocstats(table(heart_data$DificultadCaminar, heart
```

```
## V de Cramér (Caminar vs. Tareas Diarias): 0.3829
```

```
cat(sprintf("V de Cramér (Vestirse/Bañarse vs. Tareas Diarias): %.4f\n", assocstats(table(heart_data$DificultadVesti
```

```
## V de Cramér (Vestirse/Bañarse vs. Tareas Diarias): 0.4158
```

Los valores del estadístico no son despreciables, pero tampoco son altos, puesto que no superan siquiera el 0.5. Por tanto, dos a dos, podemos decir que las variables tengan una correlación suficiente como para eliminar alguna.

El siguiente grupo de variables a estudiar es uno formado por la salud general autopercibida y las variables de dias de malestar, tanto físico como mental.

```
kw1 <- kruskal.test(DiasMalaSaludFisica ~ SaludGeneral, data = heart_data)
cat(sprintf("Kruskal (Salud Física ~ Salud General):, p-valor %s\n", format.pval(kw1$p.value, eps = 1e-16)))
```

```
## Kruskal (Salud Física ~ Salud General):, p-valor < 1e-16
```

```
sp1 <- cor.test(as.numeric(heart_data$SaludGeneral), heart_data$DiasMalaSaludFisica, method = "spearman", exact = FA
cat(sprintf("Spearman (Salud General vs. Salud Física): $\\rho$ = %.4f \n",
sp1$estimate))
```

```
## Spearman (Salud General vs. Salud Física): $\rho$ = -0.4048
```

```
kw2 <- kruskal.test(DiasMalaSaludMental ~ SaludGeneral, data = heart_data)
cat(sprintf("Kruskal (Salud Mental ~ Salud General): p-valor %s\n", format.pval(kw2$p.value, eps = 1e-16)))
```

```
## Kruskal (Salud Mental ~ Salud General): p-valor < 1e-16
```

```
sp2 <- cor.test(as.numeric(heart_data$SaludGeneral), heart_data$DiasMalaSaludMental, method = "spearman", exact = FA
cat(sprintf("Spearman (Salud General vs. Salud Mental): $\\rho$ = %.4f \n",
sp2$estimate))
```

```
## Spearman (Salud General vs. Salud Mental): $\rho$ = -0.2095
```

El test de Kruskal con p valor bajo nos dice que hay cierta relación entre las variables, pero es Spearman el que cuantifica como de fuerte es esta relación. Valores negativos entre -0.2 y -0.5 nos permiten concluir que la relación es moderada, pero no hay redundancia, además de que la relación de estas variables es inversa (mayor salud general se traduce en menos dias malos). Además, podemos concluir que la salud física es más influyente en la percepción de la salud general.

Relacionado con esto tambien podemos comparar las variables `DiasMalaSaludMental` con `TrastornoDepresivo`.

```
wt <- wilcox.test(DiasMalaSaludMental ~ TrastornoDepresivo, data = heart_data)
cat(sprintf("Wilcoxon test (Salud Mental ~ Depresión):  p-valor %s\n", format.pval(wt$p.value, eps = 1e-16)))
```

```
## Wilcoxon test (Salud Mental ~ Depresión):  p-valor < 1e-16
```

```
sp <- cor.test(as.numeric(heart_data$TrastornoDepresivo), heart_data$DiasMalaSaludMental, method = "spearman", exact
cat(sprintf("Spearman (Depresión vs. Salud Mental): $\\rho$ = %.4f \n",
sp$estimate))
```

```
## Spearman (Depresión vs. Salud Mental): $\rho$ = 0.4301
```

De nuevo, la relación parece ser existente, pero Spearman nos dice que la magnitud no es lo suficientemente grande como para ser redundante. Destacar que como cabría esperar una relación directa entre las dos variables, en contraposición a la de salud general que era inversa.

El último bloque que vamos a tratar es el de fumadores y fumadores electrónicos o vaper ya que no sería raro una fuerte correlación.

```
cat(sprintf("V de Cramér (Fumador vs. Cigarrillo Electrónico): %.4f\n", assocstats(table(heart_data$EstadoFumador, h
```

```
## V de Cramér (Fumador vs. Cigarrillo Electrónico): 0.1783
```

El valor del estadístico es bastante bajo, lo cual nos dice que a priori la relación entre estas dos variables no es nada importante.

Por último, destacar que otras variables que van a tener cierta correlación por construcción son las que literalmente hemos construido a partir de otras variables, como `IMC` o `TotalEnfermedades`. Estas variables no las hemos estudiado aquí porque su cometido es el contrario, intentar resumir el contenido de varias variables para enriquecer el dataset. Dependiendo del modelo con el que se quiera trabajar resulta más útil quitar variables redundantes o generar nuevas variables que pueden resumir mejor la información.

3.2.2. Relación con la variable objetivo

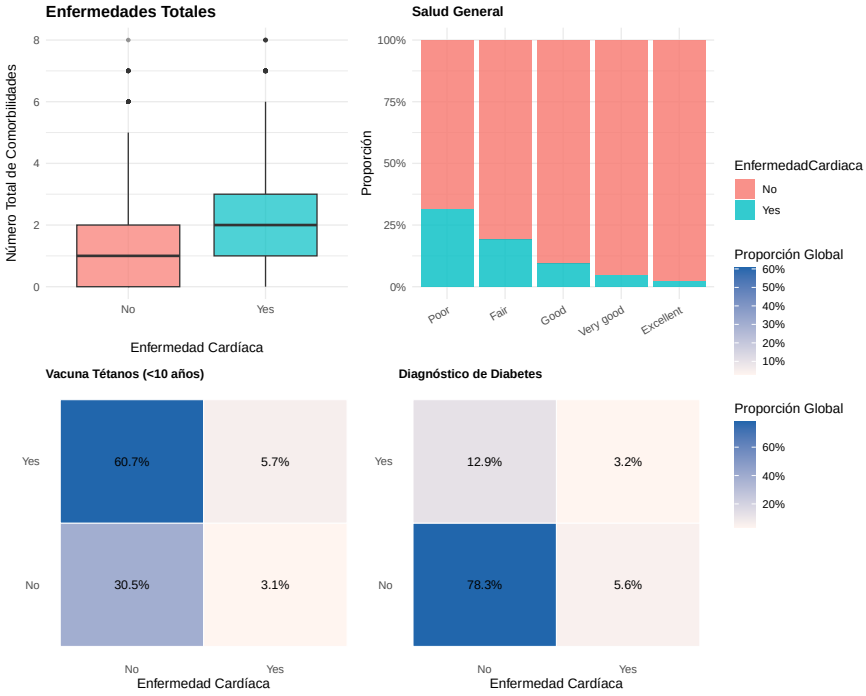
Ahora estudiaremos la relación de las variables con la variable objetivo. Para ello, nos serviremos de el valor que nos devuelve Spearman (en valor absoluto) y V de Cramer, que aunque no sea lo mismo, es comparable, ya que no podemos hacer el mismo test para distintos tipos de variables. Con esto, tendremos las distintas columnas ordenadas en cierta medida por orden de influencia en la target.

```
predictors <- names(heart_data)[-c(10,11,41)]
influencia <- c()
for (var in predictors) {
  x <- heart_data[[var]]
  y <- heart_data[['EnfermedadCardiaca']]
  if (is.numeric(x) || is.ordered(x)) {
    spearman_res <- suppressWarnings(cor.test(as.numeric(x), as.numeric(y), method = "spearman"))
    influencia[var] <- abs(spearman_res$estimate)}
  else {
    tabla <- table(x, y)
    cramer_res <- assocstats(tabla)$cramer
    influencia[var] <- cramer_res}}
influencia_ordenada <- sort(influencia, decreasing = TRUE)
df_influencia_ordenada <- data.frame(Variable = names(influencia_ordenada),
  Influencia = as.numeric(influencia_ordenada))
tabla_resumen <- bind_rows(head(df_influencia_ordenada, 5),
  data.frame(Variable = "...", Influencia = NA),tail(df_influencia_ordenada, 5))
```

Vemos como variables como la edad o el número de enfermedades son las que más influyen, mientras que horas de sueño y los días de mala salud mental son las que menos influyen a priori.

Podríamos comparar y comentar los valores de esta tabla con mas detención pero sería demasiado estenso, así que en su lugar vamos a representar gráficamente la relación entre target y algunas de las variables.

```
p1<-ggplot(heart_data, aes(x = EnfermedadCardiaca, y = TotalEnfermedades, fill = EnfermedadCardiaca)) +
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.2, outlier.size = 1) +
  labs(title = "Enfermedades Totales",x = "Enfermedad Cardíaca",
    y = "Número Total de Comorbilidades") +theme_minimal() +
  theme(legend.position = "none", plot.title = element_text(face = "bold"))
p2 <- ggplot(heart_data, aes(x = SaludGeneral, fill = EnfermedadCardiaca)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Salud General", x = NULL, y = "Proporción") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 30, hjust = 1, size = 9),
        plot.title = element_text(face = "bold", size = 11))
crear_heatmap_binaria <- function(data, var_binaria, titulo) {
  data %>%count(EnfermedadCardiaca, !!sym(var_binaria)) %>%
    mutate(Proporcion = n / sum(n)) %>%
    ggplot(aes(x = EnfermedadCardiaca, y = as.factor(!!sym(var_binaria)), fill = Proporcion)) +geom_tile(color = "wh
    scale_fill_gradient(low = "#FFF5F0", high = "#2166AC", labels = scales::percent) +
    geom_text(aes(label = scales::percent(Proporcion, accuracy = 0.1)), color = "black", size = 3.5) +
    labs(title = titulo, x = "Enfermedad Cardíaca", y = NULL, fill = "Proporción Global") +theme_minimal() +theme(
      plot.title = element_text(face = "bold", size = 10),
      panel.grid = element_blank())}
p3 <- crear_heatmap_binaria(heart_data, "VacunaTetanos10Anos", "Vacuna Tétanos (<10 años)")
p4 <- crear_heatmap_binaria(heart_data, "Diabetes", "Diagnóstico de Diabetes")
(p1 + p2) / (p3 + p4) + plot_layout(guides = "collect")
```



A partir de esto podemos interpretar cosas de estas variables, y en caso de querer, de otras que no hemos representado por falta de espacio.

Cuando vemos las variables que son numéricas representamos un boxplot y podemos ver como afecta la variable el valor de la target. En este caso vemos como los que sí tienen cardiopatías promedian más enfermedades que los que no.

Al tener factores, sobre todo ordenados, podemos hacer un gráfico de barras para verlo en proporción con el total. En el caso representado vemos como los enfermos reportan una salud general menor como cabría esperar, pero además podemos comparar este valor con el de los otros grupos de salud general.

En variables binarias representamos con heatmaps, permitiendo ver los 4 grupos generados por la intersección de las 2 variables. Es aquí donde hay que tener cuidado con el desbalance de las variables, ya que se ve claramente como la vacuna del tetanos no afecta a las proporciones de enfermedad cardiaca, pero ver que diabete si afecta significativamente pese a ser una variable muy desbalanceada puede ser difícil de ver a primera vista ya que el porcentaje de no diabéticos con enfermedad cardiaca es mayor que el de diabéticos.

3.3. Distribución Geográfica y Prevalencia por Estado

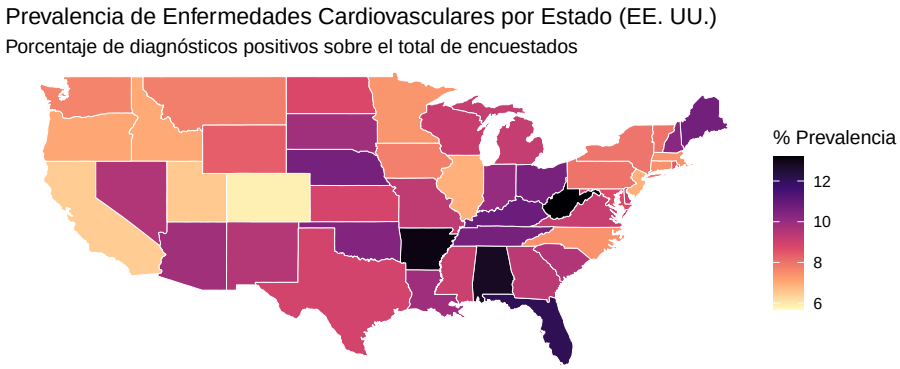
Con el fin de determinar si el riesgo cardiovascular se distribuye homogéneamente en el territorio de Estados Unidos, se calcula la tasa de prevalencia de cardiopatías en cada estado a partir de los datos recopilados. Esta representación geográfica facilita la detección de disparidades territoriales significativas y zonas de concentración de riesgo.

```r
#Cálculo de la prevalencia de cardiopatías por estado
prevalencia_estado <- heart_data %>%
  filter(!is.na(Estado)) %>%
  group_by(Estado) %>%
  summarise(
    Total = n(),
    Casos = sum(EnfermedadCardiaca == "Yes", na.rm = TRUE),
    Prevalencia = (Casos / Total) * 100
  ) %>%
  mutate(region = tolower(as.character(Estado)))#Conversión del nombre del estado a minúsculas para cruzar con los p

#Carga de los datos de los estados de EE. UU.
us_states <- map_data("state")

#Unión de la prevalencia de cardiopatías con las coordenadas del mapa
mapa_datos <- us_states %>% left_join(prevalencia_estado, by = "region")

#Generación del mapa de los estados de eeuu coloreados según la prevalencia de cardipatías
ggplot(mapa_datos, aes(x = long, y = lat, group = group, fill = Prevalencia)) +
  geom_polygon(color = "white", linewidth = 0.2) +
  scale_fill_viridis_c(option = "magma", direction = -1, name = "% Prevalencia") +
  theme_void() +
  labs(
    title = "Prevalencia de Enfermedades Cardiovasculares por Estado (EE. UU.)",
    subtitle = "Porcentaje de diagnósticos positivos sobre el total de encuestados"
  )
```



El mapa refleja de forma clara que la presencia de cardiopatías no se distribuye por igual en todos los estados de EE. UU. Las tasas más altas (por encima del 11%) se concentran en el sureste y la zona de los Apalaches, destacando estados como Virginia Occidental, Arkansas, Misisipi y Alabama. Esta concentración coincide con el conocido "cinturón del infarto" (*Stroke Belt*), caracterizado por mayores niveles de tabaquismo y obesidad, dietas con más sodio y peores accesos a revisiones médicas preventivas. Por su parte, la mayor prevalencia en estados como Florida y Maine se explica sobre todo por la edad de sus habitantes, al contar con un mayor porcentaje de personas mayores por el retiro de jubilados y el envejecimiento general de la población. En cambio, las cifras más bajas (entre el 5% y el 6%) se registran en estados del oeste como Utah y Colorado, donde la población es más joven y practica más actividad física.

3.4. Discusión y Conclusiones

Para responder a la pregunta de investigación planteada, el análisis confirma que existe una relación directa entre las características sociodemográficas, los hábitos de vida y las patologías previas con el riesgo cardiovascular. El envejecimiento y la acumulación de problemas de salud se consolidan como los factores más asociados. En cambio, las horas de sueño, la salud mental y el cigarrillo electrónico muestran un impacto directo bajo, mientras que el IMC actúa principalmente como un mediador indirecto. A nivel complementario, la representación en el mapa aporta un matiz visual exploratorio que permite observar una mayor concentración de casos en los estados del sureste de EE. UU.

3.4.1. Perfil de Vulnerabilidad del Paciente

El arquetipo de mayor riesgo corresponde a un varón de 65 o más años. Clínicamente, se caracteriza por una percepción de salud de regular a mala, antecedentes de patologías previas (diabetes, EPOC, ictus o artritis), historial de tabaquismo y el haber acudido habitualmente a chequeos médicos o pruebas de seguimiento en el tórax tras haber experimentado molestias o problemas de salud.

3.4.2. Líneas de Investigación Futura

Con el conjunto de datos acondicionado, se podría plantear en un futuro una fase de modelización predictiva mediante algoritmos supervisados como Random Forest. Esta hipotética extensión del trabajo se centraría en aplicar técnicas de rebalanceo para abordar el 9% de casos positivos, buscando maximizar la sensibilidad diagnóstica en la detección precoz de cardiopatías.

Funding: Este trabajo no ha recibido financiación externa.

Institutional Review Board Statement: Not applicable

Informed Consent Statement: Not applicable

Data Availability Statement: Los datos utilizados están disponibles en el repositorio de GitHub del proyecto.

Conflicts of Interest: Los autores declaran no tener conflicto de intereses.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.