MDPI

Article

Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares

Yeray Antón Juárez[1], Carlos Foó Sidro[1], Àngel Queral Castell[1]

[1] Máster en Ciencia de Datos Universitat de València; yeanjua@alumni.uv.es
* Correspondence: yeanjua@alumni.uv.es

Abstract: El proyecto trata de un análisis exploratorio de datos médicos con el objetivo de encontrar patrones entre datos del historial de un paciente y la aparición de enfermedades cardiovasculares, con el objetivo de poder llegar a predecir en un futuro si otros pacientes son susceptibles a desarrollar cardiopatías.

Keywords: Análisis Exploratorio de Datos; RMarkdown; Tidyverse; Enfermedades Cardiovasculares; Medicina.

1. Introducción

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel global. Según la Organización Mundial de la Salud (OMS), estas patologías son responsables de aproximadamente un 32% de todas las muertes en el mundo. Por tanto, lograr identificar de forma precoz a los pacientes susceptibles de padecerlas puede salvar multitud de vidas, especialmente considerando que el diagnóstico de estas enfermedades suele producirse en fases avanzadas.

El objetivo principal de este estudio es analizar los datos procedentes de la encuesta epidemiológica anual del *Centers for Disease Control and Prevention* (CDC), procesados y disponibles en Kaggle, para establecer relaciones entre diversas variables explicativas y la aparición de cardiopatías. El conjunto de datos está compuesto por 40 variables, incluyendo datos demográficos, hábitos de vida y la presencia de otras patologías secundarias, junto con una variable objetivo binaria que indica la presencia de enfermedad cardíaca.

El presente análisis se articula en torno a la pregunta de si existe una relación directa entre los hábitos de vida, las características sociodemográficas y la presencia de patologías previas u otras variables con el riesgo de padecer enfermedades cardiovasculares.

El análisis exploratorio de datos (EDA) consistirá en un primer preprocesamiento y limpieza de los datos, seguido de un análisis mediante la visualización de relaciones entre variables con gráficos estadísticos. Además, buscará identificar cuáles de estas variables muestran una mayor asociación con las cardiopatías, cómo interactúan entre sí y qué patrones o perfiles de pacientes presentan una mayor vulnerabilidad.

2. Métodos y Materiales

2.1. Descripción del Conjunto de Datos y Procedencia

El conjunto de datos analizado procede del Behavioral Risk Factor Surveillance System (BRFSS) correspondiente al año 2022, un sistema de encuestas telefónicas coordinado por los Centros para el Control y la Prevención de Enfermedades de los Estados Unidos. Esta base de datos recopila información anual de ciudadanos adultos no institucionalizados sobre hábitos de riesgo para la salud, condiciones médicas crónicas y uso de servicios preventivos.

El conjunto cuenta inicialmente con 445.132 observaciones y 40 variables que recogen mediciones biométricas, variables sociodemográficas y antecedentes clínicos.

Citation: Antón, Y.; Foó, C.; Queral, A. Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

2.2. Diccionario de Variables

Para estructurar el análisis, las 40 variables del estudio se clasifican en seis dominios clínicos fundamentales: - **Factores Sociodemográficos:** Estado de residencia (`Estado`), sexo biológico (`Sexo`), intervalo de edad en 13 tramos quinquenales (`GrupoEdad`) e identificación étnica (`RazaEtnia`). - **Antropometría y Salud Percibida:** Mediciones biométricas continuas (`AlturaMetros`, `PesoKilogramos`, `IMC`) y percepción subjetiva de salud (`SaludGeneral`, `DiasMalaSaludFisica`, `DiasMalaSaludMental`). - **Hábitos de Vida:** Horas de descanso (`HorasSueno`), práctica de ejercicio (`ActividadFisica`), `ConsumidorAlcohol`, `EstadoFumador` y `UsoCigarrilloElectronico`. - **Patologías y Comorbilidades:** Diagnósticos médicos de afección vascular y crónica (`InfartoMiocardio`, `AnginaPecho`, `Ictus`, `Diabetes`, `EPOC`, `Asma`, `EnfermedadRenal`, `Artritis`, `CancerPiel`, `TrastornoDepresivo`). - **Limitaciones Funcionales:** Piezas dentales extraídas (`DientesExtraidos`) y limitaciones en la vida diaria (`DificultadAuditiva`, `Visual`, `Concentracion`, `Caminar`, `VestirseBanarse`, `TareasDiarias`). - **Atención Preventiva:** `UltimoChequeoMedico`, pruebas diagnósticas (`TomografiaTorax`, `PruebaVIH`), antecedentes de `CovidPositivo` e inmunizaciones (`VacunaGripeUltimoAno`, `VacunaNeumococo`, `VacunaTetanos10Anos`). A partir de estos registros se formula la variable objetivo principal `EnfermedadCardiaca`, definida como respuesta afirmativa ante infarto de miocardio o angina de pecho.

2.3. Ingesta y Tipado de Variables

La importación se realiza de forma reproducible a partir del archivo comprimido mediante la librería readr. Posteriormente, se convierten las variables cualitativas a factores nominales y ordinales, y se define la variable objetivo EnfermedadCardiaca (definida como presencia de infarto de miocardio HadHeartAttack o angina de pecho HadAngina).

```r
# Carga reproducible
heart_raw <- read_csv("data/heart_2022_with_nans.csv.gz")

# Renombrado de variables a español ocupando el ancho completo de columna
heart_data <- heart_raw %>%
  rename(
    Estado = State, Sexo = Sex, SaludGeneral = GeneralHealth, DiasMalaSaludFisica = PhysicalHealthDays,
    DiasMalaSaludMental = MentalHealthDays, UltimoChequeoMedico = LastCheckupTime,
    ActividadFisica = PhysicalActivities, HorasSueno = SleepHours, DientesExtraidos = RemovedTeeth,
    InfartoMiocardio = HadHeartAttack, AnginaPecho = HadAngina, Ictus = HadStroke, Asma = HadAsthma,
    CancerPiel = HadSkinCancer, EPOC = HadCOPD, TrastornoDepresivo = HadDepressiveDisorder,
    EnfermedadRenal = HadKidneyDisease, Artritis = HadArthritis, Diabetes = HadDiabetes,
    DificultadAuditiva = DeafOrHardOfHearing, DificultadVisual = BlindOrVisionDifficulty,
    DificultadConcentracion = DifficultyConcentrating, DificultadCaminar = DifficultyWalking,
    DificultadVestirseBanarse = DifficultyDressingBathing, DificultadTareasDiarias = DifficultyErrands,
    EstadoFumador = SmokerStatus, UsoCigarrilloElectronico = ECigaretteUsage,
    TomografiaTorax = ChestScan, RazaEtnia = RaceEthnicityCategory, GrupoEdad = AgeCategory,
    AlturaMetros = HeightInMeters, PesoKilogramos = WeightInKilograms, IMC = BMI,
    ConsumidorAlcohol = AlcoholDrinkers, PruebaVIH = HIVTesting, VacunaGripeUltimoAno = FluVaxLast12,
    VacunaNeumococo = PneumoVaxEver, VacunaTetanos10Anos = TetanusLast10Tdap,
    ConductaAltoRiesgo = HighRiskLastYear, CovidPositivo = CovidPos
  )

# Tipado de variables y creación de HeartDisease
heart_data <- heart_data %>%
  mutate(
    EnfermedadCardiaca = factor(if_else(InfartoMiocardio == "Yes" | AnginaPecho == "Yes", "Yes", "No"),
                                levels = c("No", "Yes")),
    Diabetes = factor(case_when(
      Diabetes %in% c("Yes", "No, pre-diabetes or borderline diabetes") ~ "Yes",
      Diabetes %in% c("No", "Yes, but only during pregnancy (female)") ~ "No",
      TRUE ~ NA_character_
    ), levels = c("No", "Yes")),
    SaludGeneral = factor(SaludGeneral, ordered = TRUE,
      levels = c("Poor", "Fair", "Good", "Very good", "Excellent")),
    GrupoEdad = factor(GrupoEdad, ordered = TRUE, levels = c(
      "Age 18 to 24", "Age 25 to 29", "Age 30 to 34", "Age 35 to 39", "Age 40 to 44", "Age 45 to 49",
      "Age 50 to 54", "Age 55 to 59", "Age 60 to 64", "Age 65 to 69", "Age 70 to 74", "Age 75 to 79",
      "Age 80 or older"
    )),
    DientesExtraidos = factor(DientesExtraidos, ordered = TRUE,
      levels = c("None of them", "1 to 5", "6 or more, but not all", "All")),
    EstadoFumador = factor(EstadoFumador, ordered = TRUE, levels = c(
      "Never smoked", "Former smoker", "Current smoker - now smokes some days",
```

```
      "Current smoker - now smokes every day"
    )),
    UsoCigarrilloElectronico = factor(UsoCigarrilloElectronico, ordered = TRUE, levels = c(
      "Never used e-cigarettes in my entire life", "Not at all (right now)",
      "Use them some days", "Use them every day"
    )),
    UltimoChequeoMedico = factor(UltimoChequeoMedico, ordered = TRUE, levels = c(
      "Within past year (anytime less than 12 months ago)",
      "Within past 2 years (1 year but less than 2 years ago)",
      "Within past 5 years (2 years but less than 5 years ago)", "5 or more years ago"
    )),
    CovidPositivo = factor(case_when(
      CovidPositivo == "No" ~ "No", str_detect(CovidPositivo, "positive|Yes") ~ "Yes",
      TRUE ~ NA_character_
    ), levels = c("No", "Yes")),
    VacunaTetanos10Anos = factor(case_when(
      str_detect(VacunaTetanos10Anos, "^No") ~ "No", str_detect(VacunaTetanos10Anos, "^Yes") ~ "Yes",
      TRUE ~ NA_character_
    ), levels = c("No", "Yes")),
    TotalEnfermedades = rowSums(across(c(
      Ictus, Diabetes, Asma, EPOC, EnfermedadRenal, Artritis, CancerPiel, TrastornoDepresivo
    ), ~ .x == "Yes"), na.rm = TRUE),
    across(where(is.character), as.factor)
  )
```

El conjunto de datos cuenta inicialmente con 445.132 observaciones y 40 variables, identificándose 40.589 casos de cardiopatía (9.12%).

2.4. Detección y Corrección de Inconsistencias

Siguiendo con el análisis exploratorio se analiza la presencia de valores especiales, valores numéricos imposibles para las variables y la consistencia entre el índice de masa corporal, el peso y la altura.

```
# Comprobación de especiales, valores no positivos y consistencia de IMC
infinitos <- sapply(heart_data %>% select(where(is.numeric)), function(x) sum(is.infinite(x)))
menores_cero <- sapply(heart_data %>% select(where(is.numeric)), function(x) sum(x < 0, na.rm = TRUE))
bmi_teorico <- heart_data$PesoKilogramos / (heart_data$AlturaMetros^2)
inconsistencias_bmi <- sum(abs(heart_data$IMC - bmi_teorico) > 1.5, na.rm = TRUE)

# Corrección de inconsistencias biológicas imposibles a NA
heart_data <- heart_data %>%
  mutate(
    HorasSueno = if_else(HorasSueno <= 2 | HorasSueno >= 20, NA_real_, HorasSueno),
    AlturaMetros = if_else(AlturaMetros < 1.0, NA_real_, AlturaMetros)
  )
```

Tras la verificación, se ha comprobado la ausencia de valores infinitos y de valores negativos imposibles en las variables numéricas (constatando que únicamente DiasMalaSaludFisica y DiasMalaSaludMental presentan valores 0 válidos). Asimismo, no se detectaron discrepancias entre el IMC y el cociente peso/altura fuera del margen de tolerancia de 1.5 kg/m^2 atribuible al redondeo de unidades imperiales. Se sustituyeron por `NA` los valores biológicamente anómalos: horas de sueño ≤ 2 o ≥ 20 y estaturas de adultos inferiores a 1 metro.

2.5. Valores Perdidos y Observaciones Completas

A continuación se cuantifica el volumen de valores perdidos presentes en las variables y se evalúa la proporción de casos completos.

```
# Cálculo de NAs por columna y completitud global
nas_columna <- colSums(is.na(heart_data))
pct_nas <- round((nas_columna / nrow(heart_data)) * 100, 2)
num_completas <- sum(complete.cases(heart_data))
```

El análisis de valores perdidos indica que las mayores ausencias se concentran en ítems clínicos preventivos optativos: vacuna del tétanos (18.54%), vacuna antineumocócica (17.31%), prueba de VIH (14.86%), tomografía de tórax (12.59%) y diagnóstico de COVID-19 (11.40%). Un total de 277.447 observaciones (el 62.33%) cuentan con registros completos. Descartar filas incompletas en esta fase supondría perder casi un 38% de la muestra, por lo que se conservan y se imputarán los atributos importantes.

2.6. Detección de Outliers y Comparativa de Métodos

A continuación se aplican y comparan cuatro métodos de detección de outliers sobre el IMC (Índice de Masa Corporal): regla 3 sigma, identificador Hampel, regla del boxplot y percentiles (5% y 95%).

```
# Definición de reglas
reglasigma   <- function(x) abs(x - mean(x, na.rm = TRUE)) > 3 * sd(x, na.rm = TRUE)
reglahampel  <- function(x) {
  m <- median(x, na.rm = TRUE); abs(x - m) > 3 * (1.4826 * median(abs(x - m), na.rm = TRUE))
}
reglaboxplot <- function(x) {
  q <- quantile(x, c(0.25, 0.75), na.rm = TRUE); x < q[1] - 1.5 * diff(q) | x > q[2] + 1.5 * diff(q)
}
reglapercentil <- function(x) {
  p <- quantile(x, c(0.05, 0.95), na.rm = TRUE); x < p[1] | x > p[2]
}

# Clasificación de outliers sobre IMC
heart_outliers <- heart_data %>%
  mutate(
    IMC_Sigma = reglasigma(IMC), IMC_Hampel = reglahampel(IMC),
    IMC_Boxplot = reglaboxplot(IMC), IMC_Percentil = reglapercentil(IMC)
  )
```

La comparativa de métodos refleja la asimetría del IMC. La regla 3 Sigma resulta poco agresiva: sitúa el umbral superior en 48.19 y detecta solo un 1.28% de anomalías (5.071 casos), al verse inflada la desviación típica por valores extremos. El identificador Hampel fija el corte en 44.03 (2.69% de outliers, 10.657 casos), mientras que la regla del Boxplot lo sitúa en 43.18 (3.11% de anomalías, 12.339 casos). El método de percentiles (5%–95%) acota el rango entre 20.12 y 40.69 (38.840 casos, 9.80%). Estos registros extremos representan individuos con obesidad mórbida real (grado III) y no errores de encuesta, por lo que los outliers se conservan en la muestra para no perder información útil.

2.7. Imputación de Variables Numéricas

Para garantizar la integridad de los análisis cuantitativos posteriores sin introducir sesgos artificiales, se aplica una imputación según la naturaleza de cada variable:

Variables AlturaMetros, PesoKilogramos, IMC: Hombres y mujeres siguen distribuciones distintas. Imputamos los valores perdidos directamente por la media según el Sexo del paciente.

Variables `HorasSueno`,`DiasMalaSaludFisica`, `DiasMalaSaludMental`**):** Al concentrarse en valores típicos (7 horas de sueño y 0 días de enfermedad), se imputan mediante su mediana.

```
# Imputación por Sexo (antropometría) y por Mediana (descanso y salud percibida)
heart_data <- heart_data %>%
  group_by(Sexo) %>%
  mutate(
    AlturaMetros = coalesce(AlturaMetros, mean(AlturaMetros, na.rm = TRUE)),
    PesoKilogramos = coalesce(PesoKilogramos, mean(PesoKilogramos, na.rm = TRUE)),
    IMC = coalesce(IMC, mean(IMC, na.rm = TRUE))
  ) %>%
  ungroup() %>%
  mutate(across(c(HorasSueno, DiasMalaSaludFisica, DiasMalaSaludMental),
                ~ coalesce(.x, median(.x, na.rm = TRUE)))) %>%
  drop_na()
```

Tras el proceso de imputación de las variables cuantitativas y el filtrado de observaciones completas en los registros categóricos restantes, el conjunto de datos final cuenta con 267.281 observaciones y cero valores perdidos en la totalidad de sus 40 variables para los análisis univariante, bivariante y multivariante posteriores.

3. Resultados

En este apartado vamos a estudiar los datos que hemos mencionado en la sección anterior, dividiéndolo en dos subsecciones dependiendo de la naturaleza del análisis.

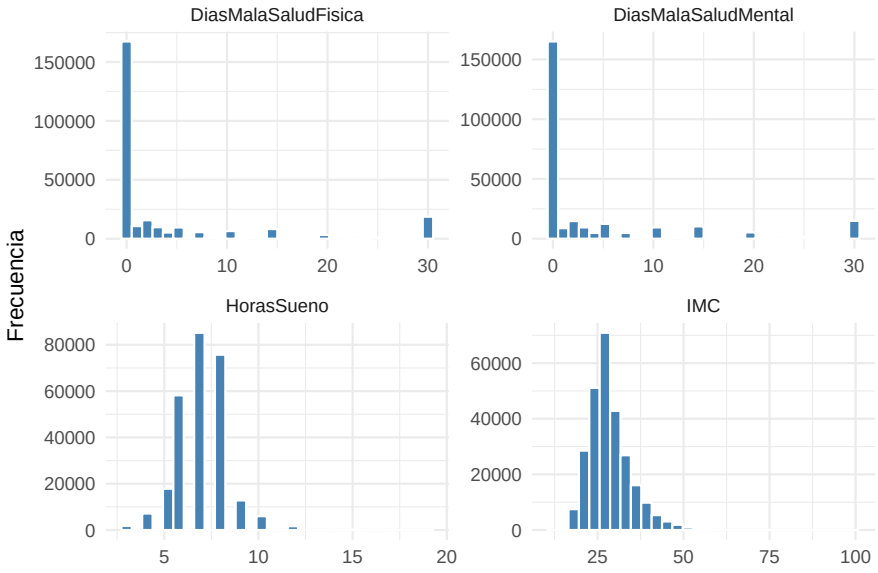


Figure 1. Distribución de las variables cuantitativas principales.

3.1. Análisis Univariante

A su vez, el análisis univariante lo vamos a estructurar dependiendo del tipo de dato de cada columna.

3.1.1. Variables Cuantitativas

El análisis univariante de las variables cuantitativas (`AlturaMetros`, `PesoKilogramos`, `IMC`, `HorasSueno`, `TotalEnfermedades`, `DiasMalaSaludFisica` y `DiasMalaSaludMental`) permite evaluar sus propiedades distribucionales, contrastando los estadísticos clásicos con estimadores robustos para mitigar el efecto de la asimetría y la presencia de colas pesadas.

Primero vamos a comenzar con unos plots de las distribuciones de cada variable, obviando `AlturaMetros` y `PesoKilogramos` porque son algo redundantes con `IMC`.

```
heart_data %>%
  select(IMC, HorasSueno, DiasMalaSaludFisica, DiasMalaSaludMental) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>%ggplot(aes(x = Valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  facet_wrap(~ Variable, scales = "free") +theme_minimal() +
  labs(x = NULL, y = "Frecuencia")
```

Con estos histogramas podemos sacar varias conclusiones. De las dos primeras gráficas es resaltable la tendencia a valores pequeños de ambas variables, pero también el sesgo presente hacia los valores extremos 30 y 0 por la naturaleza de las variables (al ser una respuesta subjetiva en una encuesta). Por otra parte, el histograma de horas de sueño también es peculiar en su medida, ya que se nota un cierto sesgo en ciertos números, pero la distribución es mucho más parecida a una normal. Por último, con el BMI pasa algo similar a esto último, ya que la distribución es bastante centrada.

Todo esto podemos verlo de mejor manera en la tabla `estadisticos_num` hecha previamente. Sin embargo, antes de comentar lo que vemos en esta tabla podemos ampliarla con algunos estadísticos que habíamos obviado previamente.

```
skewness <- function(x) {
  x <- x[!is.na(x)]
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^3 / s^3) / n}
kurtosis <- function(x) {
  x <- x[!is.na(x)]
  n <- length(x)
```

```
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^4 / s^4) / n - 3}
madm <- function(x) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)}
# Hago de nuevo la tabla por todas las imputaciones hechas
estadisticos_num <- heart_data %>%select(where(is.numeric)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>%
  group_by(Variable) %>%summarise(
    Media = round(mean(Valor, na.rm = TRUE), 2),SD  = round(sd(Valor, na.rm = TRUE), 2),
    Mediana = round(median(Valor, na.rm = TRUE), 2),
    MADM = round(madm(Valor), 2),IQR = round(IQR(Valor, na.rm = TRUE), 2),
    Sesgo = round(skewness(Valor), 2),Curtosis = round(kurtosis(Valor), 2))
kable(estadisticos_num, caption = "Estadísticos para variables cuantitativas.", booktabs = TRUE) %>%
  kable_styling(font_size = 6, latex_options = "hold_position")
```

Table 1. Estadísticos para variables cuantitativas.

Variable	Media	SD	Mediana	MADM	IQR	Sesgo	Curtosis
AlturaMetros	1.70	0.11	1.70	0.12	0.15	0.07	-0.04
DiasMalaSaludFisica	4.09	8.41	0.00	0.00	3.00	2.29	4.00
DiasMalaSaludMental	4.13	8.10	0.00	0.00	4.00	2.23	3.92
HorasSueno	7.05	1.37	7.00	1.48	2.00	0.63	4.66
IMC	28.66	6.36	27.98	5.32	7.18	1.37	4.35
PesoKilogramos	83.26	20.99	79.83	17.48	26.31	1.08	2.69
TotalEnfermedades	1.11	1.19	1.00	1.48	2.00	1.17	1.30

Podemos extraer ciertas conclusiones a partir de aquí. En `DiasMalaSaludFisica` y `DiasMalaSaludMental`, la mediana y el MADM son 0 (la mayoría de los individuos dicen no tener días de enfermedad), mientras que la media se sitúa en torno a 4 días con una desviación típica de más de 8 días, claramente inflada por los individuos con patologías crónicas graves. En el `IMC` y el `PesoKilogramos`, la media es superior a la mediana debido a la presencia de casos con obesidad severa en la cola superior de la distribución. La variable `NumeroEnfermedades` es numérica pero es basicamente un factor, ya que hay poco rango de enfermedades que se pueden padecer. El valor medio y mediano ronda 1 enfermedad por persona pero su distribución no merece la pena representarse gráficamente por ahora. En cuanto al sesgo, como cabría esperar, las variables más asimétricas son las que más sesgo tienen. Además, vemos que `IMC` tiene un sesgo no despreciable, lo que sugiere que la distribución quizás no es normal. La curtosis nos revela también que las colas de `IMC` y de `HorasSueno` son demasiado anchas, así que probablemente no nos encontramos ante distribuciones normales. `AlturaMetros` sí parece seguir algo parecido a una normal debido a su curtosis y sesgo.

Como último paso para este tipo de variables vamos a comprobar la normalidad con Q-Q plots, ya que los test de normalidad se ven muy penalizados por la cantidad tan grande de instancias que tenemos.

```
par(mfrow = c(1, 3))
qqPlot(heart_data$AlturaMetros, main = "A) Altura (Metros)",
       xlab = "Cuantiles teóricos", ylab = "Cuantiles muestrales",id = FALSE)
qqPlot(heart_data$IMC, main = "B) Índice de Masa Corporal",
       xlab = "Cuantiles teóricos", ylab = "Cuantiles muestrales",id = FALSE)
qqPlot(heart_data$HorasSueno, main = "C) Horas de Sueño",
       xlab = "Cuantiles teóricos", ylab = "Cuantiles muestrales",id = FALSE)
```

```
par(mfrow = c(1, 1))
```

Comparando los cuantiles de nuestra distribución con los de una gaussiana teórica vemos como el desplazamiento de las distribuciones de `IMC` y `HorasSueno` son lo suficientemente importantes como para descartar su normalidad, pero con altura vemos como su comportamiento puede ser lo suficientemente parecido como para asumir que sigue una distribución gaussiana.

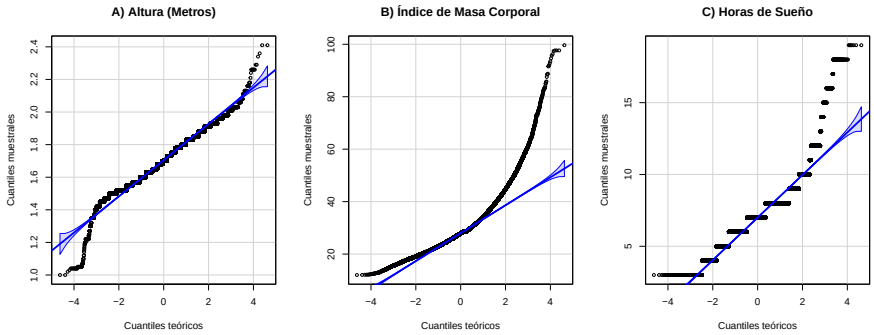


Figure 2. Comparativa de gráficos QQ de normalidad para Altura, IMC y Horas de Sueño.

3.1.2. Variables Binarias

Comenzando el análisis de las variables binarias, lo primero que vamos a hacer es el cálculo de la proporción de 'Sí' en cada una de las variables.

```
variables_binarias <- heart_data %>%
  select(where(~ is.factor(.x) && nlevels(.x) == 2)) %>%names()
tabla_binarias <- heart_data %>%select(any_of(variables_binarias)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Respuesta") %>%filter(!is.na(Respuesta)) %>%
  mutate(Porcentaje = round((Conteo / sum(Conteo)) * 100, 2)) %>%
  ungroup() %>%filter(Respuesta == "Yes") %>%arrange(desc(Porcentaje)) %>%
  select(Variable, N = Conteo, Porcentaje = Porcentaje)
filas_a_mostrar <- unique(c(1,3,9,11,15,26))
tabla_binarias_reducida <- tabla_binarias %>% slice(filas_a_mostrar)
kable(tabla_binarias_reducida, caption = "Frecuencia de factores de riesgo yde algunas binarias.", booktabs = TRUE)
  kable_styling(font_size = 6, latex_options = "hold_position")
```

Table 2. Frecuencia de factores de riesgo yde algunas binarias.

Variable	N	Porcentaje
ActividadFisica	205982	77.07
ConsumidorAlcohol	143851	53.82
CovidPositivo	85067	31.83
Diabetes	43100	16.13
EnfermedadCardiaca	23497	8.79
DificultadVestirseBanarse	9379	3.51

Viendo esta tabla podemos destacar la presencia de distintos tipos de variables, con frecuencias más o menos grandes. Destaca el desbalance de nuestra variable objetivo, con un 9% de casos positivos, lo cual puede ser importante en un futuro al trabajar con modelos predictivos. Para tener una mejor idea de lo que estamos viendo en el resto de variables podemos fragmentar las variables en distintos grupos, siendo estos grupos hábitos, otras patologías y distintas medidas de prevención.

```
habitos_binarios <- c("ActividadFisica", "ConsumidorAlcohol")
patologias_binarias <- c("Ictus", "Diabetes", "Asma", "EPOC", "EnfermedadRenal", "Artritis", "CancerPiel", "Trastorn
prevencion_binarias <- c("TomografiaTorax", "PruebaVIH", "VacunaGripeUltimoAno", "VacunaNeumococo", "VacunaTetanos10
limitaciones_binarias <- c("DificultadAuditiva", "DificultadVisual", "DificultadConcentracion", "DificultadCaminar",
todas_binarias <- c(habitos_binarios, patologias_binarias, prevencion_binarias,limitaciones_binarias)
tabla_binarias_tematica <- heart_data %>%select(any_of(todas_binarias)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Respuesta") %>%filter(!is.na(Respuesta)) %>%
  mutate(Porcentaje = round((Conteo / sum(Conteo)) * 100, 2)) %>%
  ungroup() %>%filter(Respuesta == "Yes") %>%mutate(
    BloqueTematico = case_when(
      Variable %in% habitos_binarios     ~ "1. Hábitos de Vida",
      Variable %in% patologias_binarias  ~ "2. Patologías y Antecedentes",
      Variable %in% prevencion_binarias  ~ "3. Prevención y Atención Médica",
      Variable %in% limitaciones_binarias  ~ "4. Limitaciones",
      TRUE                               ~ "Otros")) %>%
  select(BloqueTematico, Variable, Casos_Yes = Conteo, Prevalencia_Pct = Porcentaje) %>%arrange(BloqueTematico, desc
heart_data %>%select(any_of(todas_binarias)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Respuesta") %>%filter(!is.na(Respuesta)) %>%
  group_by(Variable) %>%mutate(Proporcion = n / sum(n)) %>%
```



Figure 3. Distribución de variables binarios

```
  ungroup() %>%filter(Respuesta == "Yes") %>%mutate(
    BloqueTematico = case_when(
      Variable %in% habitos_binarios     ~ "1. Hábitos de Vida",
      Variable %in% patologias_binarias  ~ "2. Patologías y Antecedentes",
      Variable %in% prevencion_binarias  ~ "3. Prevención y Atención Médica",
      Variable %in% limitaciones_binarias  ~ "4. Limitaciones",
      TRUE                               ~ "Otros")) %>%
  ggplot(aes(x = reorder(Variable, Proporcion), y = Proporcion * 100, fill = BloqueTematico)) +geom_col(width = 0.7,
  coord_flip() +facet_wrap(~ BloqueTematico, scales = "free", ncol = 1) +
  theme_minimal() +labs(title = "Distribución de variables binarios",x = NULL, y = "Respuestas positivas (%)")
```

De esta manera, el análisis de cada grupo se vuelve más fácil.

Los hábitos de vida son solo 2, así que solo podemos comentar que son variables muy balanceadas. Las patologías tienden a ser más raras y por tanto conviene llevar cuidado con el desbalanceo de clases. El tercer gráfico correspondiente a la atención médica y prevenciones detaca que volvemos a tener variables más o menos balanceadas exceptuando `ConductaAltoRiesgo`. Por último exploramos las variables que expresan las dificultades en distintos ámbitos de la vida, que por supuesto son variables bastante desbalanceadas a favor del no.

Por último, conviene destacar que al igual que con diabetes alguna variable podría perder algo de información para volverse binaria y analizarla aquí pero a priori no parece que merezca la pena. Otra variable que puede ser interpretada como binaria es la de `Sexo` , pero su balance hace que no aporte nada analizarla aquí.

```
heart_data %>% count(Sexo) %>%
  mutate(Porcentaje = round((n / sum(n)) * 100, 1)) %>%
  kable(col.names = c("Sexo", "Conteo", "Porcentaje (%)"),
        caption = "Distribución de la muestra por sexo.", booktabs = TRUE)
```

Table 3. Distribución de la muestra por sexo.

Sexo	Conteo	Porcentaje (%)
Female	143339	53.6
Male	123942	46.4

3.1.3. Variables Categóricas

Por último, estudiaremos las variables categóricas. Estas variables son mucho más difíciles de interpretar de manera univariante ya que no podemos calcular medias ni otros

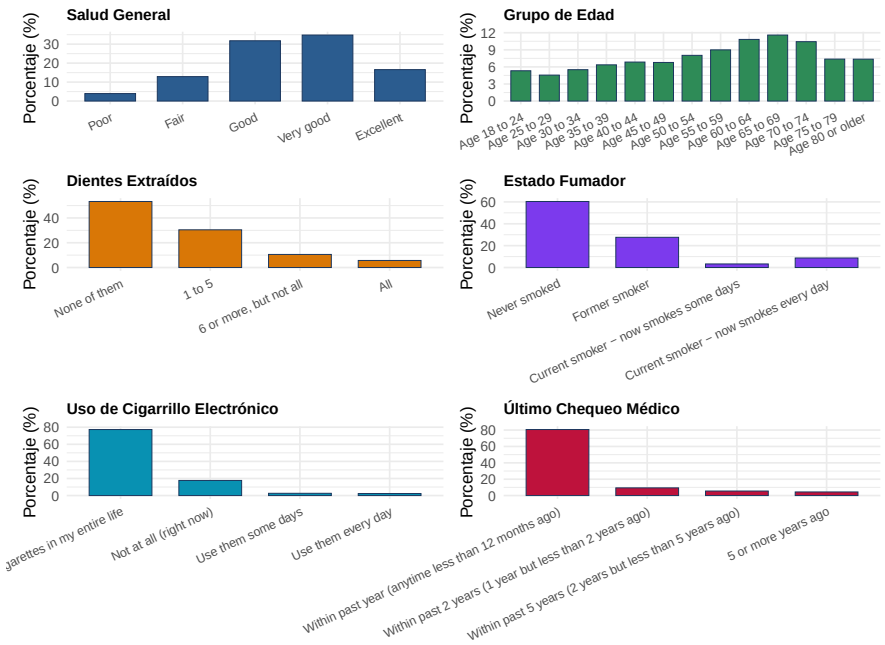


Figure 4. Distribución porcentual de los factores ordinales.

estadísticos,y como mucho podemos aprovechar que estas categorías estén algo ordenadas para extraer algo más de información.

Por tanto, vamos a comenzar graficando las variables que tienen cierto orden.

```
#por como funcionan los factores tenemos que usar patchwork para construir los subplots. Creamos una funcion para no
plot_ordinal <- function(var_name, title_text, bar_color = "#2b5c8f") {
  heart_data %>%filter(!is.na(.data[[var_name]])) %>%
    count(.data[[var_name]]) %>%mutate(Prop = (n / sum(n)) * 100) %>%
    ggplot(aes(x = .data[[var_name]], y = Prop)) +
    geom_col(fill = bar_color, width = 0.7, color = "#1a365d", linewidth = 0.2) +theme_minimal() +labs(title = title
      plot.title = element_text(size = 10, face = "bold"))}
g1 <- plot_ordinal("SaludGeneral", "Salud General", bar_color = "#2b5c8f")
g2 <- plot_ordinal("GrupoEdad", "Grupo de Edad", bar_color = "#2e8b57")
g3 <- plot_ordinal("DientesExtraidos", "Dientes Extraídos", bar_color = "#d97706")
g4 <- plot_ordinal("EstadoFumador", "Estado Fumador", bar_color = "#7c3aed")
g5 <- plot_ordinal("UsoCigarrilloElectronico", "Uso de Cigarrillo Electrónico", bar_color = "#0891b2")
g6 <- plot_ordinal("UltimoChequeoMedico", "Último Chequeo Médico", bar_color = "#be123c")
(g1 + g2) / (g3 + g4) / (g5 + g6)
```

En estos gráficos de barras podemos ver claramente la moda y la distribución general de la variables, pudiendo detectar sesgos. En estos casos hay variables claramente sesgadas (por ejemplo es muy claro que lo más común es que no hayan dientes extraidos) pero nada que resulte raro.

Por último vamos a graficar las dos últimas variables que no hemos tratado, aunque es más bien para tener una idea de qué son ya que además de ser dos variables que a priori no parecen muy importantes para la pregunta que queremos responder, son muy difíciles de interpretar.

```
#misma estructura que antes pero ahora ordenado de mayor a menor frecuencia. en el caso de estados seleccionamos sol
plot_nominal <- function(var_name, title_text, bar_color) {
  heart_data %>%filter(!is.na(.data[[var_name]])) %>%count(.data[[var_name]]) %>%mutate(Prop = (n / sum(n)) * 100,Ca
    ggplot(aes(x = Categoria, y = Prop)) +geom_col(fill = bar_color, width = 0.7, color = "#1a365d", linewidth = 0.2
    labs(title = title_text, x = NULL, y = "Porcentaje (%)") +
    theme(axis.text.x = element_text(angle = 25, hjust = 1, size = 8),
      plot.title = element_text(size = 10, face = "bold"))}
g_raza <- plot_nominal("RazaEtnia", "Distribución por Raza / Etnia", bar_color = "#3b82f6")
g_region <- heart_data %>%filter(!is.na(Estado)) %>%
  mutate(Estado = fct_lump_n(Estado, n = 15, other_level = "Otros")) %>%
  count(Estado) %>%mutate(Prop = (n / sum(n)) * 100,Estado = fct_reorder(Estado, Prop, .desc = TRUE)) %>%ggplot(aes(
    axis.text.x = element_text(angle = 25, hjust = 1, size = 9),
    plot.title = element_text(size = 11, face = "bold"))
g_raza + g_region
```

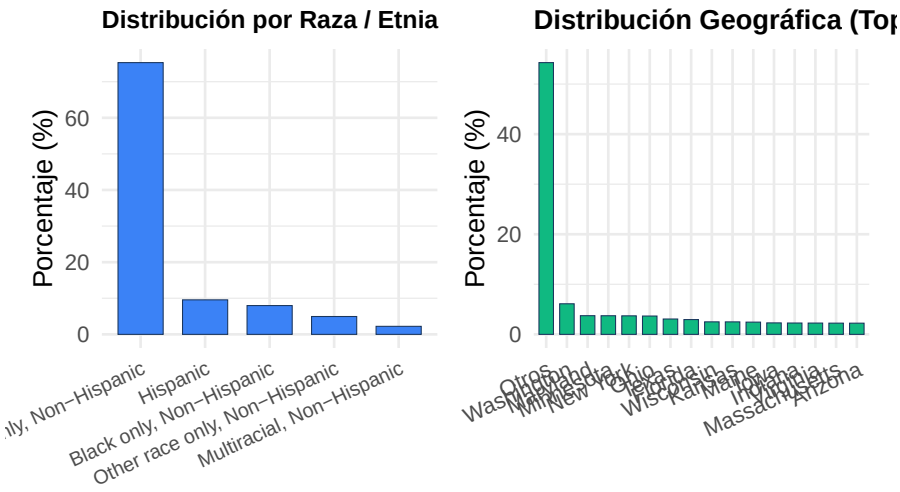


Figure 5. Distribución porcentual de las variables nominales.

Para que el gráfico sea legible se ha tenido que optar por visualizar solo los 15 estados más representados, pero se entiende que no hay mucha variabilidad entre estados.

3.2. Análisis Bivariante

Tras ver una a una las variables y sus distribuciones, ahora podemos comenzar a ver las relaciones dos a dos entre variables para poder establecer conexiones. Dividiremos este apartado en dos, el primero intentando ver las relaciones que hay entre nuestras variables explicativas, para poder encontrar variables redundantes susceptibles a eliminación para futuros modelos, y el segundo, estableciendo relaciones entre la variable objetivo y las demás variables para poder ver que variables afectan más a la aparición de enfermedades cardiovasculares.

3.2.1. Redundancia y Multicolinealidad entre Variables Explicativas

La cantidaad de pares entre las variables explicativas es muy grande, así que vamos a hacer selecciones lógicas de variables que a priori son susceptibles a estar correlacionadas y comprobarlo con las herramientas estadísticas adecuadas.

El primer grupo de variables que vamos a estudiar es del subgrupo de variables que representan dificultades, podemos pensar que las mismas dificultades motoras pueden llegar a traducirse a dificultad al andar, a vestirse o bañarse, y a hacer tareas en general. Por tanto, vamos a calcular el coeficiente V de Cramer para tener una medida de que tan redundantes son las variables.

```
cat(sprintf("V de Cramér (Caminar vs. Vestirse/Bañarse): %.4f\n", assocstats(table(heart_data$DificultadCaminar, hea
```

```
## V de Cramér (Caminar vs. Vestirse/Bañarse): 0.3816
```

```
cat(sprintf("V de Cramér (Caminar vs. Tareas Diarias): %.4f\n", assocstats(table(heart_data$DificultadCaminar, heart
```

```
## V de Cramér (Caminar vs. Tareas Diarias): 0.3829
```

```
cat(sprintf("V de Cramér (Vestirse/Bañarse vs. Tareas Diarias): %.4f\n", assocstats(table(heart_data$DificultadVesti
```

```
## V de Cramér (Vestirse/Bañarse vs. Tareas Diarias): 0.4158
```

Los valores del estadístico no son despreciables, pero tampoco son altos, puesto que no superan siquiera el 0.5. Por tanto, dos a dos, podemos decir que las variables tengan una correlación suficiente como para eliminar alguna.

El siguiente grupo de variables a estudiar es uno formado por la salud general autopercibida y las variables de dias de malestar, tanto físico como mental. Para este caso, es más práctico aprovechar que el factor está ordenado y utilizar el test de Kruskal-Wallis. Para complementar esta información también utilizaremos el test de Spearman.

```
kw1 <- kruskal.test(DiasMalaSaludFisica ~ SaludGeneral, data = heart_data)
cat(sprintf("Kruskal (Salud Física ~ Salud General):, p-valor %s\n", format.pval(kw1$p.value, eps = 1e-16)))
```

```
## Kruskal (Salud Física ~ Salud General):, p-valor < 1e-16
```

```
sp1 <- cor.test(as.numeric(heart_data$SaludGeneral), heart_data$DiasMalaSaludFisica, method = "spearman", exact = FA
cat(sprintf("Spearman (Salud General vs. Salud Física): $\\rho$ = %.4f \n",
sp1$estimate))
```

```
## Spearman (Salud General vs. Salud Física): $\rho$ = -0.4048
```

```
kw2 <- kruskal.test(DiasMalaSaludMental ~ SaludGeneral, data = heart_data)
cat(sprintf("Kruskal (Salud Mental ~ Salud General): p-valor %s\n", format.pval(kw2$p.value, eps = 1e-16)))
```

```
## Kruskal (Salud Mental ~ Salud General): p-valor < 1e-16
```

```
sp2 <- cor.test(as.numeric(heart_data$SaludGeneral), heart_data$DiasMalaSaludMental, method = "spearman", exact = FA
cat(sprintf("Spearman (Salud General vs. Salud Mental): $\\rho$ = %.4f \n",
sp2$estimate))
```

```
## Spearman (Salud General vs. Salud Mental): $\rho$ = -0.2095
```

El test de Kruskal con p valor bajo nos dice que hay cierta relación entre las variables, pero es Spearman el que cuantifica como de fuerte es esta relación. Valores negativos entre -0.2 y -0.5 nos permiten concluir que la relación es moderada, pero no hay redundancia, además de que la relación de estas variables es inversa (mayor salud general se traduce en menos dias malos). Además, podemos concluir que la salud física es más influyente en la percepción de la salud general.

Relacionado con esto tambien podemos comparar las variables `DiasMalaSaludMental` con `TrastornoDepresivo`. Esto lo haremos de manera similar a la anterior, utilizando el test de Wilcoxon para comparar una variable numérica con una binaria, y apoyándonos en Spearman para identificar la intensidad de la relación.

```
wt <- wilcox.test(DiasMalaSaludMental ~ TrastornoDepresivo, data = heart_data)
cat(sprintf("Wilcoxon test (Salud Mental ~ Depresión):  p-valor %s\n", format.pval(wt$p.value, eps = 1e-16)))
```

```
## Wilcoxon test (Salud Mental ~ Depresión):  p-valor < 1e-16
```

```
sp <- cor.test(as.numeric(heart_data$TrastornoDepresivo), heart_data$DiasMalaSaludMental, method = "spearman", exact
cat(sprintf("Spearman (Depresión vs. Salud Mental): $\\rho$ = %.4f \n",
sp$estimate))
```

```
## Spearman (Depresión vs. Salud Mental): $\rho$ = 0.4301
```

De nuevo, la relación parece ser existente, pero Spearman nos dice que la magnitud no es lo suficientemente grande como para ser redundante. Destacar que como cabría esperar una relación directa entre las dos variables, en contraposición a la de salud general que era inversa.

El último bloque que vamos a tratar es el de fumadores y fumadores electrónicos o vaper. Claramente son variables que pueden estar muy relacionadas así que vamos a utilizar la V de Cramer para comparar ambas variables.

```
cat(sprintf("V de Cramér (Fumador vs. Cigarrillo Electrónico): %.4f\n", assocstats(table(heart_data$EstadoFumador, h
```

```
## V de Cramér (Fumador vs. Cigarrillo Electrónico): 0.1783
```

El valor del estadístico es bastante bajo, lo cual nos dice que a priori la relación entre estas dos variables no es nada importante.

Por último, destacar que otras variables que van a tener cierta correlación por construcción son las que literalmente hemos construido a partir de otras variables, como `IMC` o `TotalEnfermedades`. Estas variables no las hemos estudiado aquí porque su cometido es el contrario, intentar resumir el contenido de varias variables para enriquecer el dataset. Dependiendo del modelo con el que se quiera trabajar resulta más útil quitar variables redundantes o generar nuevas variables que pueden resumir mejor la información.

3.2.2. Relación con la variable objetivo

Ahora estudiaremos la relación de todas las variables con la variable objetivo. Para ello, nos serviremos de el valor que nos devuelve Spearman (en valor absoluto) y V de Cramer, que aunque no sea lo mismo, es comparable, ya que no podemos hacer el mismo test para distintos tipos de variables. Con esto, tendremos las distintas columnas ordenadas en cierta medida por orden de influencia en la target.

```
predictors <- names(heart_data)[-c(10,11,41)]
influencia <- c()
for (var in predictors) {
  x <- heart_data[[var]]
  y <- heart_data[['EnfermedadCardiaca']]
  if (is.numeric(x) || is.ordered(x)) {
    spearman_res <- suppressWarnings(cor.test(as.numeric(x), as.numeric(y), method = "spearman"))
    influencia[var] <- abs(spearman_res$estimate)}
  else {
    tabla <- table(x, y)
    cramer_res <- assocstats(tabla)$cramer
    influencia[var] <- cramer_res}}
influencia_ordenada <- sort(influencia, decreasing = TRUE)
df_influencia_ordenada <- data.frame(Variable = names(influencia_ordenada),
  Influencia = as.numeric(influencia_ordenada))
tabla_resumen <- bind_rows(head(df_influencia_ordenada, 5),
  data.frame(Variable = "...", Influencia = NA),tail(df_influencia_ordenada, 5))
kable(tabla_resumen, col.names = c("Predictor", "Influencia"), digits = 4,
      caption = "Mayores y menores influencias en la target.",
      booktabs = TRUE) %>%kable_styling(font_size = 6, latex_options = "hold_position")
```

Table 4. Mayores y menores influencias en la target.

Predictor	Influencia
GrupoEdad	0.2348
TotalEnfermedades	0.2260
TomografiaTorax	0.2148
SaludGeneral	0.2135
DificultadCaminar	0.1992
...	NA
AlturaMetros	0.0267
UsoCigarrilloElectronico	0.0214
VacunaTetanos10Anos	0.0082
HorasSueno	0.0073
DiasMalaSaludMental	0.0035

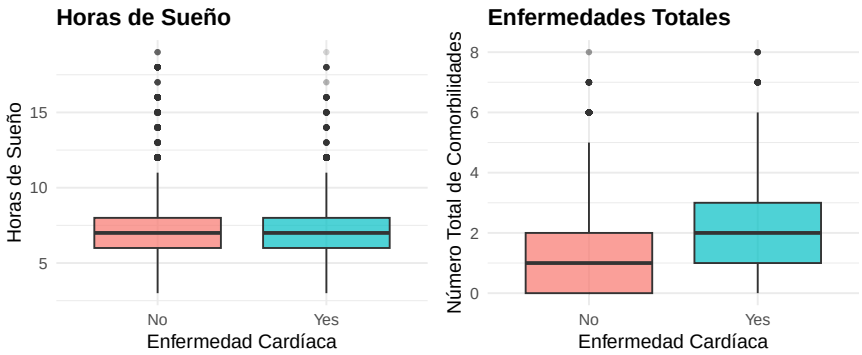
Vemos como variables como la edad o el número de enfermedades son las que más influyen, mientras que horas de sueño y los días de mala salud mental son las que menos influyen a priori.

Variables que sorprende encontrar con coeficientes altos son la tomografía, aunque es posible que tenga que ver con pruebas posteriores a la detección de la enfermedad, salud general porque es algo subjetivo, dientes extraidos porque parece no tener nada que ver, o incluso enfermedades particulares como diabetes que puede que alguno no se espere que sea tan influyente.

Respecto a las más bajas sorprende ver a las variables relacionadas con la salud mental tan bajas, a su vez que el vaper también está de las menos influyentes. Por último destacar también que el IMC se encuentra sorpresivamente bajo.

Dicho esto, vamos a hacer algunos boxplots, gráficos de barras y heat maps para representar algunas de estas variables, ya sean las más influyentes o las menos, para visualizar los datos.

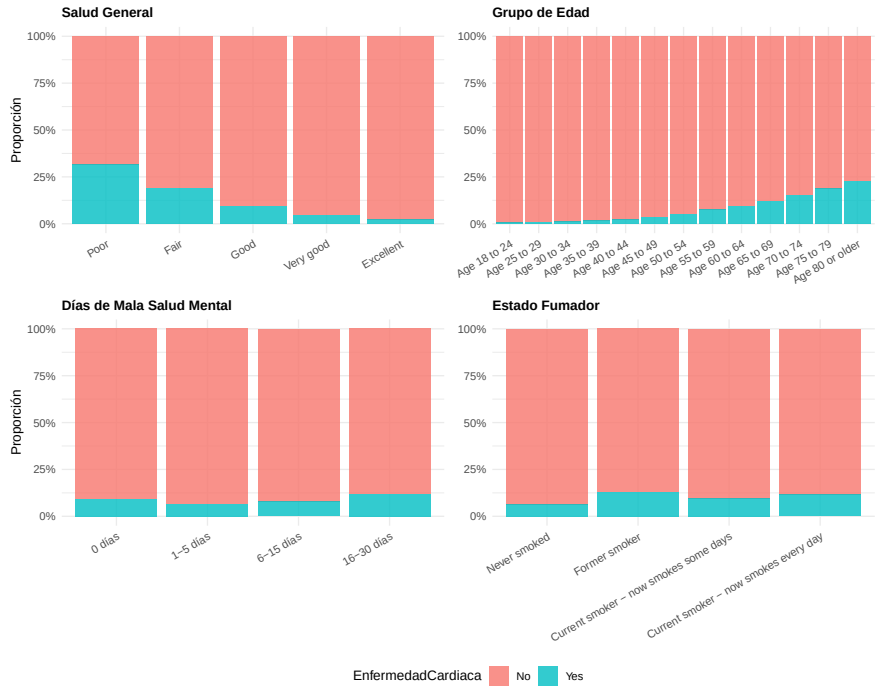
```
p1<-ggplot(heart_data, aes(x = EnfermedadCardiaca, y = HorasSueno, fill = EnfermedadCardiaca)) +
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.2, outlier.size = 1) +
  labs(title = "Horas de Sueño",
    x = "Enfermedad Cardíaca",y = "Horas de Sueño") +theme_minimal() +
  theme(legend.position = "none", plot.title = element_text(face = "bold"))
p2<-ggplot(heart_data, aes(x = EnfermedadCardiaca, y = TotalEnfermedades, fill = EnfermedadCardiaca)) +
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.2, outlier.size = 1) +
  labs(title = "Enfermedades Totales",x = "Enfermedad Cardíaca",
    y = "Número Total de Comorbilidades") +theme_minimal() +
  theme(legend.position = "none", plot.title = element_text(face = "bold"))
p1 + p2
```



En estos dos boxplots se ve claramente como el factor de tener o no enfermedad cardiaca condiciona (en el caso de las enfermedades) o no (en el caso del sueño) la media del subgrupo generado por la cardiopatía.

Ahora vamos con algunos gráficos de barras.

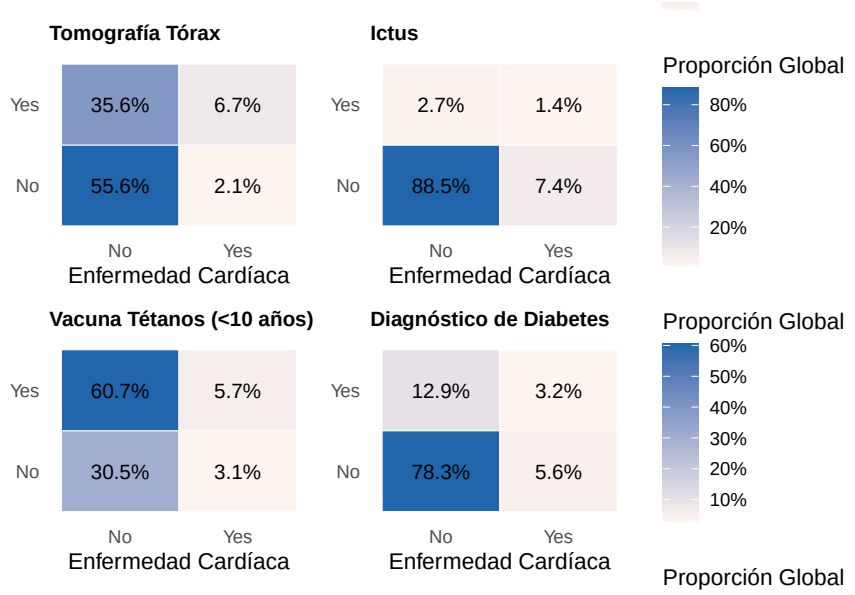
```
p1 <- ggplot(heart_data, aes(x = SaludGeneral, fill = EnfermedadCardiaca)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Salud General", x = NULL, y = "Proporción") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 30, hjust = 1, size = 9),
        plot.title = element_text(face = "bold", size = 11))
p2 <- ggplot(heart_data, aes(x = GrupoEdad, fill = EnfermedadCardiaca)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Grupo de Edad", x = NULL, y = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 30, hjust = 1, size = 9),
        plot.title = element_text(face = "bold", size = 11))
heart_data$SaludMentalBinned <- cut(
  heart_data$DiasMalaSaludMental,
  breaks = c(-1, 0, 5, 15, 30),
  labels = c("0 días", "1-5 días", "6-15 días", "16-30 días")
)
p3 <- ggplot(heart_data, aes(x = SaludMentalBinned, fill = EnfermedadCardiaca)) +geom_bar(position = "fill", alpha =
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Días de Mala Salud Mental", x = NULL, y = "Proporción") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 30, hjust = 1, size = 9),
        plot.title = element_text(face = "bold", size = 11))
p4 <- ggplot(heart_data, aes(x = EstadoFumador, fill = EnfermedadCardiaca)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Estado Fumador", x = NULL, y = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 30, hjust = 1, size = 9),
        plot.title = element_text(face = "bold", size = 11))
(p1 + p2) / (p3 + p4) + plot_layout(guides = "collect") &
  theme(legend.position = "bottom")
```



En estos gráficos de barras podemos apreciar muy bien como la proporción de enfermos del corazón aumenta significativamente , por ejemplo, en grupos de edad avanzada, como cabría esperar o en gente que dice tener mala salud. En el caso de los fumadores sí que se nota que el riesgo de padecer cardiopatías desciende en los no fumadores, y además podemos ver como en los días de mala salud mental se mantiene casi constante excepto en el último tramo, pero este es un tramo que concentra muchos números de días.

Por último podemos comparar variables binarrias con heat maps.

```
crear_heatmap_binaria <- function(data, var_binaria, titulo) {
  data %>%count(EnfermedadCardiaca, !!sym(var_binaria)) %>%
    mutate(Proporcion = n / sum(n)) %>%
    ggplot(aes(x = EnfermedadCardiaca, y = as.factor(!!sym(var_binaria)), fill = Proporcion)) +geom_tile(color = "wh
    scale_fill_gradient(low = "#FFF5F0", high = "#2166AC", labels = scales::percent) +
    geom_text(aes(label = scales::percent(Proporcion, accuracy = 0.1)), color = "black", size = 3.5) +
    labs(title = titulo, x = "Enfermedad Cardíaca", y = NULL, fill = "Proporción Global") +theme_minimal() +theme(
      plot.title = element_text(face = "bold", size = 10),
      panel.grid = element_blank())}
p1 <- crear_heatmap_binaria(heart_data, "TomografiaTorax", "Tomografía Tórax")
p2 <- crear_heatmap_binaria(heart_data, "Ictus", "Ictus")
p3 <- crear_heatmap_binaria(heart_data, "VacunaTetanos10Anos", "Vacuna Tétanos (<10 años)")
p4 <- crear_heatmap_binaria(heart_data, "Diabetes", "Diagnóstico de Diabetes")
(p1 + p2) / (p3 + p4) + plot_layout(guides = "collect")
```



Estos gráficos hay que interpretarlos con cuidado. Por ejemplo, el de la vacuna del tétanos nos dice que la proporción entre los que padecen enfermedades cardiovasculares en los grupos generados por la variable de vacuna del tétanos son prácticamente iguales. Por otra parte, en tomografía se ve claramente como a pesar de que hay menos personas con tomografías hechas tienen mayor proporción de cardiopatías. Lo mismo pasa con diabetes y con ictus pero al tener clases tan desbalanceadas cuesta mucho más visualizarlo.

3.3. Extracción de Características - PCA

En el marco del análisis exploratorio de datos, una práctica habitual es plantear técnicas de extracción de características y reducción de dimensionalidad como el Análisis de Componentes Principales (PCA). Sin embargo, tras evaluar exhaustivamente la naturaleza del conjunto de datos y los objetivos del proyecto, se ha tomado la decisión de no aplicar esta técnica. El motivo principal radica en la explicabilidad clínica, un requisito ético y práctico obligatorio en el ámbito médico. El PCA transforma el espacio original en combinaciones lineales abstractas, lo que supondría perder la trazabilidad directa de los factores de riesgo originales. De cara a un diagnóstico clínico, es indispensable saber si la vulnerabilidad de un paciente deriva de su consumo de tabaco, de un IMC elevado o de antecedentes patológicos, información que un componente principal abstracto no puede proporcionar.

Además del factor clínico, existen fuertes motivos estadísticos para descartar su uso en este caso de estudio. Desde un punto de vista matemático, el PCA resulta inadecuado debido a que está diseñado para extraer patrones de varianza en espacios de variables numéricas continuas, mientras que la inmensa mayoría de los atributos de esta encuesta son factores categóricos (binarios, ordinales y nominales). Por otra parte, no existe una necesidad técnica de reducir el espacio dimensional para evitar la "maldición de la dimensionalidad" o posibles problemas de sobreajuste computacional, dado que se dispone de una muestra masiva de más de 246.000 observaciones frente a un número acotado de apenas 40 variables. Por todo ello, se opta por conservar el espacio original de variables explicativas, garantizando que los futuros modelos predictivos mantengan intacto el significado biológico de los datos y resulten completamente transparentes para el personal médico.

3.4. Distribución Geográfica y Prevalencia por Estado

Con el fin de determinar si el riesgo cardiovascular se distribuye homogéneamente en el territorio de Estados Unidos, se calcula la tasa de prevalencia de cardiopatías en cada

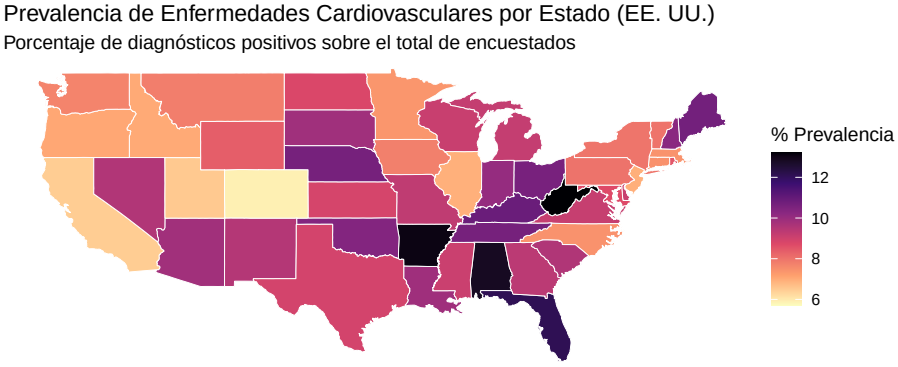
estado a partir de los datos recopilados. Esta representación geográfica facilita la detección de disparidades territoriales significativas y zonas de concentración de riesgo.

```r
#Cálculo de la prevalencia de cardiopatías por estado
prevalencia_estado <- heart_data %>%
  filter(!is.na(Estado)) %>%
  group_by(Estado) %>%
  summarise(
    Total = n(),
    Casos = sum(EnfermedadCardiaca == "Yes", na.rm = TRUE),
    Prevalencia = (Casos / Total) * 100
  ) %>%
  mutate(region = tolower(as.character(Estado)))#Conversión del nombre del estado a minúsculas para cruzar con los p

#Carga de los datos de los estados de EE. UU.
us_states <- map_data("state")

#Unión de la prevalencia de cardiopatías con las coordenadas del mapa
mapa_datos <- us_states %>% left_join(prevalencia_estado, by = "region")

#Generación del mapa de los estados de eeuu coloreados según la prevalencia de cardipatías
ggplot(mapa_datos, aes(x = long, y = lat, group = group, fill = Prevalencia)) +
  geom_polygon(color = "white", linewidth = 0.2) +
  scale_fill_viridis_c(option = "magma", direction = -1, name = "% Prevalencia") +
  theme_void() +
  labs(
    title = "Prevalencia de Enfermedades Cardiovasculares por Estado (EE. UU.)",
    subtitle = "Porcentaje de diagnósticos positivos sobre el total de encuestados"
  )
```



El mapa refleja de forma clara que la presencia de cardiopatías no se distribuye por igual en todos los estados de EE. UU. Las tasas más altas (por encima del 11%) se concentran en el sureste y la zona de los Apalaches, destacando estados como Virginia Occidental, Arkansas, Misisipi y Alabama. Esta concentración coincide con el conocido "cinturón del infarto" (*Stroke Belt*), caracterizado por mayores niveles de tabaquismo y obesidad, dietas con más sodio y peores accesos a revisiones médicas preventivas. Por su parte, la mayor prevalencia en estados como Florida y Maine se explica sobre todo por la edad de sus habitantes, al contar con un mayor porcentaje de personas mayores por el retiro de jubilados y el envejecimiento general de la población. En cambio, las cifras más bajas (entre el 5% y el 6%) se registran en estados del oeste como Utah y Colorado, donde la población es más joven y practica más actividad física.

3.5. Discusión y Conclusiones

Para responder a la pregunta de investigación planteada, el análisis confirma que existe una relación directa entre las características sociodemográficas, los hábitos de vida y las patologías previas con el riesgo cardiovascular. El envejecimiento y la acumulación de problemas de salud se consolidan como los factores más asociados. En cambio, las horas de sueño, la salud mental y el cigarrillo electrónico muestran un impacto directo bajo, mientras que el IMC actúa principalmente como un mediador indirecto. A nivel complementario, la representación en el mapa aporta un matiz visual exploratorio que permite observar una mayor concentración de casos en los estados del sureste de EE. UU.

3.5.1. Perfil de Vulnerabilidad del Paciente

El arquetipo de mayor riesgo corresponde a un varón de 65 o más años. Clínicamente, se caracteriza por una percepción de salud de regular a mala, antecedentes de patologías previas (diabetes, EPOC, ictus o artritis), historial de tabaquismo y el haber acudido habitualmente a chequeos médicos o pruebas de seguimiento en el tórax tras haber experimentado molestias o problemas de salud.

3.5.2. Líneas de Investigación Futura

Con el conjunto de datos acondicionado, se podría plantear en un futuro una fase de modelización predictiva mediante algoritmos supervisados como Random Forest. Esta hipotética extensión del trabajo se centraría en aplicar técnicas de rebalanceo para abordar el 9% de casos positivos, buscando maximizar la sensibilidad diagnóstica en la detección precoz de cardiopatías.

Funding: Este trabajo no ha recibido financiación externa.

Institutional Review Board Statement: Not applicable

Informed Consent Statement: Not applicable

Data Availability Statement: Los datos utilizados están disponibles en el repositorio de GitHub del proyecto.

Conflicts of Interest: Los autores declaran no tener conflicto de intereses.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.