MDPI

Article

Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares

Yeray Antón Juárez[1], Carlos Foo Sidro[1], Ángel Queral Castell[1]

[1] Máster en Ciencia de Datos Universitat de València; yeanjua@alumni.uv.es
* Correspondence: yeanjua@alumni.uv.es

Abstract: El proyecto trata de un análisis exploratorio de datos médicos con el objetivo de encontrar patrones entre datos del historial de un paciente y la aparición de enfermedades cardiovasculares, con el objetivo de poder llegar a predecir en un futuro si otros pacientes son susceptibles a desarrollar cardiopatías.

Keywords: Análisis Exploratorio de Datos; RMarkdown; Tidyverse; Enfermedades Cardiovasculares; Medicina.

1. Introducción

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel global. Según la Organización Mundial de la Salud (OMS), estas patologías son responsables de aproximadamente un 32% de todas las muertes en el mundo [**?**]. Por tanto, lograr identificar de forma precoz a los pacientes susceptibles de padecerlas puede salvar multitud de vidas, especialmente considerando que el diagnóstico de estas enfermedades suele producirse en fases avanzadas.

El objetivo principal de este estudio es analizar los datos procedentes de la encuesta epidemiológica anual del *Centers for Disease Control and Prevention* (CDC), procesados y disponibles en Kaggle [**?**], para establecer relaciones entre diversas variables explicativas y la aparición de cardiopatías. El conjunto de datos está compuesto por 40 variables, incluyendo datos demográficos, hábitos de vida y la presencia de otras patologías secundarias, junto con una variable objetivo binaria que indica la presencia de enfermedad cardíaca. Al disponer de una muestra amplia de aproximadamente 246.000 observaciones, se cuenta con una base sólida para trabajar sobre los datos de forma robusta.

El análisis exploratorio de datos (EDA) consistirá en un primer preprocesamiento y limpieza de los datos (tratamiento de valores perdidos y tipado de variables), seguido de un análisis mediante la visualización de relaciones entre variables con gráficos estadísticos.

A partir de este conjunto de datos, el presente análisis se articula en torno a la siguiente pregunta principal de investigación:

¿Existe una relación directa entre los hábitos de vida, las características sociodemográficas y la presencia de patologías previas u otras variables con el riesgo de padecer enfermedades cardiovasculares?

El análisis exploratorio buscará identificar cuáles de estas variables muestran una mayor asociación con las cardiopatías, cómo interactúan entre sí y qué patrones o perfiles de pacientes presentan una mayor vulnerabilidad.

2. Métodos y Materiales

2.1. Descripción del Conjunto de Datos y Procedencia

El conjunto de datos analizado procede del Behavioral Risk Factor Surveillance System (BRFSS) correspondiente al año 2022, un sistema de encuestas telefónicas coordinado por los Centros para el Control y la Prevención de Enfermedades de los Estados Unidos. Esta base de datos recopila información anual de ciudadanos adultos no institucionalizados

Citation: Antón, Y.; Foo, C.; Queral, A. Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

sobre hábitos de riesgo para la salud, condiciones médicas crónicas y uso de servicios preventivos.

El conjunto cuenta inicialmente con 445.132 observaciones y 40 variables que recogen mediciones biométricas continuas, variables sociodemográficas y antecedentes clínicos.

2.2. Diccionario de Variables

Para facilitar la comprensión del estudio, las 40 variables se traducen al español y se describen a continuación según su naturaleza:

Variable Objetivo Derivada: `EnfermedadCardiaca`: Presencia de patología cardiovascular (infarto de miocardio o angina de pecho).

Variables Sociodemográficas: `Estado`: Estado de residencia en EE. UU. `Sexo`: Sexo biológico (*Female / Male*). `GrupoEdad`: Intervalo de edad en tramos de cinco años (de 18-24 a 80 o más). `RazaEtnia`: Identificación racial y étnica.

Medidas Antropométricas y Estado Físico: `AlturaMetros`: Altura en metros. `PesoKilogramos`: Peso en kilogramos. `IMC`: Índice de masa corporal en kg/m^2. `SaludGeneral`: Autopercepción del estado general de salud (*Poor, Fair, Good, Very good, Excellent*). `DiasMalaSaludFisica`: Número de días con mala salud física en los últimos 30 días (0 a 30). `DiasMalaSaludMental`: Número de días con problemas de salud mental en los últimos 30 días (0 a 30).

Hábitos de Vida: `HorasSueno`: Horas promedio de sueño en 24 horas. `ActividadFisica`: Realización de ejercicio físico en los últimos 30 días (*Yes / No*). `EstadoFumador`: Frecuencia y hábito de consumo de tabaco convencional. `UsoCigarrilloElectronico`: Uso de cigarrillos electrónicos o vapeadores. `ConsumidorAlcohol`: Consumo habitual de bebidas alcohólicas (*Yes / No*).

Patologías y Limitaciones: `InfartoMiocardio`, `AnginaPecho`, `Ictus`: Antecedentes de patología cardiovascular aguda. `Diabetes`, `Asma`, `EPOC`, `EnfermedadRenal`,`Artritis`, `CancerPiel`, `TrastornoDepresivo`: Diagnósticos médicos previos (*Yes / No*). `DientesExtraidos`: Piezas dentales permanentes extraídas (*None, 1 to 5, 6 or more, All*). `DificultadAuditiva`,`Dificultad` `DificultadConcentracion`, `DificultadCaminar`,`DificultadVestirseBanarse`, `DificultadTarea`: Dificultades funcionales y limitaciones en la vida diaria.

Atención Médica y Prevención: `UltimoChequeoMedico`: Tiempo transcurrido desde la última revisión médica rutinaria. `TomografiaTorax`: Realización de escáner o TAC de tórax. `PruebaVIH`, `VacunaGripeUltimoAno`,`VacunaNeumococo`, `VacunaTetanos10Anos`: Pruebas preventivas e inmunizaciones. `ConductaAltoRiesgo`, `CovidPositivo`: Conductas de riesgo y diagnóstico positivo de COVID-19.

2.3. Ingesta y Tipado de Variables

La importación se realiza de forma reproducible a partir del archivo comprimido mediante la librería readr. Posteriormente, se convierten las variables cualitativas a factores nominales y ordinales, y se define la variable objetivo EnfermedadCardiaca (definida como presencia de infarto de miocardio HadHeartAttack o angina de pecho HadAngina).

```r
# Carga, puede tardar unos segundos
heart_raw <- read_csv("data/heart_2022_with_nans.csv.gz")

# Renombrado de variables a español
heart_data <- heart_raw %>%
  rename(
    Estado = State,
    Sexo = Sex,
    SaludGeneral = GeneralHealth,
    DiasMalaSaludFisica = PhysicalHealthDays,
    DiasMalaSaludMental = MentalHealthDays,
    UltimoChequeoMedico = LastCheckupTime,
    ActividadFisica = PhysicalActivities,
```

```
    HorasSueno = SleepHours,
    DientesExtraidos = RemovedTeeth,
    InfartoMiocardio = HadHeartAttack,
    AnginaPecho = HadAngina,
    Ictus = HadStroke,
    Asma = HadAsthma,
    CancerPiel = HadSkinCancer,
    EPOC = HadCOPD,
    TrastornoDepresivo = HadDepressiveDisorder,
    EnfermedadRenal = HadKidneyDisease,
    Artritis = HadArthritis,
    Diabetes = HadDiabetes,
    DificultadAuditiva = DeafOrHardOfHearing,
    DificultadVisual = BlindOrVisionDifficulty,
    DificultadConcentracion = DifficultyConcentrating,
    DificultadCaminar = DifficultyWalking,
    DificultadVestirseBanarse = DifficultyDressingBathing,
    DificultadTareasDiarias = DifficultyErrands,
    EstadoFumador = SmokerStatus,
    UsoCigarrilloElectronico = ECigaretteUsage,
    TomografiaTorax = ChestScan,
    RazaEtnia = RaceEthnicityCategory,
    GrupoEdad = AgeCategory,
    AlturaMetros = HeightInMeters,
    PesoKilogramos = WeightInKilograms,
    IMC = BMI,
    ConsumidorAlcohol = AlcoholDrinkers,
    PruebaVIH = HIVTesting,
    VacunaGripeUltimoAno = FluVaxLast12,
    VacunaNeumococo = PneumoVaxEver,
    VacunaTetanos10Anos = TetanusLast10Tdap,
    ConductaAltoRiesgo = HighRiskLastYear,
    CovidPositivo = CovidPos
  )

# Tipado de variables y creación de HeartDisease
heart_data <- heart_data %>%
  mutate(
    # Variable objetivo combinada (Cardiopatía)
    EnfermedadCardiaca = factor(
    if_else(InfartoMiocardio == "Yes" | AnginaPecho == "Yes", "Yes", "No"),
    levels = c("No", "Yes")),

    # Factores ordinales con jerarquía lógica
    SaludGeneral = factor(
      SaludGeneral,
      levels = c("Poor", "Fair", "Good", "Very good", "Excellent"),
      ordered = TRUE
    ),

    GrupoEdad = factor(
      GrupoEdad,
      levels = c(
        "Age 18 to 24", "Age 25 to 29", "Age 30 to 34", "Age 35 to 39",
```

```
        "Age 40 to 44", "Age 45 to 49", "Age 50 to 54", "Age 55 to 59",
        "Age 60 to 64", "Age 65 to 69", "Age 70 to 74", "Age 75 to 79",
        "Age 80 or older"
      ),
      ordered = TRUE
    ),

    DientesExtraidos = factor(
      DientesExtraidos,
      levels = c("None of them", "1 to 5", "6 or more, but not all", "All"),
      ordered = TRUE
    ),

    # Factores nominales (resto de variables de texto)
    across(where(is.character), as.factor)
  )

# Resumen del dataset
tabla_resumen <- tibble(
  Métrica = c("Total de Observaciones (Filas)", "Variables Totales",
              "Casos con Cardiopatía (Yes)", "Casos sin Cardiopatía (No)",
              "Porcentaje de Cardiopatía (%)"),
  Valor = c(
    nrow(heart_data),
    as.character(ncol(heart_data)),
    sum(heart_data$EnfermedadCardiaca == "Yes", na.rm = TRUE),
    sum(heart_data$EnfermedadCardiaca == "No", na.rm = TRUE),
    paste(round(mean(heart_data$EnfermedadCardiaca == "Yes", na.rm = TRUE) * 100,
  )
)

kable(tabla_resumen, caption = "Dimensiones iniciales y porcentaje de cardiopatías
```

Table 1. Dimensiones iniciales y porcentaje de cardiopatías.

Métrica	Valor
Total de Observaciones (Filas)	445132
Variables Totales	41
Casos con Cardiopatía (Yes)	39751
Casos sin Cardiopatía (No)	400360
Porcentaje de Cardiopatía (%)	9.03 %

2.4. Detección y Corrección de Inconsistencias

Siguiendo con el análisis exploratorio se analiza la presencia de valores especiales, valores numéricos imposibles para las variables y la consistencia entre el índice de masa corporal, el peso y la altura.

```
#Comprobación de valores especiales

infinitos <- sapply(heart_data %>% select(where(is.numeric)), function(x) sum(is.i
print("Valores infinitos por variable numérica:")
```

```
## [1] "Valores infinitos por variable numérica:"
```

```r
print(infinitos)
```

```
## DiasMalaSaludFisica DiasMalaSaludMental          HorasSueno        AlturaMetros
##                   0                    0                   0                   0
##      PesoKilogramos                 IMC
##                   0                    0
```

```r
# Comprobación de valores menores o iguales a cero
menores_iguales_cero <- sapply(heart_data %>% select(where(is.numeric)), function(
print("Valores <= 0 por variable:")
```

```
## [1] "Valores <= 0 por variable:"
```

```r
print(menores_iguales_cero)
```

```
## DiasMalaSaludFisica DiasMalaSaludMental          HorasSueno        AlturaMetros
##              267819              265229                   0                   0
##      PesoKilogramos                 IMC
##                   0                    0
```

```r
#En DiasMalaSaludFisica y en DiasMalaSaludMental sí tiene sentido encontrar
#iguales a 0

# Calculamos la diferencia entre el BMI registrado y el calculado

# Se usa un margen de tolerancia de 1.5 kg/m^2 porque los datos originales
# se recogieron en unidades imperiales (libras y pulgadas) y al convertirlos
# a metros y kilogramos se acumulan errores de redondeo de hasta +-1.2 puntos.
# Una diferencia superior a 1.5 indica un error real de incoherencia.

bmi_calculado <- heart_data$PesoKilogramos / (heart_data$AlturaMetros^2)
diferencia_bmi <- abs(heart_data$IMC - bmi_calculado)
inconsistencias_bmi <- sum(diferencia_bmi > 1.5, na.rm = TRUE)

print(paste("Número de registros con BMI inconsistente respecto a peso/altura:", i
```

```
## [1] "Número de registros con BMI inconsistente respecto a peso/altura: 0"
```

```r
# Corrección de inconsistencias

# Sustituimos por NA valores biológicamente imposibles:
# - Horas de sueño: dormir <= 2h o >= 20h de forma continuada es anómalo/error
#   de encuesta
# - Alturas inferiores a 1 metro en adultos

heart_data <- heart_data %>%
  mutate(
    HorasSueno = ifelse(HorasSueno <= 2 | HorasSueno >= 20, NA, HorasSueno),
    AlturaMetros = ifelse(AlturaMetros < 1.0, NA, AlturaMetros)
  )
```

2.5. Valores Perdidos y Observaciones Completas

A continuación se cuantifica el número y porcentaje de valores perdidos presentes en las variables y se evalúa el volumen de observaciones completas.

```
# Número y porcentaje de NAs por columna

nas_columna <- colSums(is.na(heart_data))
nas_columna
```

```
##                   Estado                     Sexo            SaludGeneral
##                        0                        0                    1198
##      DiasMalaSaludFisica      DiasMalaSaludMental      UltimoChequeoMedico
##                    10927                     9067                    8308
##          ActividadFisica              HorasSueno         DientesExtraidos
##                     1093                     8392                   11360
##         InfartoMiocardio             AnginaPecho                    Ictus
##                     3065                     4405                    1557
##                    Asma              CancerPiel                     EPOC
##                     1773                     3143                    2219
##       TrastornoDepresivo          EnfermedadRenal                 Artritis
##                     2812                     1926                    2633
##                 Diabetes       DificultadAuditiva         DificultadVisual
##                     1087                    20647                   21564
##  DificultadConcentracion        DificultadCaminar DificultadVestirseBanarse
##                    24240                    24012                   23915
##  DificultadTareasDiarias           EstadoFumador UsoCigarrilloElectronico
##                    25656                    35462                   35660
##          TomografiaTorax              RazaEtnia               GrupoEdad
##                    56046                    14057                    9079
##             AlturaMetros         PesoKilogramos                     IMC
##                    28683                    42078                   48806
##        ConsumidorAlcohol              PruebaVIH     VacunaGripeUltimoAno
##                    46574                    66127                   47121
##          VacunaNeumococo      VacunaTetanos10Anos       ConductaAltoRiesgo
##                    77040                    82516                   50623
##            CovidPositivo      EnfermedadCardiaca
##                    50764                    5021
```

```
pct_nas <- round((nas_columna / nrow(heart_data)) * 100, 2)
pct_nas
```

```
##                   Estado                     Sexo            SaludGeneral
##                     0.00                     0.00                    0.27
##      DiasMalaSaludFisica      DiasMalaSaludMental      UltimoChequeoMedico
##                     2.45                     2.04                    1.87
##          ActividadFisica              HorasSueno         DientesExtraidos
##                     0.25                     1.89                    2.55
##         InfartoMiocardio             AnginaPecho                    Ictus
##                     0.69                     0.99                    0.35
##                    Asma              CancerPiel                     EPOC
##                     0.40                     0.71                    0.50
##       TrastornoDepresivo          EnfermedadRenal                 Artritis
##                     0.63                     0.43                    0.59
##                 Diabetes       DificultadAuditiva         DificultadVisual
```

```
##                     0.24                     4.64                     4.84
##   DificultadConcentracion        DificultadCaminar DificultadVestirseBanarse
##                     5.45                     5.39                     5.37
##   DificultadTareasDiarias            EstadoFumador  UsoCigarrilloElectronico
##                     5.76                     7.97                     8.01
##           TomografiaTorax               RazaEtnia                GrupoEdad
##                    12.59                     3.16                     2.04
##              AlturaMetros          PesoKilogramos                      IMC
##                     6.44                     9.45                    10.96
##         ConsumidorAlcohol               PruebaVIH     VacunaGripeUltimoAno
##                    10.46                    14.86                    10.59
##           VacunaNeumococo      VacunaTetanos10Anos       ConductaAltoRiesgo
##                    17.31                    18.54                    11.37
##             CovidPositivo       EnfermedadCardiaca
##                    11.40                     1.13
```

```
# Tabla con las variables que presentan valores perdidos (ordenadas de mayor a men
tabla_nas <- tibble(
  Variable = names(nas_columna),
  Num_NAs = nas_columna,
  Porcentaje = paste(pct_nas, " %")
) %>%
  filter(Num_NAs > 0) %>%
  arrange(desc(Num_NAs))

# Mostramos las 10 variables con mayor volumen de NAs
head(tabla_nas, 10)
```

```
## # A tibble: 10 x 3
##    Variable             Num_NAs Porcentaje
##    <chr>                  <dbl> <chr>
##  1 VacunaTetanos10Anos    82516 18.54  %
##  2 VacunaNeumococo        77040 17.31  %
##  3 PruebaVIH              66127 14.86  %
##  4 TomografiaTorax        56046 12.59  %
##  5 CovidPositivo          50764 11.4  %
##  6 ConductaAltoRiesgo     50623 11.37  %
##  7 IMC                    48806 10.96  %
##  8 VacunaGripeUltimoAno   47121 10.59  %
##  9 ConsumidorAlcohol      46574 10.46  %
## 10 PesoKilogramos         42078 9.45  %
```

```
# Observaciones completas
num_completas <- sum(complete.cases(heart_data))
pct_completas <- round((num_completas / nrow(heart_data)) * 100, 2)

print(paste("Número de observaciones completas:", num_completas))
```

```
## [1] "Número de observaciones completas: 244635"
```

```
print(paste("Porcentaje de observaciones completas:", pct_completas, "%"))
```

```
## [1] "Porcentaje de observaciones completas: 54.96 %"
```

A diferencia de análisis sobre muestras pequeñas donde se eliminan todas las filas incompletas, en este caso descartar observaciones con algún valor perdido supondría perder un porcentaje demasiado alto de los pacientes (principalmente por no haber contestado a preguntas secundarias como la vacunación o la prueba de VIH). Por tanto, se conservan las observaciones para el análisis general y se aplicarán métodos de imputación.

2.6. Estadísticos Descriptivos

Se analiza la influencia de los valores extremos sobrelas variables numéricas. Para ello, se calculan estadísticos clásicos sensibles a valores atípicos (media y desviación típica) y se contrastan con estimadores robustos (mediana, MADM e IQR).

```
# Función MADM robusta a NAs
madm <- function(x, na.rm = TRUE) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)
}

# Cálculo de estadísticos para cada variable numérica
estadisticos_num <- heart_data %>%
  select(where(is.numeric)) %>%
  pivot_longer(
    cols = everything(),
    names_to = "Variable",
    values_to = "Valor"
  ) %>%
  group_by(Variable) %>%
  summarise(
    Media   = round(mean(Valor, na.rm = TRUE), 2),
    SD      = round(sd(Valor, na.rm = TRUE), 2),
    Mediana = round(median(Valor, na.rm = TRUE), 2),
    MADM    = round(madm(Valor, na.rm = TRUE), 2),
    IQR     = round(IQR(Valor, na.rm = TRUE), 2)
  )

kable(estadisticos_num, caption = "Comparativa de estadísticos clásicos y robustos
```

Table 2. Comparativa de estadísticos clásicos y robustos en variables numéricas.

Variable	Media	SD	Mediana	MADM	IQR
AlturaMetros	1.70	0.11	1.70	0.12	0.15
DiasMalaSaludFisica	4.35	8.69	0.00	0.00	3.00
DiasMalaSaludMental	4.38	8.39	0.00	0.00	5.00
HorasSueno	7.05	1.41	7.00	1.48	2.00
IMC	28.53	6.55	27.44	5.53	7.62
PesoKilogramos	83.07	21.45	80.74	18.83	27.21

Al comparar los resultados se observa una notable discrepancia entre las medidas clásicas y las robustas en variables con fuerte asimetría:

- En DiasMalaSaludFisica y DiasMalaSaludMental, la mediana y el MADM son 0 (la mayoría de los individuos dicen no tener días de enfermedad), mientras que la media se sitúa en torno a 4 días con una desviación típica de más de 8 días, claramente inflada por los individuos con patologías crónicas graves (30 días).
- En el IMC y el PesoKilogramos, la media es superior a la mediana debido a la presencia de casos con obesidad severa en la cola superior de la distribución.

2.7. Detección Univariante de Outliers y Comparativa de Métodos

A continuación se aplican y comparan cuatro métodos de detección de outliers sobre el IMC (Índice de Masa Corporal): regla 3 sigma, identificador Hampel, regla del boxplot y percentiles (5% y 95%).

Para cada método se evalúa tanto el número de anomalías detectadas como los umbrales que definen los valores típicos para decidir como tratar a los valores extremos.

```r
# 1. Definición de las 4 funciones de detección

# Regla 3 Sigma
reglasigma <- function(x) {
  media <- mean(x, na.rm = TRUE)
  desviacion <- sd(x, na.rm = TRUE)
  abs(x - media) > 3 * desviacion
}

# Identificador Hampel
reglahampel <- function(x) {
  mediana <- median(x, na.rm = TRUE)
  mad <- 1.4826 * median(abs(x - mediana), na.rm = TRUE)
  abs(x - mediana) > 3 * mad
}

# Regla Boxplot
reglaboxplot <- function(x) {
  q1 <- quantile(x, 0.25, na.rm = TRUE)
  q3 <- quantile(x, 0.75, na.rm = TRUE)
  iqr <- q3 - q1
  (x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)
}

# Percentiles (5% - 95%)
reglapercentil <- function(x) {
  p05 <- quantile(x, 0.05, na.rm = TRUE)
  p95 <- quantile(x, 0.95, na.rm = TRUE)
  (x < p05) | (x > p95)
}

# Aplicación de las reglas sobre el IMC
heart_outliers <- heart_data %>%
  mutate(
    IMC_Sigma     = reglasigma(IMC),
    IMC_Hampel    = reglahampel(IMC),
    IMC_Boxplot   = reglaboxplot(IMC),
    IMC_Percentil = reglapercentil(IMC)
  )

# Cálculo de umbrales y tabla comparativa
media_imc <- mean(heart_data$IMC, na.rm = TRUE)
sd_imc    <- sd(heart_data$IMC, na.rm = TRUE)
med_imc   <- median(heart_data$IMC, na.rm = TRUE)
mad_imc   <- 1.4826 * median(abs(heart_data$IMC - med_imc), na.rm = TRUE)
q1_imc    <- quantile(heart_data$IMC, 0.25, na.rm = TRUE)
q3_imc    <- quantile(heart_data$IMC, 0.75, na.rm = TRUE)
```

```
iqr_imc   <- q3_imc - q1_imc
p05_imc   <- quantile(heart_data$IMC, 0.05, na.rm = TRUE)
p95_imc   <- quantile(heart_data$IMC, 0.95, na.rm = TRUE)

tabla_outliers <- tibble(
  Método = c("Regla 3 Sigma", "Identificador Hampel", "Regla Boxplot", "Percentile
  Outliers_Detectados = c(
    sum(heart_outliers$IMC_Sigma, na.rm = TRUE),
    sum(heart_outliers$IMC_Hampel, na.rm = TRUE),
    sum(heart_outliers$IMC_Boxplot, na.rm = TRUE),
    sum(heart_outliers$IMC_Percentil, na.rm = TRUE)
  ),
  Porcentaje = paste(round(c(
    mean(heart_outliers$IMC_Sigma, na.rm = TRUE),
    mean(heart_outliers$IMC_Hampel, na.rm = TRUE),
    mean(heart_outliers$IMC_Boxplot, na.rm = TRUE),
    mean(heart_outliers$IMC_Percentil, na.rm = TRUE)
  ) * 100, 2), "%"),
  Umbral_Inferior = round(c(media_imc - 3 * sd_imc, med_imc - 3 * mad_imc, q1_imc
  Umbral_Superior = round(c(media_imc + 3 * sd_imc, med_imc + 3 * mad_imc, q3_imc
)

kable(tabla_outliers, caption = "Comparativa de métodos de detección de outliers y
```

Table 3. Comparativa de métodos de detección de outliers y umbrales en la variable IMC.

Método	Outliers_Detectados	Porcentaje	Umbral_Inferior	Umbral_Superior
Regla 3 Sigma	5071	1.28 %	8.87	48.19
Identificador Hampel	10657	2.69 %	10.85	44.03
Regla Boxplot	12339	3.11 %	12.70	43.18
Percentiles (5% - 95%)	38840	9.8 %	20.12	40.69

La regla 3 Sigma es poco agresiva: fija el umbral superior en 48.21, detectando solo un 1.28% de outliers debido a que la propia desviación típica se expande por la presencia de casos extremos. **El identificador Hampel es más agresivo:** al basarse en el MADM, sitúa el umbral superior en 44.03, identificando un 2.69% de anomalías. **La regla del Boxplot:** con un umbral superior de 43.33 y detectando un 3.11% de valores fuera de los bigotes. Esto pasa porque justo la variable IMC no es simétrica si no con una cola a la derecha. **Percentiles:** corta de forma fija el 10% de la muestra, con independencia de la distribución.

Tratamiento de los outliers identificados: Estos valores de IMC no representan errores de medición o transcripción (ya fueron filtrados antes), sino observaciones biológicamente reales correspondientes a pacientes con obesidad mórbida (grado III). Por tanto, no se eliminan del conjunto de datos, sino que se conservan para ser analizados mediante procedimientos y estadísticos en los siguientes bloques.

2.8. Representación Gráfica de Outliers por Método

Se representan gráficamente los valores de IMC frente a los métodos de detección empleados, mostrando los datos catalogados como típicos y los catalogados como outliers en distinto color.

Para evitar problemas de saturación visual en el gráfico debido al volumen de más de 400.000 observaciones, se utiliza una muestra aleatoria representativa de 5.000 observaciones con set.seed(123) y se aplica dispersión aleatoria con transparencia.

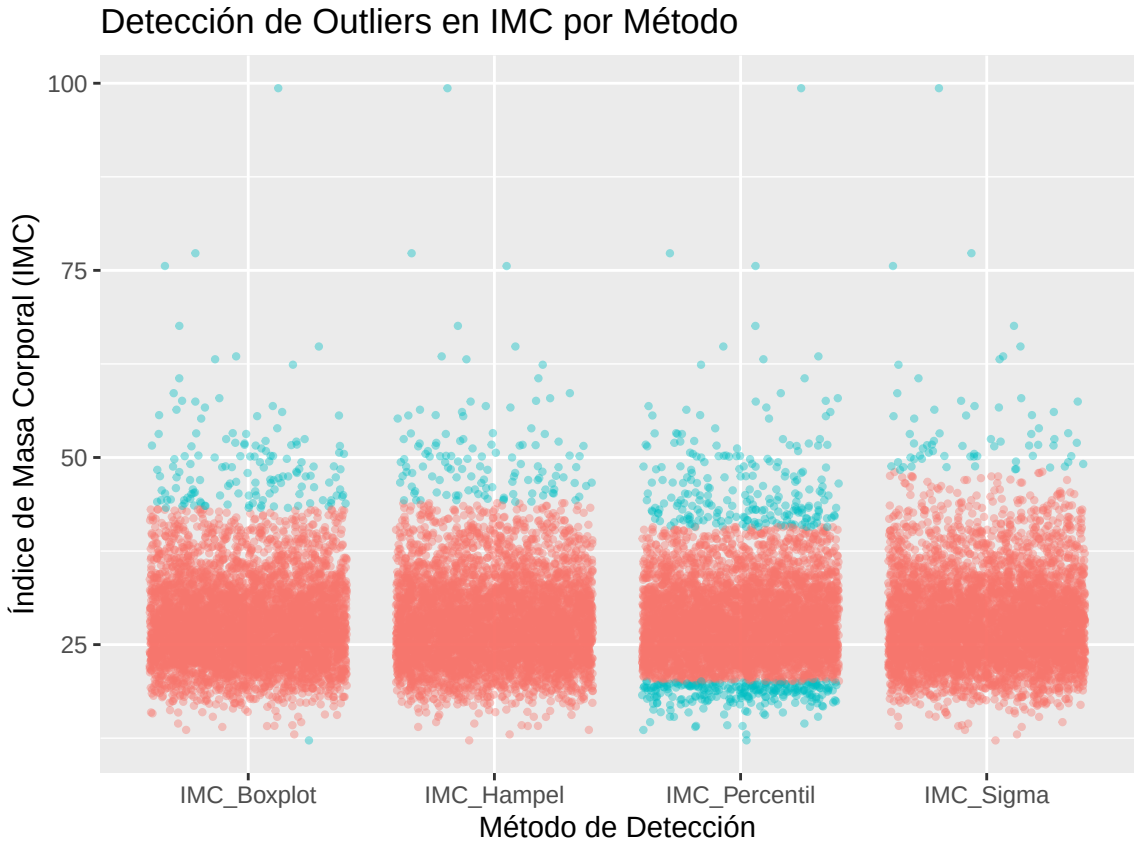


Figure 1. Detección de outliers en IMC según cada método implementado.

```r
# Preparación de datos
set.seed(123)

df_plot_outliers <- heart_outliers %>%
  select(IMC, starts_with("IMC_")) %>%
  filter(!is.na(IMC)) %>%
  slice_sample(n = 5000) %>%
  pivot_longer(
    cols = starts_with("IMC_"),
    names_to = "Metodo",
    values_to = "Es_Outlier"
  )

# Gráfico de puntos con jitter
ggplot(df_plot_outliers, aes(x = Metodo, y = IMC, color = Es_Outlier)) +
  geom_point(position = "jitter", alpha = 0.4, size = 0.8) +
  labs(
    title = "Detección de Outliers en IMC por Método",
    x = "Método de Detección",
    y = "Índice de Masa Corporal (IMC)",
    color = "Es Outlier"
  )
```

El gráfico refleja de manera visual la sensibilidad de cada método.

Continuidad de los datos: Se observa que los valores superiores no son puntos aislados ni errores tipográficos, sino una nube continua que se extiende hasta valores

extremos, confirmando que se trata de individuos con obesidad severa real que deben conservarse en la muestra.

- **Comparativa de cortes:** La regla 3 Sigma deja una franja alta de puntos clasificados como normales (debido a la varianza inflada), mientras que la regla del Boxplot y el identificador Hampel capturan de forma equilibrada la masa de valores atípicos.

2.9. Imputación de Variables Numéricas

Para garantizar la integridad de los análisis cuantitativos posteriores sin introducir sesgos artificiales, se aplica una imputación según la naturaleza de cada variable:

Variables AlturaMetros, PesoKilogramos, IMC: Hombres y mujeres siguen distribuciones distintas. Imputamos los valores perdidos directamente por la media según el Sexo del paciente.

Variables de descanso y salud percibida (`HorasSueno`, `DiasMalaSaludFisica`, `DiasMalaSalud` Al concentrarse en valores típicos (7 horas de sueño y 0 días de enfermedad), se imputan mediante su mediana.

```
# Imputación de medidas por Sexoç

heart_data <- heart_data %>%
  group_by(Sexo) %>%
  mutate(
    AlturaMetros   = ifelse(is.na(AlturaMetros), mean(AlturaMetros, na.rm = TRUE),
    PesoKilogramos = ifelse(is.na(PesoKilogramos), mean(PesoKilogramos, na.rm = TR
    IMC            = ifelse(is.na(IMC), mean(IMC, na.rm = TRUE), IMC)
  ) %>%
  ungroup()

# Imputación de descanso y salud percibida por la mediana

heart_data <- heart_data %>%
  mutate(
    HorasSueno          = ifelse(is.na(HorasSueno), median(HorasSueno, na.rm = TRU
    DiasMalaSaludFisica = ifelse(is.na(DiasMalaSaludFisica), median(DiasMalaSaludF
    DiasMalaSaludMental = ifelse(is.na(DiasMalaSaludMental), median(DiasMalaSaludM
  )
# Comprobación final de NAs restantes en variables numéricas

nas_numericas_final <- sapply(heart_data %>% select(where(is.numeric)), function(x
print("NAs restantes en variables numéricas tras la imputación:")
```

```
## [1] "NAs restantes en variables numéricas tras la imputación:"
```

```
print(nas_numericas_final)
```

```
## DiasMalaSaludFisica DiasMalaSaludMental          HorasSueno        AlturaMetros
##                   0                    0                   0                   0
##      PesoKilogramos                 IMC
##                   0                    0
```

Tras el proceso de imputación, todas las variables numéricas continuas y discretas del estudio quedan con cero valores perdidos, listas para el análisis bivariante y multivariante.

3. Resultados

This section may be divided by subheadings. It should provide a concise and precise description of the experimental results, their interpretation as well as the experimental conclusions that can be drawn.

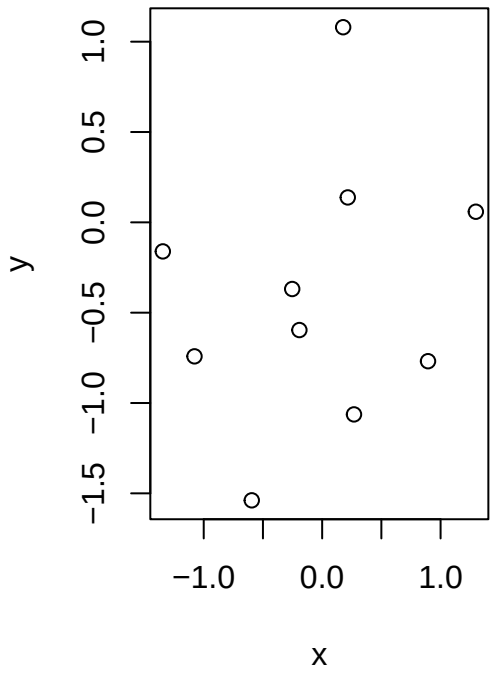


Figure 2. A figure added with a code chunk.

3.1. Subsection Heading Here

Subsection text here.

3.1.1. Subsubsection Heading Here

Bulleted lists look like this:

- First bullet
- Second bullet
- Third bullet

All figures and tables should be cited in the main text as Figure 2, **??**, etc. To get cross-reference to figure generated by R chunks include the `\\label{}` tag in the `fig.cap` attribute of the R chunk: `fig.cap = "Fancy Caption\\label{fig:plot}"`.

4. Discusión

Authors should discuss the results and how they can be interpreted in perspective of previous studies and of the working hypotheses. The findings and their implications should be discussed in the broadest context possible. Future research directions may also be highlighted.

5. Conclusión

This section is not mandatory, but can be added to the manuscript if the discussion is unusually long or complex.

Funding: Este trabajo no ha recibido financiación externa.

Institutional Review Board Statement: Not applicable

Informed Consent Statement: Not applicable

Data Availability Statement: Los datos utilizados están disponibles en el repositorio de GitHub del proyecto.

Conflicts of Interest: Los autores declaran no tener conflicto de intereses.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.