MDPI

Article

Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares

Yeray Antón Juárez[1], Carlos Foo Sidro[1], Ángel Queral Castell[1]

[1] Máster en Ciencia de Datos Universitat de València; yeanjua@alumni.uv.es
* Correspondence: yeanjua@alumni.uv.es

Abstract: El proyecto trata de un análisis exploratorio de datos médicos con el objetivo de encontrar patrones entre datos del historial de un paciente y la aparición de enfermedades cardiovasculares, con el objetivo de poder llegar a predecir en un futuro si otros pacientes son susceptibles a desarrollar cardiopatías.

Keywords: Análisis Exploratorio de Datos; RMarkdown; Tidyverse; Enfermedades Cardiovasculares; Medicina.

1. Introducción

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel global. Según la Organización Mundial de la Salud (OMS), estas patologías son responsables de aproximadamente un 32% de todas las muertes en el mundo [**?**]. Por tanto, lograr identificar de forma precoz a los pacientes susceptibles de padecerlas puede salvar multitud de vidas, especialmente considerando que el diagnóstico de estas enfermedades suele producirse en fases avanzadas.

El objetivo principal de este estudio es analizar los datos procedentes de la encuesta epidemiológica anual del *Centers for Disease Control and Prevention* (CDC), procesados y disponibles en Kaggle [**?**], para establecer relaciones entre diversas variables explicativas y la aparición de cardiopatías. El conjunto de datos está compuesto por 40 variables, incluyendo datos demográficos, hábitos de vida y la presencia de otras patologías secundarias, junto con una variable objetivo binaria que indica la presencia de enfermedad cardíaca. Al disponer de una muestra amplia de aproximadamente 246.000 observaciones, se cuenta con una base sólida para trabajar sobre los datos de forma robusta.

El análisis exploratorio de datos (EDA) consistirá en un primer preprocesamiento y limpieza de los datos (tratamiento de valores perdidos y tipado de variables), seguido de un análisis mediante la visualización de relaciones entre variables con gráficos estadísticos.

A partir de este conjunto de datos, el presente análisis se articula en torno a la siguiente pregunta principal de investigación:

¿Existe una relación directa entre los hábitos de vida, las características sociodemográficas y la presencia de patologías previas u otras variables con el riesgo de padecer enfermedades cardiovasculares?

El análisis exploratorio buscará identificar cuáles de estas variables muestran una mayor asociación con las cardiopatías, cómo interactúan entre sí y qué patrones o perfiles de pacientes presentan una mayor vulnerabilidad.

2. Métodos y Materiales

2.1. Descripción del Conjunto de Datos y Procedencia

El conjunto de datos analizado procede del Behavioral Risk Factor Surveillance System (BRFSS) correspondiente al año 2022, un sistema de encuestas telefónicas coordinado por los Centros para el Control y la Prevención de Enfermedades de los Estados Unidos. Esta base de datos recopila información anual de ciudadanos adultos no institucionalizados

Citation: Antón, Y.; Foo, C.; Queral, A. Análisis Exploratorio de Datos: Indicadores de Enfermedades Cardiovasculares. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

sobre hábitos de riesgo para la salud, condiciones médicas crónicas y uso de servicios preventivos.

El conjunto cuenta inicialmente con 445.132 observaciones y 40 variables que recogen mediciones biométricas continuas, variables sociodemográficas y antecedentes clínicos.

2.2. Diccionario de Variables

Para facilitar la comprensión del estudio, las 40 variables se traducen al español y se describen a continuación según su naturaleza:

Variable Objetivo Derivada: `EnfermedadCardiaca`: Presencia de patología cardiovascular (infarto de miocardio o angina de pecho).

Variables Sociodemográficas: `Estado`: Estado de residencia en EE. UU. `Sexo`: Sexo biológico (*Female / Male*). `GrupoEdad`: Intervalo de edad en tramos de cinco años (de 18-24 a 80 o más). `RazaEtnia`: Identificación racial y étnica.

Medidas Antropométricas y Estado Físico: `AlturaMetros`: Altura en metros. `PesoKilogramos`: Peso en kilogramos. `IMC`: Índice de masa corporal en kg/m^2. `SaludGeneral`: Autopercepción del estado general de salud (*Poor, Fair, Good, Very good, Excellent*). `DiasMalaSaludFisica`: Número de días con mala salud física en los últimos 30 días (0 a 30). `DiasMalaSaludMental`: Número de días con problemas de salud mental en los últimos 30 días (0 a 30).

Hábitos de Vida: `HorasSueno`: Horas promedio de sueño en 24 horas. `ActividadFisica`: Realización de ejercicio físico en los últimos 30 días (*Yes / No*). `EstadoFumador`: Frecuencia y hábito de consumo de tabaco convencional. `UsoCigarrilloElectronico`: Uso de cigarrillos electrónicos o vapeadores. `ConsumidorAlcohol`: Consumo habitual de bebidas alcohólicas (*Yes / No*).

Patologías y Limitaciones: `InfartoMiocardio`, `AnginaPecho`, `Ictus`: Antecedentes de patología cardiovascular aguda. `Diabetes`, `Asma`, `EPOC`, `EnfermedadRenal`,`Artritis`, `CancerPiel`, `TrastornoDepresivo`: Diagnósticos médicos previos (*Yes / No*). `DientesExtraidos`: Piezas dentales permanentes extraídas (*None, 1 to 5, 6 or more, All*). `DificultadAuditiva`,`Dificultad` `DificultadConcentracion`, `DificultadCaminar`,`DificultadVestirseBanarse`, `DificultadTarea` Dificultades funcionales y limitaciones en la vida diaria.

Atención Médica y Prevención: `UltimoChequeoMedico`: Tiempo transcurrido desde la última revisión médica rutinaria. `TomografiaTorax`: Realización de escáner o TAC de tórax. `PruebaVIH`, `VacunaGripeUltimoAno`,`VacunaNeumococo`, `VacunaTetanos10Anos`: Pruebas preventivas e inmunizaciones. `ConductaAltoRiesgo`, `CovidPositivo`: Conductas de riesgo y diagnóstico positivo de COVID-19.

2.3. Ingesta y Tipado de Variables

La importación se realiza de forma reproducible a partir del archivo comprimido mediante la librería readr. Posteriormente, se convierten las variables cualitativas a factores nominales y ordinales, y se define la variable objetivo EnfermedadCardiaca (definida como presencia de infarto de miocardio HadHeartAttack o angina de pecho HadAngina).

```r
# Carga, puede tardar unos segundos
heart_raw <- read_csv("data/heart_2022_with_nans.csv.gz")

# Renombrado de variables a español
heart_data <- heart_raw %>%
  rename(
    Estado = State,
    Sexo = Sex,
    SaludGeneral = GeneralHealth,
    DiasMalaSaludFisica = PhysicalHealthDays,
    DiasMalaSaludMental = MentalHealthDays,
    UltimoChequeoMedico = LastCheckupTime,
    ActividadFisica = PhysicalActivities,
```

```
    HorasSueno = SleepHours,
    DientesExtraidos = RemovedTeeth,
    InfartoMiocardio = HadHeartAttack,
    AnginaPecho = HadAngina,
    Ictus = HadStroke,
    Asma = HadAsthma,
    CancerPiel = HadSkinCancer,
    EPOC = HadCOPD,
    TrastornoDepresivo = HadDepressiveDisorder,
    EnfermedadRenal = HadKidneyDisease,
    Artritis = HadArthritis,
    Diabetes = HadDiabetes,
    DificultadAuditiva = DeafOrHardOfHearing,
    DificultadVisual = BlindOrVisionDifficulty,
    DificultadConcentracion = DifficultyConcentrating,
    DificultadCaminar = DifficultyWalking,
    DificultadVestirseBanarse = DifficultyDressingBathing,
    DificultadTareasDiarias = DifficultyErrands,
    EstadoFumador = SmokerStatus,
    UsoCigarrilloElectronico = ECigaretteUsage,
    TomografiaTorax = ChestScan,
    RazaEtnia = RaceEthnicityCategory,
    GrupoEdad = AgeCategory,
    AlturaMetros = HeightInMeters,
    PesoKilogramos = WeightInKilograms,
    IMC = BMI,
    ConsumidorAlcohol = AlcoholDrinkers,
    PruebaVIH = HIVTesting,
    VacunaGripeUltimoAno = FluVaxLast12,
    VacunaNeumococo = PneumoVaxEver,
    VacunaTetanos10Anos = TetanusLast10Tdap,
    ConductaAltoRiesgo = HighRiskLastYear,
    CovidPositivo = CovidPos
  )

# Tipado de variables y creación de HeartDisease
heart_data <- heart_data %>%
  mutate(
    # Variable objetivo combinada (Cardiopatía)
    EnfermedadCardiaca = factor(
      if_else(InfartoMiocardio == "Yes" | AnginaPecho == "Yes", "Yes", "No"),
      levels = c("No", "Yes")
    ),

    # Recodificación de Diabetes (agrupando prediabetes y reasignando gestacional)
    Diabetes = factor(
      case_when(
        Diabetes == "Yes" ~ "Yes",
        Diabetes == "No, pre-diabetes or borderline diabetes" ~ "Yes",
        Diabetes == "Yes, but only during pregnancy (female)" ~ "No",
        Diabetes == "No" ~ "No",
        TRUE ~ NA_character_
      ),
      levels = c("No", "Yes")
```

```
  ),

  # Factores ordinales con jerarquía lógica
  SaludGeneral = factor(
    SaludGeneral,
    levels = c("Poor", "Fair", "Good", "Very good", "Excellent"),
    ordered = TRUE
  ),

  GrupoEdad = factor(
    GrupoEdad,
    levels = c(
      "Age 18 to 24", "Age 25 to 29", "Age 30 to 34", "Age 35 to 39",
      "Age 40 to 44", "Age 45 to 49", "Age 50 to 54", "Age 55 to 59",
      "Age 60 to 64", "Age 65 to 69", "Age 70 to 74", "Age 75 to 79",
      "Age 80 or older"
    ),
    ordered = TRUE
  ),

  DientesExtraidos = factor(
    DientesExtraidos,
    levels = c("None of them", "1 to 5", "6 or more, but not all", "All"),
    ordered = TRUE
  ),

  EstadoFumador = factor(
    EstadoFumador,
    levels = c(
      "Never smoked",
      "Former smoker",
      "Current smoker - now smokes some days",
      "Current smoker - now smokes every day"
    ),
    ordered = TRUE
  ),

  UsoCigarrilloElectronico = factor(
    UsoCigarrilloElectronico,
    levels = c(
      "Never used e-cigarettes in my entire life",
      "Not at all (right now)",
      "Use them some days",
      "Use them every day"
    ),
    ordered = TRUE
  ),

  UltimoChequeoMedico = factor(
    UltimoChequeoMedico,
    levels = c(
      "Within past year (anytime less than 12 months ago)",
      "Within past 2 years (1 year but less than 2 years ago)",
      "Within past 5 years (2 years but less than 5 years ago)",
```

```
        "5 or more years ago"
      ),
      ordered = TRUE
    ),

    # Binarización de CovidPositivo
    CovidPositivo = factor(
      case_when(
        CovidPositivo == "No" ~ "No",
        str_detect(CovidPositivo, "positive|Yes") ~ "Yes",
        TRUE ~ NA_character_
      ),
      levels = c("No", "Yes")
    ),

    # Binarización de VacunaTetanos10Anos
    VacunaTetanos10Anos = factor(
      case_when(
        str_detect(VacunaTetanos10Anos, "^No") ~ "No",
        str_detect(VacunaTetanos10Anos, "^Yes") ~ "Yes",
        TRUE ~ NA_character_
      ),
      levels = c("No", "Yes")
    ),

    # Índice de Comorbilidad (Suma de patologías crónicas excluyendo target)
    TotalEnfermedades = rowSums(
      across(c(Ictus, Diabetes, Asma, EPOC,
               EnfermedadRenal, Artritis, CancerPiel, TrastornoDepresivo)) == "Yes
      na.rm = TRUE
    ),

    # Factores nominales (resto de variables de texto restantes)
    across(where(is.character), as.factor)
  )

# Resumen del dataset
tabla_resumen <- tibble(
  Métrica = c("Total de Observaciones (Filas)", "Variables Totales",
              "Casos con Cardiopatía (Yes)", "Casos sin Cardiopatía (No)",
              "Porcentaje de Cardiopatía (%)"),
  Valor = c(
    nrow(heart_data),
    as.character(ncol(heart_data)),
    sum(heart_data$EnfermedadCardiaca == "Yes", na.rm = TRUE),
    sum(heart_data$EnfermedadCardiaca == "No", na.rm = TRUE),
    paste(round(mean(heart_data$EnfermedadCardiaca == "Yes", na.rm = TRUE) * 100,
  )
)

kable(tabla_resumen, caption = "Dimensiones iniciales y porcentaje de cardiopatías
```

Table 1. Dimensiones iniciales y porcentaje de cardiopatías.

Métrica	Valor
Total de Observaciones (Filas)	445132
Variables Totales	42
Casos con Cardiopatía (Yes)	39751
Casos sin Cardiopatía (No)	400360
Porcentaje de Cardiopatía (%)	9.03 %

2.4. Detección y Corrección de Inconsistencias

Siguiendo con el análisis exploratorio se analiza la presencia de valores especiales, valores numéricos imposibles para las variables y la consistencia entre el índice de masa corporal, el peso y la altura.

```
#Comprobación de valores especiales

infinitos <- sapply(heart_data %>% select(where(is.numeric)), function(x) sum(is.i
print("Valores infinitos por variable numérica:")
```

```
## [1] "Valores infinitos por variable numérica:"
```

```
print(infinitos)
```

```
## DiasMalaSaludFisica DiasMalaSaludMental          HorasSueno        AlturaMetros
##                   0                    0                   0                   0
##      PesoKilogramos                 IMC   TotalEnfermedades
##                   0                    0                   0
```

```
# Comprobación de valores menores o iguales a cero
menores_iguales_cero <- sapply(heart_data %>% select(where(is.numeric)), function(
print("Valores <= 0 por variable:")
```

```
## [1] "Valores <= 0 por variable:"
```

```
print(menores_iguales_cero)
```

```
## DiasMalaSaludFisica DiasMalaSaludMental          HorasSueno        AlturaMetros
##              267819              265229                   0                   0
##      PesoKilogramos                 IMC   TotalEnfermedades
##                   0                    0              173224
```

```
#En DiasMalaSaludFisica y en DiasMalaSaludMental sí tiene sentido encontrar
#iguales a 0

# Calculamos la diferencia entre el BMI registrado y el calculado

# Se usa un margen de tolerancia de 1.5 kg/m^2 porque los datos originales
# se recogieron en unidades imperiales (libras y pulgadas) y al convertirlos
# a metros y kilogramos se acumulan errores de redondeo de hasta +-1.2 puntos.
# Una diferencia superior a 1.5 indica un error real de incoherencia.

bmi_calculado <- heart_data$PesoKilogramos / (heart_data$AlturaMetros^2)
diferencia_bmi <- abs(heart_data$IMC - bmi_calculado)
```

```r
inconsistencias_bmi <- sum(diferencia_bmi > 1.5, na.rm = TRUE)

print(paste("Número de registros con BMI inconsistente respecto a peso/altura:", i
```

```
## [1] "Número de registros con BMI inconsistente respecto a peso/altura: 0"
```

```r
# Corrección de inconsistencias

# Sustituimos por NA valores biológicamente imposibles:
# - Horas de sueño: dormir <= 2h o >= 20h de forma continuada es anómalo/error
#   de encuesta
# - Alturas inferiores a 1 metro en adultos

heart_data <- heart_data %>%
  mutate(
    HorasSueno = ifelse(HorasSueno <= 2 | HorasSueno >= 20, NA, HorasSueno),
    AlturaMetros = ifelse(AlturaMetros < 1.0, NA, AlturaMetros)
  )
```

2.5. Valores Perdidos y Observaciones Completas

A continuación se cuantifica el número y porcentaje de valores perdidos presentes en las variables y se evalúa el volumen de observaciones completas.

```r
# Número y porcentaje de NAs por columna

nas_columna <- colSums(is.na(heart_data))
nas_columna
```

```
##                    Estado                      Sexo             SaludGeneral
##                         0                         0                     1198
##       DiasMalaSaludFisica       DiasMalaSaludMental       UltimoChequeoMedico
##                     10927                      9067                     8308
##          ActividadFisica              HorasSueno         DientesExtraidos
##                      1093                      8392                    11360
##         InfartoMiocardio             AnginaPecho                     Ictus
##                      3065                      4405                     1557
##                     Asma             CancerPiel                      EPOC
##                      1773                      3143                     2219
##       TrastornoDepresivo         EnfermedadRenal                  Artritis
##                      2812                      1926                     2633
##                 Diabetes       DificultadAuditiva         DificultadVisual
##                      1087                     20647                    21564
##  DificultadConcentracion        DificultadCaminar DificultadVestirseBanarse
##                     24240                     24012                    23915
##  DificultadTareasDiarias            EstadoFumador UsoCigarrilloElectronico
##                     25656                     35462                    35660
##          TomografiaTorax              RazaEtnia                GrupoEdad
##                     56046                     14057                     9079
##             AlturaMetros          PesoKilogramos                      IMC
##                     28683                     42078                    48806
##        ConsumidorAlcohol              PruebaVIH     VacunaGripeUltimoAno
##                     46574                     66127                    47121
##          VacunaNeumococo      VacunaTetanos10Anos       ConductaAltoRiesgo
##                     77040                     82516                    50623
```

```
##             CovidPositivo        EnfermedadCardiaca         TotalEnfermedades
##                     50764                      5021                         0
```

```
pct_nas <- round((nas_columna / nrow(heart_data)) * 100, 2)
pct_nas
```

```
##                    Estado                      Sexo             SaludGeneral
##                      0.00                      0.00                      0.27
##       DiasMalaSaludFisica       DiasMalaSaludMental       UltimoChequeoMedico
##                      2.45                      2.04                      1.87
##           ActividadFisica             HorasSueno          DientesExtraidos
##                      0.25                      1.89                      2.55
##          InfartoMiocardio             AnginaPecho                     Ictus
##                      0.69                      0.99                      0.35
##                     Asma             CancerPiel                      EPOC
##                      0.40                      0.71                      0.50
##        TrastornoDepresivo          EnfermedadRenal                 Artritis
##                      0.63                      0.43                      0.59
##                  Diabetes       DificultadAuditiva         DificultadVisual
##                      0.24                      4.64                      4.84
##   DificultadConcentracion        DificultadCaminar DificultadVestirseBanarse
##                      5.45                      5.39                      5.37
##   DificultadTareasDiarias           EstadoFumador UsoCigarrilloElectronico
##                      5.76                      7.97                      8.01
##           TomografiaTorax             RazaEtnia               GrupoEdad
##                     12.59                      3.16                      2.04
##             AlturaMetros          PesoKilogramos                       IMC
##                      6.44                      9.45                     10.96
##         ConsumidorAlcohol             PruebaVIH     VacunaGripeUltimoAno
##                     10.46                     14.86                     10.59
##           VacunaNeumococo      VacunaTetanos10Anos       ConductaAltoRiesgo
##                     17.31                     18.54                     11.37
##             CovidPositivo        EnfermedadCardiaca         TotalEnfermedades
##                     11.40                      1.13                      0.00
```

```
# Tabla con las variables que presentan valores perdidos (ordenadas de mayor a men
tabla_nas <- tibble(
  Variable = names(nas_columna),
  Num_NAs = nas_columna,
  Porcentaje = paste(pct_nas, " %")
) %>%
  filter(Num_NAs > 0) %>%
  arrange(desc(Num_NAs))

# Mostramos las 10 variables con mayor volumen de NAs
head(tabla_nas, 10)
```

```
## # A tibble: 10 x 3
##    Variable             Num_NAs Porcentaje
##    <chr>                  <dbl> <chr>
##  1 VacunaTetanos10Anos    82516 18.54  %
##  2 VacunaNeumococo        77040 17.31  %
##  3 PruebaVIH              66127 14.86  %
##  4 TomografiaTorax        56046 12.59  %
```

```
##  5 CovidPositivo           50764 11.4  %
##  6 ConductaAltoRiesgo      50623 11.37  %
##  7 IMC                     48806 10.96  %
##  8 VacunaGripeUltimoAno    47121 10.59  %
##  9 ConsumidorAlcohol       46574 10.46  %
## 10 PesoKilogramos          42078 9.45  %
```

```r
# Observaciones completas
num_completas <- sum(complete.cases(heart_data))
pct_completas <- round((num_completas / nrow(heart_data)) * 100, 2)

print(paste("Número de observaciones completas:", num_completas))
```

```
## [1] "Número de observaciones completas: 244635"
```

```r
print(paste("Porcentaje de observaciones completas:", pct_completas, "%"))
```

```
## [1] "Porcentaje de observaciones completas: 54.96 %"
```

A diferencia de análisis sobre muestras pequeñas donde se eliminan todas las filas incompletas, en este caso descartar observaciones con algún valor perdido supondría perder un porcentaje demasiado alto de los pacientes (principalmente por no haber contestado a preguntas secundarias como la vacunación o la prueba de VIH). Por tanto, se conservan las observaciones para el análisis general y se aplicarán métodos de imputación.

2.6. Estadísticos Descriptivos

Se analiza la influencia de los valores extremos sobrelas variables numéricas. Para ello, se calculan estadísticos clásicos sensibles a valores atípicos (media y desviación típica) y se contrastan con estimadores robustos (mediana, MADM e IQR).

```r
# Función MADM robusta a NAs
madm <- function(x, na.rm = TRUE) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)
}

# Cálculo de estadísticos para cada variable numérica
estadisticos_num <- heart_data %>%
  select(where(is.numeric)) %>%
  pivot_longer(
    cols = everything(),
    names_to = "Variable",
    values_to = "Valor"
  ) %>%
  group_by(Variable) %>%
  summarise(
    Media   = round(mean(Valor, na.rm = TRUE), 2),
    SD      = round(sd(Valor, na.rm = TRUE), 2),
    Mediana = round(median(Valor, na.rm = TRUE), 2),
    MADM    = round(madm(Valor, na.rm = TRUE), 2),
    IQR     = round(IQR(Valor, na.rm = TRUE), 2)
  )

kable(estadisticos_num, caption = "Comparativa de estadísticos clásicos y robustos
```

Table 2. Comparativa de estadísticos clásicos y robustos en variables numéricas.

Variable	Media	SD	Mediana	MADM	IQR
AlturaMetros	1.70	0.11	1.70	0.12	0.15
DiasMalaSaludFisica	4.35	8.69	0.00	0.00	3.00
DiasMalaSaludMental	4.38	8.39	0.00	0.00	5.00
HorasSueno	7.05	1.41	7.00	1.48	2.00
IMC	28.53	6.55	27.44	5.53	7.62
PesoKilogramos	83.07	21.45	80.74	18.83	27.21
TotalEnfermedades	1.10	1.20	1.00	1.48	2.00

Por ahora no vamos a analizar estos valores ya que esto se hará en el análisis de resultados, pero conocer estos valores es necesario para la posterior detección de outliers.

2.7. Detección Univariante de Outliers y Comparativa de Métodos

A continuación se aplican y comparan cuatro métodos de detección de outliers sobre el IMC (Índice de Masa Corporal): regla 3 sigma, identificador Hampel, regla del boxplot y percentiles (5% y 95%).

Para cada método se evalúa tanto el número de anomalías detectadas como los umbrales que definen los valores típicos para decidir como tratar a los valores extremos.

```r
# 1. Definición de las 4 funciones de detección

# Regla 3 Sigma
reglasigma <- function(x) {
  media <- mean(x, na.rm = TRUE)
  desviacion <- sd(x, na.rm = TRUE)
  abs(x - media) > 3 * desviacion
}

# Identificador Hampel
reglahampel <- function(x) {
  mediana <- median(x, na.rm = TRUE)
  mad <- 1.4826 * median(abs(x - mediana), na.rm = TRUE)
  abs(x - mediana) > 3 * mad
}

# Regla Boxplot
reglaboxplot <- function(x) {
  q1 <- quantile(x, 0.25, na.rm = TRUE)
  q3 <- quantile(x, 0.75, na.rm = TRUE)
  iqr <- q3 - q1
  (x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)
}

# Percentiles (5% - 95%)
reglapercentil <- function(x) {
  p05 <- quantile(x, 0.05, na.rm = TRUE)
  p95 <- quantile(x, 0.95, na.rm = TRUE)
  (x < p05) | (x > p95)
}

# Aplicación de las reglas sobre el IMC
heart_outliers <- heart_data %>%
```

```r
  mutate(
    IMC_Sigma     = reglasigma(IMC),
    IMC_Hampel    = reglahampel(IMC),
    IMC_Boxplot   = reglaboxplot(IMC),
    IMC_Percentil = reglapercentil(IMC)
  )

# Cálculo de umbrales y tabla comparativa
media_imc <- mean(heart_data$IMC, na.rm = TRUE)
sd_imc    <- sd(heart_data$IMC, na.rm = TRUE)
med_imc   <- median(heart_data$IMC, na.rm = TRUE)
mad_imc   <- 1.4826 * median(abs(heart_data$IMC - med_imc), na.rm = TRUE)
q1_imc    <- quantile(heart_data$IMC, 0.25, na.rm = TRUE)
q3_imc    <- quantile(heart_data$IMC, 0.75, na.rm = TRUE)
iqr_imc   <- q3_imc - q1_imc
p05_imc   <- quantile(heart_data$IMC, 0.05, na.rm = TRUE)
p95_imc   <- quantile(heart_data$IMC, 0.95, na.rm = TRUE)

tabla_outliers <- tibble(
  Método = c("Regla 3 Sigma", "Identificador Hampel", "Regla Boxplot", "Percentile
  Outliers_Detectados = c(
    sum(heart_outliers$IMC_Sigma, na.rm = TRUE),
    sum(heart_outliers$IMC_Hampel, na.rm = TRUE),
    sum(heart_outliers$IMC_Boxplot, na.rm = TRUE),
    sum(heart_outliers$IMC_Percentil, na.rm = TRUE)
  ),
  Porcentaje = paste(round(c(
    mean(heart_outliers$IMC_Sigma, na.rm = TRUE),
    mean(heart_outliers$IMC_Hampel, na.rm = TRUE),
    mean(heart_outliers$IMC_Boxplot, na.rm = TRUE),
    mean(heart_outliers$IMC_Percentil, na.rm = TRUE)
  ) * 100, 2), "%"),
  Umbral_Inferior = round(c(media_imc - 3 * sd_imc, med_imc - 3 * mad_imc, q1_imc
  Umbral_Superior = round(c(media_imc + 3 * sd_imc, med_imc + 3 * mad_imc, q3_imc
)

kable(tabla_outliers, caption = "Comparativa de métodos de detección de outliers y
```

Table 3. Comparativa de métodos de detección de outliers y umbrales en la variable IMC.

Método	Outliers_Detectados	Porcentaje	Umbral_Inferior	Umbral_Superior
Regla 3 Sigma	5071	1.28 %	8.87	48.19
Identificador Hampel	10657	2.69 %	10.85	44.03
Regla Boxplot	12339	3.11 %	12.70	43.18
Percentiles (5% - 95%)	38840	9.8 %	20.12	40.69

La regla 3 Sigma es poco agresiva: fija el umbral superior en 48.21, detectando solo un 1.28% de outliers debido a que la propia desviación típica se expande por la presencia de casos extremos. **El identificador Hampel es más agresivo:** al basarse en el MADM, sitúa el umbral superior en 44.03, identificando un 2.69% de anomalías. **La regla del Boxplot:** con un umbral superior de 43.33 y detectando un 3.11% de valores fuera de los bigotes.

Esto pasa porque justo la variable IMC no es simétrica si no con una cola a la derecha. **Percentiles:** corta de forma fija el 10% de la muestra, con independencia de la distribución.

Tratamiento de los outliers identificados: Estos valores de IMC no representan errores de medición o transcripción (ya fueron filtrados antes), sino observaciones biológicamente reales correspondientes a pacientes con obesidad mórbida (grado III). Por tanto, no se eliminan del conjunto de datos, sino que se conservan para ser analizados mediante procedimientos y estadísticos en los siguientes bloques.

2.8. Representación Gráfica de Outliers por Método

Se representan gráficamente los valores de IMC frente a los métodos de detección empleados, mostrando los datos catalogados como típicos y los catalogados como outliers en distinto color.

Para evitar problemas de saturación visual en el gráfico debido al volumen de más de 400.000 observaciones, se utiliza una muestra aleatoria representativa de 5.000 observaciones con set.seed(123) y se aplica dispersión aleatoria con transparencia.

```
# Preparación de datos
set.seed(123)

df_plot_outliers <- heart_outliers %>%
  select(IMC, starts_with("IMC_")) %>%
  filter(!is.na(IMC)) %>%
  slice_sample(n = 5000) %>%
  pivot_longer(
    cols = starts_with("IMC_"),
    names_to = "Metodo",
    values_to = "Es_Outlier"
  )

# Gráfico de puntos con jitter
ggplot(df_plot_outliers, aes(x = Metodo, y = IMC, color = !Es_Outlier)) +
  geom_point(position = "jitter", alpha = 0.4, size = 0.8) +
  labs(
    title = "Detección de Outliers en IMC por Método",
    x = "Método de Detección",
    y = "Índice de Masa Corporal (IMC)",
    color = "No es Outlier"
  )
```

El gráfico refleja de manera visual la sensibilidad de cada método.

Continuidad de los datos: Se observa que los valores superiores no son puntos aislados ni errores tipográficos, sino una nube continua que se extiende hasta valores extremos, confirmando que se trata de individuos con obesidad severa real que deben conservarse en la muestra.

- **Comparativa de cortes:** La regla 3 Sigma deja una franja alta de puntos clasificados como normales (debido a la varianza inflada), mientras que la regla del Boxplot y el identificador Hampel capturan de forma equilibrada la masa de valores atípicos.

2.9. Imputación de Variables Numéricas

Para garantizar la integridad de los análisis cuantitativos posteriores sin introducir sesgos artificiales, se aplica una imputación según la naturaleza de cada variable:

Variables AlturaMetros, PesoKilogramos, IMC: Hombres y mujeres siguen distribuciones distintas. Imputamos los valores perdidos directamente por la media según el Sexo del paciente.

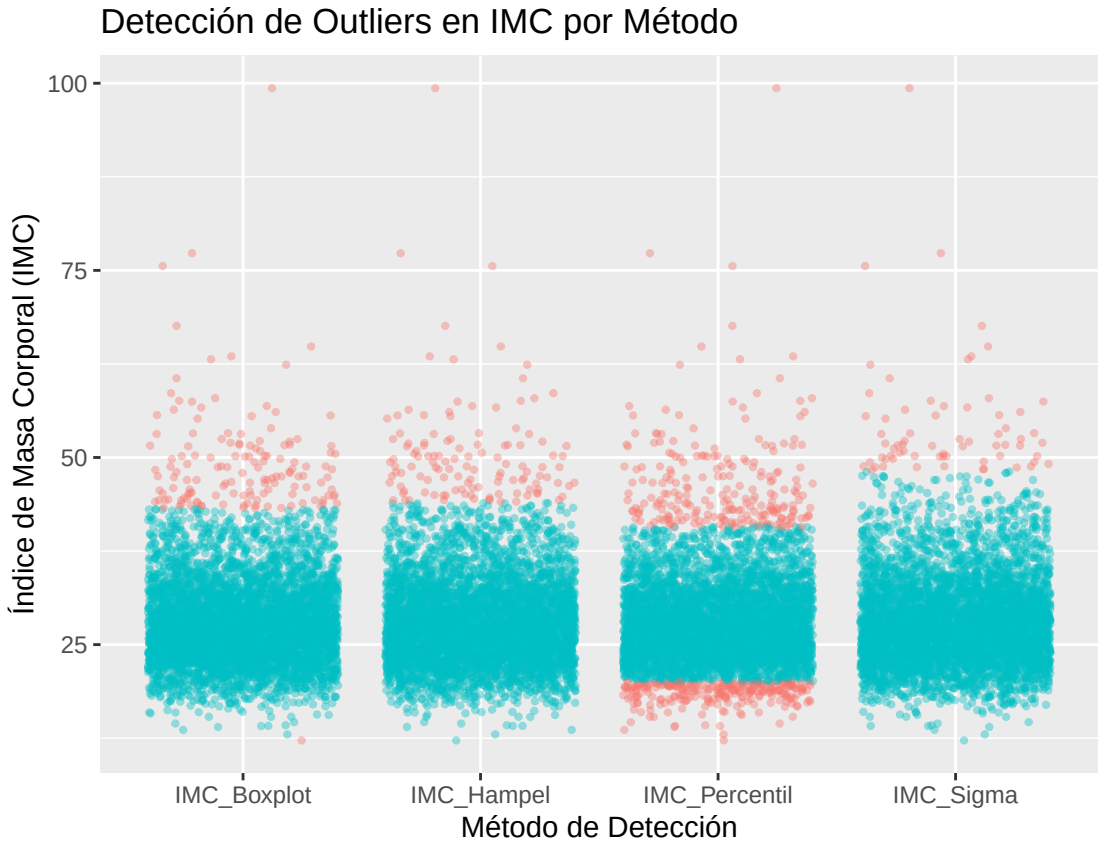


Figure 1. Detección de outliers en IMC según cada método implementado.

Variables de descanso y salud percibida (`HorasSueno`, `DiasMalaSaludFisica`, `DiasMalaSalud`
Al concentrarse en valores típicos (7 horas de sueño y 0 días de enfermedad), se imputan mediante su mediana.

```
# Imputación de medidas por Sexoç

heart_data <- heart_data %>%
  group_by(Sexo) %>%
  mutate(
    AlturaMetros   = ifelse(is.na(AlturaMetros), mean(AlturaMetros, na.rm = TRUE),
    PesoKilogramos = ifelse(is.na(PesoKilogramos), mean(PesoKilogramos, na.rm = TR
    IMC            = ifelse(is.na(IMC), mean(IMC, na.rm = TRUE), IMC)
  ) %>%
  ungroup()

# Imputación de descanso y salud percibida por la mediana

heart_data <- heart_data %>%
  mutate(
    HorasSueno          = ifelse(is.na(HorasSueno), median(HorasSueno, na.rm = TRU
    DiasMalaSaludFisica = ifelse(is.na(DiasMalaSaludFisica), median(DiasMalaSaludF
    DiasMalaSaludMental = ifelse(is.na(DiasMalaSaludMental), median(DiasMalaSaludM
  )
# Comprobación final de NAs restantes en variables numéricas
```

```
nas_numericas_final <- sapply(heart_data %>% select(where(is.numeric)), function(x
print("NAs restantes en variables numéricas tras la imputación:")
```

```
## [1] "NAs restantes en variables numéricas tras la imputación:"
```

```
print(nas_numericas_final)
```

```
## DiasMalaSaludFisica DiasMalaSaludMental          HorasSueno        AlturaMetros
##                   0                   0                   0                   0
##      PesoKilogramos                 IMC   TotalEnfermedades
##                   0                   0                   0
```

Tras el proceso de imputación, todas las variables numéricas continuas y discretas del estudio quedan con cero valores perdidos, listas para el análisis bivariante y multivariante.

2.10. 2.10. Estrategia de Análisis Estadístico

Para dar respuesta a las preguntas planteadas, estudiaremos el conjunto de datos en dos etapas:

- **Análisis Univariante:** Se examinará de forma individual la distribución y el comportamiento de cada variable del conjunto de datos. En el caso de las variables cuantitativas, se calculará estadísticos de tendencia central (media y mediana) y de dispersión clásicos y robustos (desviación típica, rango intercuartílico y MADM). Su representación visual se realizará mediante histogramas y gráficos de densidad, evaluando la normalidad de las distribuciones a través de QQ-plots. Las variables cualitativas y factores se caracterizarán mediante distribuciones de frecuencias absolutas y relativas, apoyadas en diagramas de barras.
- **Análisis Bivariante:** Se estudiarán las asociaciones e dependencias entre pares de variables para identificar patrones . Para las variables cuantitativas se emplearán coeficientes de correlación, tanto Pearson como Spearman]. En el caso de las variables cualitativas, se utilizan tablas de contingencia y el test de independencia de χ^2 . Asimismo, para evaluar la relación entre variables cuantitativas y cualitativas se recurrirá a diagramas de caja (*boxplots*) y gráficos de distribución comparada.

3. Resultados

En este apartado vamos a estudiar los datos como hemos mencionado en la sección anterior, dividiéndolo en dos subsecciones dependiendo de la naturaleza del análisis.

3.1. Análisis Univariante

A su vez, el análisis univariante lo vamos a estructurar dependiendo del tipo de dato de cada columna.

3.1.1. Variables Cuantitativas

El análisis univariante de las variables cuantitativas (`AlturaMetros`, `PesoKilogramos`, `IMC`, `HorasSueno`, `TotalEnfermedades`, `DiasMalaSaludFisica` y `DiasMalaSaludMental`) permite evaluar sus propiedades distribucionales, contrastando los estadísticos clásicos con estimadores robustos para mitigar el efecto de la asimetría y la presencia de colas pesadas.

Primero vamos a comenzar con unos plots de las distribuciones de cada variable, obviando `AlturaMetros` y `PesoKilogramos` porque son algo redundantes con `IMC`.

```
library(tidyverse)

heart_data %>%
  select(IMC, HorasSueno, DiasMalaSaludFisica, DiasMalaSaludMental) %>%
```

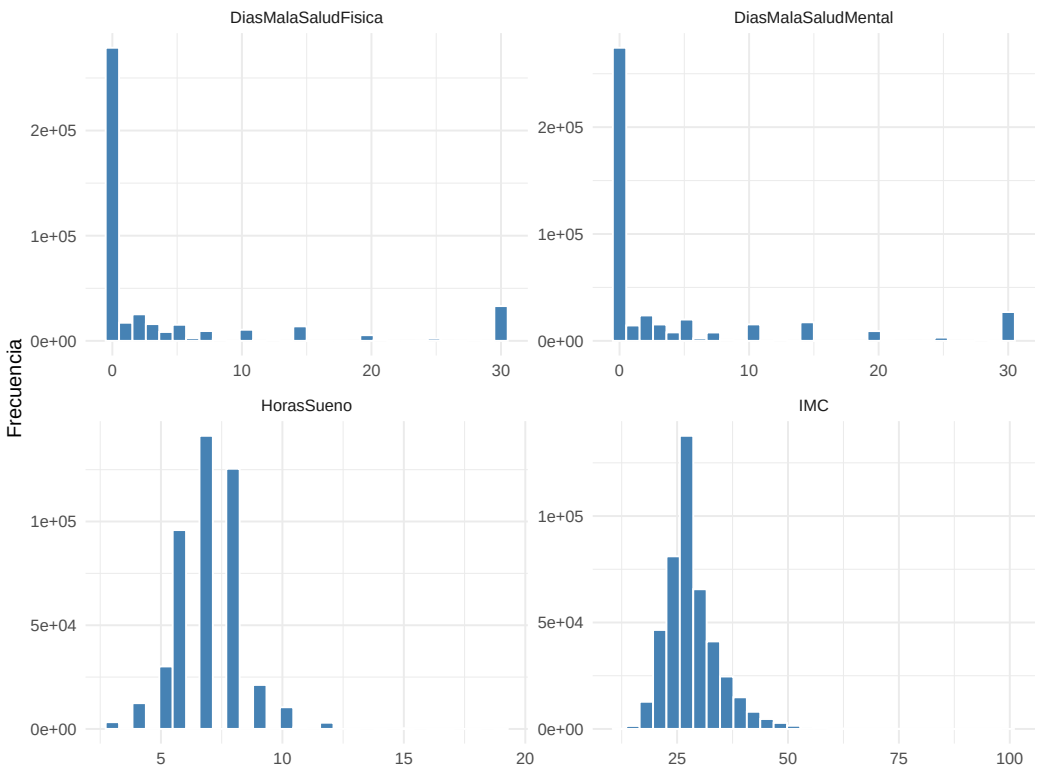


Figure 2. Distribución de las variables cuantitativas principales.

```
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>
  ggplot(aes(x = Valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  facet_wrap(~ Variable, scales = "free") +
  theme_minimal() +
  labs(x = NULL, y = "Frecuencia")
```

Con estos histogramas podemos sacar varias conclusiones. De las dos primeras gráficas es resaltable la tendencia a valores pequeños de ambas variables, pero también el sesgo presente hacia los valores extremos 30 y 0 por la naturaleza de las variables (al ser una respuesta subjetiva en una encuesta). Por otra parte, el histograma de horas de sueño también es peculiar en su medida, ya que se nota un cierto sesgo en ciertos números, pero la distribución es mucho más parecida a una normal. Por último, con el BMI pasa algo similar a esto último, ya que la distribución es bastante centrada.

Todo esto podemos verlo de mejor manera en la tabla `estadisticos_num` hecha previamente. Sin embargo, antes de comentar lo que vemos en esta tabla podemos ampliarla con algunos estadísticos que habíamos obviado previamente.

```
skewness <- function(x) {
  x <- x[!is.na(x)]
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^3 / s^3) / n
}

kurtosis <- function(x) {
  x <- x[!is.na(x)]
```

```r
  n <- length(x)
  m <- mean(x)
  s <- sd(x)
  sum((x - m)^4 / s^4) / n - 3
}

madm <- function(x) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)
}

# Hago de nuevo la tabla por todas las imputaciones y demas cambios que hemos hech
estadisticos_num <- heart_data %>%
  select(where(is.numeric)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>
  group_by(Variable) %>%
  summarise(
    Media    = round(mean(Valor, na.rm = TRUE), 2),
    SD       = round(sd(Valor, na.rm = TRUE), 2),
    Mediana  = round(median(Valor, na.rm = TRUE), 2),
    MADM     = round(madm(Valor), 2),
    IQR      = round(IQR(Valor, na.rm = TRUE), 2),
    Sesgo    = round(skewness(Valor), 2),
    Curtosis = round(kurtosis(Valor), 2)
  )

kable(estadisticos_num, caption = "Estadísticos descriptivos y de forma para varia
```

Table 4. Estadísticos descriptivos y de forma para variables cuantitativas.

Variable	Media	SD	Mediana	MADM	IQR	Sesgo	Curtosis
AlturaMetros	1.70	0.11	1.70	0.12	0.15	0.07	0.02
DiasMalaSaludFisica	4.24	8.61	0.00	0.00	3.00	2.22	3.62
DiasMalaSaludMental	4.29	8.32	0.00	0.00	4.00	2.16	3.51
HorasSueno	7.05	1.39	7.00	1.48	2.00	0.67	4.81
IMC	28.53	6.19	28.29	4.94	6.60	1.47	5.35
PesoKilogramos	82.84	20.53	79.38	16.81	23.14	1.14	3.24
TotalEnfermedades	1.10	1.20	1.00	1.48	2.00	1.19	1.37

Al observar la tabla nos damos cuenta de varias cosas:

- En `DiasMalaSaludFisica` y `DiasMalaSaludMental`, la mediana y el MADM son 0 (la mayoría de los individuos dicen no tener días de enfermedad, como habíamos visto), mientras que la media se sitúa en torno a 4 días con una desviación típica de más de 8 días, claramente inflada por los individuos con patologías crónicas graves (30 días).
- En el `IMC` y el `PesoKilogramos`, la media es superior a la mediana debido a la presencia de casos con obesidad severa en la cola superior de la distribución.
- La variable `NumeroEnfermedades` es numérica pero es basicamente un factor, ya que hay poco rango de enfermedades que se pueden padecer. El valor medio y mediano ronda 1 enfermedad por persona pero su distribución no merece la pena representarse gráficamente por ahora.
- En cuanto al sesgo, como cabría esperar, las variables más asimétricas son las que más sesgo tienen. Además, vemos que `IMC` tiene un sesgo no despreciable, lo que sugiere que la distribución quizás no es normal.

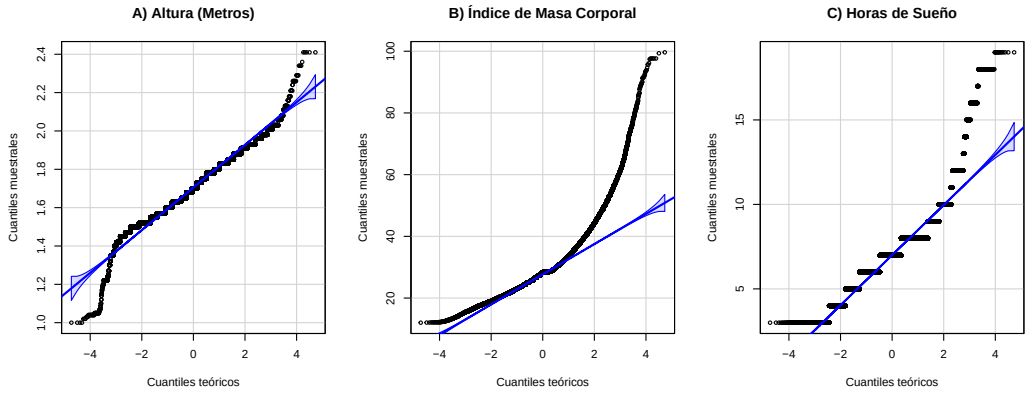


Figure 3. Comparativa de gráficos QQ de normalidad para Altura, IMC y Horas de Sueño.

- La curtosis nos revela también que las colas de `IMC` y de `HorasSueno` son demasiado anchas, así que probablemente no nos encontramos ante distribuciones normales.
- `AlturaMetros` sí parece seguir algo parecido a una normal debido a su curtosis y sesgo.

Como último paso para este tipo de variables vamos a comprobar la normalidad con Q-Q plots, ya que los test de normalidad se ven muy penalizados por la cantidad tan grande de instancias que tenemos.

```
par(mfrow = c(1, 3))

qqPlot(heart_data$AlturaMetros,
       main = "A) Altura (Metros)",
       xlab = "Cuantiles teóricos",
       ylab = "Cuantiles muestrales",
       id = FALSE)

qqPlot(heart_data$IMC,
       main = "B) Índice de Masa Corporal",
       xlab = "Cuantiles teóricos",
       ylab = "Cuantiles muestrales",
       id = FALSE)

qqPlot(heart_data$HorasSueno,
       main = "C) Horas de Sueño",
       xlab = "Cuantiles teóricos",
       ylab = "Cuantiles muestrales",
       id = FALSE)
```

```
par(mfrow = c(1, 1))
```

Comparando los cuantiles de nuestra distribución con los de una gaussiana teórica vemos como el desplazamiento de las distribuciones de `IMC` y `HorasSueno` son lo suficientemente importantes como para descartar su normalidad, pero con altura vemos como su comportamiento puede ser lo suficientemente parecido como para asumir que sigue una distribución gaussiana.

3.1.2. Variables Binarias

Comenzando el análisis de las variables binarias, lo primero que vamos a hacer es el cálculo de la proporción de 'Sí' en cada una de las variables.

```r
variables_binarias <- heart_data %>%
  select(where(~ is.factor(.x) && nlevels(.x) == 2)) %>%
  names()

tabla_binarias <- heart_data %>%
  select(any_of(variables_binarias)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Respuesta"
  filter(!is.na(Respuesta)) %>%
  count(Variable, Respuesta, name = "Conteo") %>%
  group_by(Variable) %>%
  mutate(Porcentaje = round((Conteo / sum(Conteo)) * 100, 2)) %>%
  ungroup() %>%
  filter(Respuesta == "Yes") %>%
  arrange(desc(Porcentaje)) %>%
  select(Variable, N = Conteo, Porcentaje = Porcentaje)

kable(tabla_binarias, caption = "Frecuencia de factores de riesgo y patologías bin
```

Table 5. Frecuencia de factores de riesgo y patologías binarias.

Variable	N	Porcentaje
ActividadFisica	337559	76.02
VacunaTetanos10Anos	241123	66.50
ConsumidorAlcohol	210891	52.91
VacunaGripeUltimoAno	209256	52.58
TomografiaTorax	165865	42.63
VacunaNeumococo	152488	41.43
Artritis	151148	34.16
PruebaVIH	129086	34.06
CovidPositivo	124313	31.52
TrastornoDepresivo	91410	20.67
DificultadCaminar	68081	16.17
Diabetes	71487	16.10
Asma	66694	15.04
DificultadConcentracion	50100	11.90
DificultadAuditiva	38946	9.17
EnfermedadCardiaca	39751	9.03
EPOC	35656	8.05
CancerPiel	35485	8.03
DificultadTareasDiarias	32447	7.74
AnginaPecho	26551	6.02
InfartoMiocardio	25108	5.68
DificultadVisual	23658	5.59
EnfermedadRenal	20315	4.58
ConductaAltoRiesgo	17185	4.36
Ictus	19239	4.34
DificultadVestirseBanarse	16813	3.99

Viendo esta tabla podemos destacar la presencia de distintos tipos de variables, con frecuencias más o menos grandes. Destaca el desbalance de nuestra variable objetivo, con un 9% de casos positivos, lo cual puede ser importante en un futuro al trabajar con modelos predictivos. Para tener una mejor idea de lo que estamos viendo en el resto de variables podemos fragmentar las variables en distintos grupos, siendo estos grupos hábitos, otras patologías y distintas medidas de prevención.

```r
#es necesario dividir en grupos primero

habitos_binarios <- c("ActividadFisica", "ConsumidorAlcohol")
patologias_binarias <- c("Ictus", "Diabetes",
                         "Asma", "EPOC", "EnfermedadRenal", "Artritis",
                         "CancerPiel", "TrastornoDepresivo")
prevencion_binarias <- c("TomografiaTorax", "PruebaVIH", "VacunaGripeUltimoAno",
                         "VacunaNeumococo", "VacunaTetanos10Anos", "ConductaAltoRi
limitaciones_binarias <- c("DificultadAuditiva", "DificultadVisual", "DificultadCo
                           "DificultadCaminar", "DificultadVestirseBanarse", "Difi

todas_binarias <- c(habitos_binarios, patologias_binarias, prevencion_binarias,lim


tabla_binarias_tematica <- heart_data %>%
  select(any_of(todas_binarias)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Respuesta"
  filter(!is.na(Respuesta)) %>%
  count(Variable, Respuesta, name = "Conteo") %>%
  group_by(Variable) %>%
  mutate(Porcentaje = round((Conteo / sum(Conteo)) * 100, 2)) %>%
  ungroup() %>%
  filter(Respuesta == "Yes") %>%
  mutate(
    BloqueTematico = case_when(
      Variable %in% habitos_binarios     ~ "1. Hábitos de Vida",
      Variable %in% patologias_binarias  ~ "2. Patologías y Antecedentes",
      Variable %in% prevencion_binarias  ~ "3. Prevención y Atención Médica",
      Variable %in% limitaciones_binarias  ~ "4. Limitaciones",
      TRUE                               ~ "Otros"
    )
  ) %>%
  select(BloqueTematico, Variable, Casos_Yes = Conteo, Prevalencia_Pct = Porcentaj
  arrange(BloqueTematico, desc(Prevalencia_Pct))


heart_data %>%
  select(any_of(todas_binarias)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Respuesta"
  filter(!is.na(Respuesta)) %>%
  count(Variable, Respuesta) %>%
  group_by(Variable) %>%
  mutate(Proporcion = n / sum(n)) %>%
  ungroup() %>%
  filter(Respuesta == "Yes") %>%
  mutate(
    BloqueTematico = case_when(
      Variable %in% habitos_binarios     ~ "1. Hábitos de Vida",
      Variable %in% patologias_binarias  ~ "2. Patologías y Antecedentes",
      Variable %in% prevencion_binarias  ~ "3. Prevención y Atención Médica",
      Variable %in% limitaciones_binarias  ~ "4. Limitaciones",
      TRUE                               ~ "Otros"
    )
  ) %>%
```

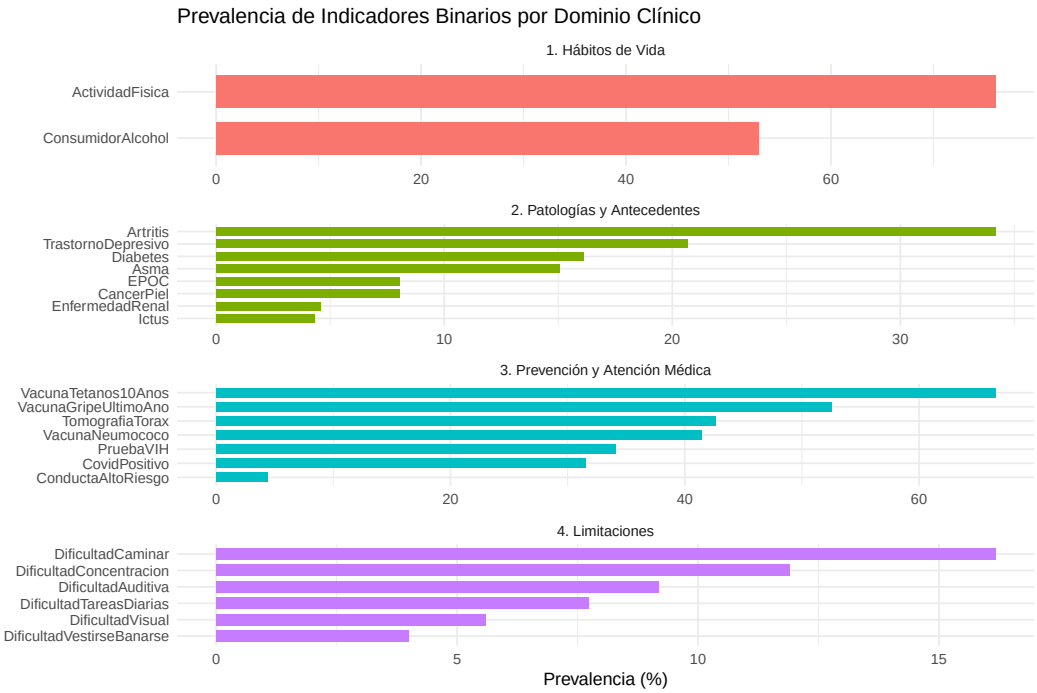


Figure 4. Prevalencia de factores binarios agrupados por dominios clínicos de la introducción.

```
  ggplot(aes(x = reorder(Variable, Proporcion), y = Proporcion * 100, fill = Bloqu
  geom_col(width = 0.7, show.legend = FALSE) +
  coord_flip() +
  facet_wrap(~ BloqueTematico, scales = "free", ncol = 1) +
  theme_minimal() +
  labs(title = "Prevalencia de Indicadores Binarios por Dominio Clínico",
       x = NULL, y = "Prevalencia (%)")
```

De esta manera, el análisis de cada grupo se vuelve más fácil.

- Los hábitos de vida son solo 2, así que solo podemos comentar que son variables muy balanceadas.
- Las patologías tienden a ser más raras y por tanto conviene llevar cuidado con el desbalanceo de clases.
- El tercer gráfico correspondiente a la atención médica y prevenciones detaca que volvemos a tener variables más o menos balanceadas exceptuando `ConductaAltoRiesgo`.
- Por último exploramos las variables que expresan las dificultades en distintos ámbitos de la vida, que por supuesto son variables bastante desbalanceadas a favor del no.

Por último, conviene destacar que al igual que con diabetes alguna variable podría perder algo de información para volverse binaria y analizarla aquí pero a priori no parece que merezca la pena. Otra variable que puede ser interpretada como binaria es la de `Sexo` , pero su balance hace que no aporte nada analizarla aquí.

```
heart_data %>% count(Sexo) %>% mutate(Porcentaje = round(n / sum(n) * 100, 2))
```

```
## # A tibble: 2 x 3
##   Sexo        n Porcentaje
##   <fct>   <int>      <dbl>
## 1 Female 235893       53.0
## 2 Male   209239       47.0
```

3.1.3. Variables Categóricas

Por último, estudiaremos las variables categóricas. Estas variables son mucho más difíciles de interpretar de manera univariante ya que no podemos calcular medias ni otros estadísticos,y como mucho podemos aprovechar que estas categorías estén algo ordenadas para extraer algo más de información.

Por tanto, vamos a comenzar graficando las variables que tienen cierto orden.

```
#por como funcionan los factores tenemos que usar patchwork para construir los sub

plot_ordinal <- function(var_name, title_text, bar_color = "#2b5c8f") {
  heart_data %>%
    filter(!is.na(.data[[var_name]])) %>%
    count(.data[[var_name]]) %>%
    mutate(Prop = (n / sum(n)) * 100) %>%
    ggplot(aes(x = .data[[var_name]], y = Prop)) +
    # Color fijo para todas las barras, eliminando el mapeo multicolor
    geom_col(fill = bar_color, width = 0.7, color = "#1a365d", linewidth = 0.2) +
    theme_minimal() +
    labs(title = title_text, x = NULL, y = "Porcentaje (%)") +
    theme(
      axis.text.x = element_text(angle = 25, hjust = 1, size = 8),
      plot.title = element_text(size = 10, face = "bold")
    )
}


g1 <- plot_ordinal("SaludGeneral", "Salud General", bar_color = "#2b5c8f")
g2 <- plot_ordinal("GrupoEdad", "Grupo de Edad", bar_color = "#2e8b57")
g3 <- plot_ordinal("DientesExtraidos", "Dientes Extraídos", bar_color = "#d97706")
g4 <- plot_ordinal("EstadoFumador", "Estado Fumador", bar_color = "#7c3aed")
g5 <- plot_ordinal("UsoCigarrilloElectronico", "Uso de Cigarrillo Electrónico", ba
g6 <- plot_ordinal("UltimoChequeoMedico", "Último Chequeo Médico", bar_color = "#b


(g1 + g2) / (g3 + g4) / (g5 + g6)
```

En estos gráficos de barras podemos ver claramente la moda y la distribución general de la variables, pudiendo detectar sesgos. En estos casos hay variables claramente sesgadas (por ejemplo es muy claro que lo más común es que no hayan dientes extraidos) pero nada que resulte raro.

Por último vamos a graficar las dos últimas variables que no hemos tratado, aunque es más bien para tener una idea de qué son ya que además de ser dos variables que a priori no parecen muy importantes para la pregunta que queremos responder, son muy difíciles de interpretar.

```
#misma estructura que antes pero ahora ordenado de mayor a menor frecuencia. en el

plot_nominal <- function(var_name, title_text, bar_color) {
  heart_data %>%
    filter(!is.na(.data[[var_name]])) %>%
    count(.data[[var_name]]) %>%
    mutate(
      Prop = (n / sum(n)) * 100,
      Categoria = fct_reorder(.data[[var_name]], Prop, .desc = TRUE)
    ) %>%
```

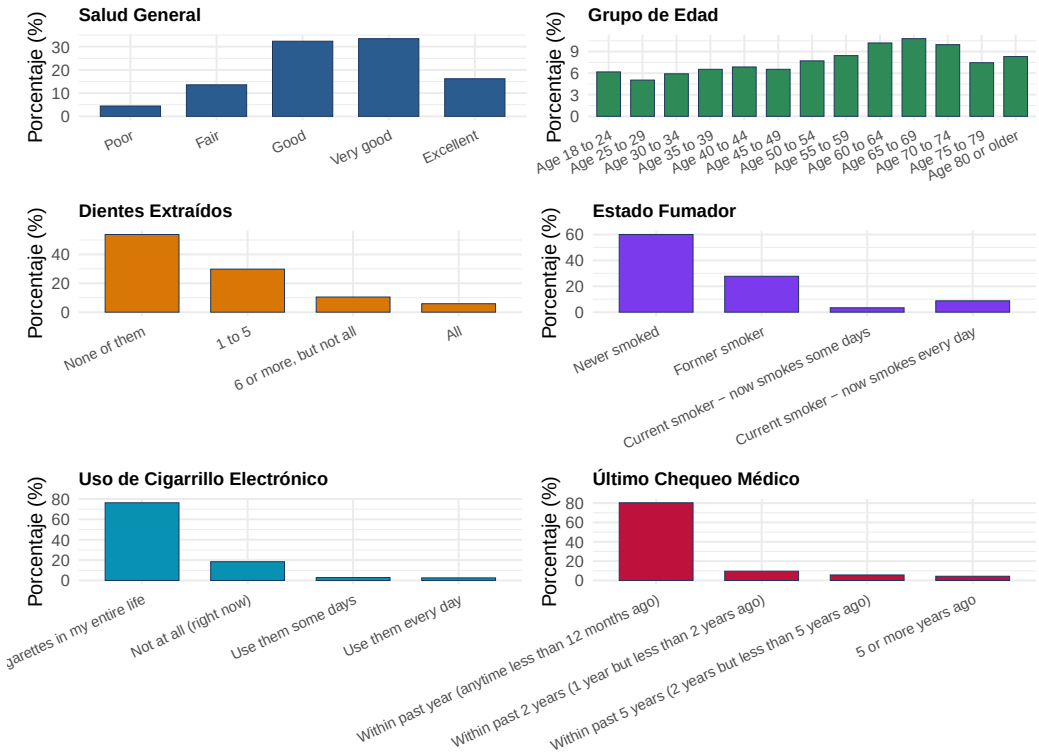


Figure 5. Distribución porcentual conjunta de los factores ordinales respetando su jerarquía lógica.

```
    ggplot(aes(x = Categoria, y = Prop)) +
    geom_col(fill = bar_color, width = 0.7, color = "#1a365d", linewidth = 0.2) +
    theme_minimal() +
    labs(title = title_text, x = NULL, y = "Porcentaje (%)") +
    theme(
      axis.text.x = element_text(angle = 25, hjust = 1, size = 8),
      plot.title = element_text(size = 10, face = "bold")
    )
}


g_raza <- plot_nominal("RazaEtnia", "Distribución por Raza / Etnia", bar_color = "
g_region <- heart_data %>%
  filter(!is.na(Estado)) %>%
  mutate(Estado = fct_lump_n(Estado, n = 15, other_level = "Otros")) %>%
  count(Estado) %>%
  mutate(
    Prop = (n / sum(n)) * 100,
    Estado = fct_reorder(Estado, Prop, .desc = TRUE)
  ) %>%
  ggplot(aes(x = Estado, y = Prop)) +
  geom_col(fill = "#10b981", width = 0.7, color = "#1a365d", linewidth = 0.2) +
  theme_minimal() +
  labs(title = "Distribución Geográfica (Top 15 Estados)", x = NULL, y = "Porcenta
  theme(
    axis.text.x = element_text(angle = 25, hjust = 1, size = 9),
    plot.title = element_text(size = 11, face = "bold")
  )
```

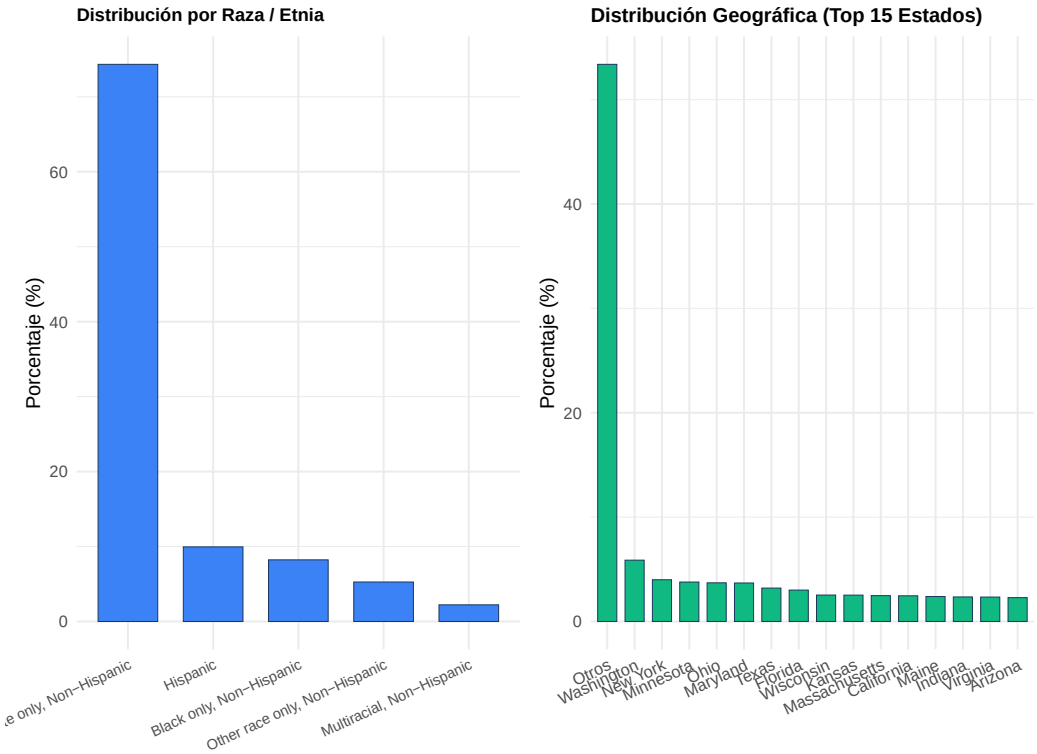


Figure 6. Distribución porcentual de las variables nominales (Raza y Región) ordenadas por frecuencia descendente.

```
g_raza + g_region
```

Para que el gráfico sea legible se ha tenido que optar por visualizar solo los 15 estados más representados, pero se entiende que no hay mucha variabilidad entre estados.

3.2. Análisis Bivariante

4. Discusión

Authors should discuss the results and how they can be interpreted in perspective of previous studies and of the working hypotheses. The findings and their implications should be discussed in the broadest context possible. Future research directions may also be highlighted.

5. Conclusión

This section is not mandatory, but can be added to the manuscript if the discussion is unusually long or complex.

Funding: Este trabajo no ha recibido financiación externa.

Institutional Review Board Statement: Not applicable

Informed Consent Statement: Not applicable

Data Availability Statement: Los datos utilizados están disponibles en el repositorio de GitHub del proyecto.

Conflicts of Interest: Los autores declaran no tener conflicto de intereses.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.